

Phase 3 — 知识库系统

SPEC-006 | Status: 设计中 | 依赖: SPEC-004

目标

实现知识库文档全生命周期：上传解析 → LLM 语义分片 → GridFS 存储 → Milvus 向量索引 → 混合搜索 → 智能解读 → 聚合层管理。

前置依赖检查

前置 Spec	状态	备注
SPEC-002	✓/✗	CI Pipeline 就绪
SPEC-003	✓/✗	基础设施可用
SPEC-004	✓/✗	Agent Engine + Skill 接口可用

实现知识库文档全生命周期：上传解析 → LLM 语义分片 → GridFS 存储 → Milvus 向量索引 → 混合搜索 → 智能解读 → 聚合层管理。

背景

Roadmap Phase 3 (Week 5-6), P3-01 ~ P3-13, 总计 ~55h。知识库是 Agent 回答质量的核心依赖。

详细设计

1. 文档解析引擎

- 支持 PDF (ledongthuc/pdf)、Word、Excel (xuri/excelize)、Markdown、TXT
- 统一输出纯文本

2. 文档存储

- 所有知识库文档统一存入 GridFS (MongoDB)
- 小文件和大文件同一路径, GridFS 自动 255KB 分片
- `knowledge_doc_contents`: `gridfs_file_id` + `filename` + `size_bytes`

3. LLM 语义分片

- 复用当前 LLM 判断语义段落边界
- 每 chunk 目标 500 字符
- Index Worker 通过 `GridFSDownloadStream` (`io.ReadSeeker`) 分批读取

4. Milvus 向量索引

- Collection: `knowledge_chunks` (1536d OpenAI / 768d 其他)
- `doc_id` 强绑定, 删除文档时级联清理
- 异步索引任务: 复用 Agent Task Queue (Redis Stream)

5. MongoDB 全文索引

- `knowledge_docs.title` + `knowledge_doc_contents.content` 建立 text index

6. 混合搜索

- Milvus 语义相似度 (top-k)
- MongoDB 全文搜索 (text score)
- 融合排序 (RRF: Reciprocal Rank Fusion)
- 权限过滤: 按用户角色裁剪结果

7. 智能解读

- KB 检索结果 + 上下文注入 → LLM 生成解读
- 分析结果落库

8. 聚合层

- 多维度聚合数据定义: dimensions + metrics
- MongoDB `aggregation_layers` 集合管理

可行性分析

检查项	结论
是否需要新 DB 集合	Yes (knowledge_docs, knowledge_doc_contents, kb_index_tasks, kb_chunks, aggregation_layers)
是否影响现有 API	No
性能影响	Milvus 向量搜索延迟 < 200ms (top-100)
是否需要新增 Skill	Yes (knowledge_search, save_analysis_report)
是否需要 E2E 测试	知识库上传→搜索→结果展示 UI 用例

相关文件

文件	角色	变更幅度
<code>skills/knowledge_search/</code>	混合搜索 Skill	新建
<code>internal/service/knowledge/</code>	知识库服务	新建
<code>github.com/pkoukk/tiktoken-go</code>	Token 计数 (Go 原生, MIT)	新增依赖

验证标准

1. 上传 PDF → 自动解析 → GridFS 存储 → 异步索引 → Milvus 可搜索
2. 删除文档 → kb_chunks 级联清理
3. 混合搜索: 输入自然语言 → 返回 top-5 相关 chunk
4. 智能解读: 分析结果 + KB 上下文 → LLM 生成解读
5. doc_id 隔离: 搜索文档 A 不会返回文档 B 的内容