

企业级数据分析 Agent 系统 — 技术 RFC

版本: v1.1 | 日期: 2026-07-06 | 作者: 罗晓军团队

本文档为技术架构与实现方案，面向开发团队。

目录


- 1. 架构总览
- 2. 技术选型与依赖
- 3. 业务时序图
- 4. 系统分层架构
- 5. 核心模块设计
- 6. Agent 系统设计
- 7. 数据模型设计
- 8. API 设计
- 9. Mock LLM Service (测试用)
- 10. Debug 日志规范
- 11. 安全架构
- 12. 会话与工作区管理
- 13. Artifact 管理 (基于 SeaweedFS)
- 14. 知识库设计
- 15. 审计系统设计
- 16. 异步任务与消息队列
- 17. 部署架构
- 18. 风险与缓解方案
- 19. 分阶段开发任务分解
- 20. AI 辅助开发流程规范
- 21. 团队分工建议
- 22. 附录


1. 架构总览

1.1 系统全景图

 系统架构全景图

系统采用前后端分离的 B/S 架构，后端使用 Go 语言，分为以下核心层：









1.2 核心数据流

数据流对比图

核心架构约定: Agent Service 是系统的中央协调器，统一管理所有用户请求的 Session、模型调用和工具编排。前端用户无论通过 Chat 模式还是 Agent 模式，最终都调用 Agent Service。

Hermes Service 例外: 探索模式下，请求直接转发到 Hermes，不经过 Agent Service。**IM 模块集成在主二进制内**，通过 `internal/service/im/` 封装飞书 Webhook 和消息路由，Chat 消息经 Agent Service 处理，复用 Chat 模式的完整能力。

Chat 模式数据流 (同步即时交互):

```
User Input → API Gateway → Auth/RBAC Check
  → Security Filter (Input Sanitization)
  → Agent Service (Session Manager + ADK Agent Engine)
  → [LLM Router → Model Inference]
  → [Tool Calls via MCP/Skill Registry]
  → [Knowledge Base Search]
  → Agent Response → Security Filter (Output Sanitization)
  → Audit Log → SSE Stream → User
```

- Chat 模式直接调用 Agent Service，走同步路径
- Agent Service 管理 Session 生命周期（创建、上下文维护、超时清理）
- 响应通过 SSE (Server-Sent Events) 流式返回

Agent 模式数据流 (批量任务，支持同步/异步):

```
└─ 同步模式 (立即执行) :
  | User Task → API Gateway → Auth/RBAC Check
  |   → Security Filter → Agent Service
  |   → Agent Engine (ADK) → Plan & Execute Tools
  |   → [Sub-Agent via A2A] → [Script Execution via Worker]
  |   → Results → Store to MongoDB + SeaweedFS → Response
  |
└─ 异步模式 (队列消费) :
```

```

User Task → API Gateway → Auth/RBAC Check
    → Security Filter → Agent Service
    → Enqueue to Redis Stream (立即返回 task_id)
    → Worker consumes from Queue
    → Worker calls Agent Service (复用 Agent Engine)
    → Execute → Results → Store
    → Notification (Email/WS) → User

```

- Agent 模式统一通过 Agent Service 入口
- 同步模式: Agent Service 直接执行, 等待结果返回
- 异步模式: Agent Service 入队后立即返回 task_id, Worker 从 Redis Stream 消费任务后回调 Agent Service 执行
- **Worker 职责:** 从队列消费异步任务后回调 Agent Service 执行核心逻辑。Worker 是纯 Go goroutine, 不涉及 Python/R 等外部运行时

定时任务数据流:

```

Scheduler (Cron 触发时刻) → 创建 ScheduledTask (MongoDB)
    → XADD agent:tasks {type: scheduled}
    → Worker 消费 → 识别为 scheduled → 创建 AgentTask (MongoDB)
    → XADD agent:tasks {type: agent} ← 转换后重入同一条队列
    → Worker 再次消费 → 识别为 agent → 回调 Agent Service
    → Agent Engine Execute → Results → Persist + Notify

```

设计意图: ScheduledTask 不直接执行。Worker 消费后将其转换为标准 AgentTask 并重入同一 `agent:tasks` 队列, 复用 Agent 异步管道的全部执行逻辑和基础设施。Scheduler 和 Agent 异步模式共享 Worker Pool 和 `agent:tasks` 队列。

关键设计要点: – Agent Service 是唯一入口: Chat 和 Agent 两种模式共享同一 Agent Engine 实例 – Session 统一由 Agent Service 管理, Chat 和 Agent 任务的 Session 模型一致 – **Worker 是所有异步路径的统一入口:** 定时任务和异步 Agent 任务都经 Redis Stream → Worker → Agent Service, Worker 不与前端直接交互 – Agent Service 仅处理同步请求 (Chat + Agent 同步模式), 异步路径全部由 Worker 代为调用

2. 技术选型与依赖

2.1 核心技术栈

组件	选型	版本	选型理由
开发语言	Go	1.22+	高性能、并发原生、部署简单
Agent 框架	google.golang.org/adk	latest	Google 官方 Agent 开发套件，生态完善
业务数据库	MongoDB	7.0+	文档模型灵活，统一存储所有业务实体（用户、权限、知识库元数据、Artifact 元数据、分析结果、配置等）
向量数据库	Milvus	2.4+	高性能向量检索，CNCF 项目
记忆系统	Mem0	latest	开源记忆层，支持多粒度记忆管理
会话工作区 & Artifact	SeaweedFS	RELEASE.2024+	S3 兼容对象存储，开源；统一承载 Session 临时文件与 Artifact 持久文件
缓存 & 消息队列	Redis	7.2+	高性能缓存 + Stream 做轻量消息队列
敏感数据管理	HashiCorp Vault	1.18+	集中管理 JWT Secret、DB 密码、API Key、SMTP 密码等敏感配置，支持动态轮转和审计
前端框架	React / Next.js	18 / 14	生态丰富，SSR 支持好
WebSocket	Gorilla WebSocket	1.5+	Go 生态标准 WebSocket 库

2.2 关键开源依赖

组件	开源项目	用途
OpenAPI → MCP 转换	<code>openapi-mcp-server</code> (或自研)	将 OpenAPI 定义转换为 MCP Tool
安全审计	<code>go-audit</code> / <code>audit-go</code>	标准化审计日志库
A2A 协议	ADK 内置 <code>a2a</code> 包	Agent 间通信协议
JWT	<code>golang-jwt/jwt</code>	用户认证 Token
Cron	<code>robfig/cron</code>	定时任务调度
PDF 解析	<code>ledongthuc/pdf</code>	知识库文档解析
Excel 解析	<code>xuri/excelize</code>	表格文档解析
邮件发送	<code>gomail</code> / <code>go-mail</code>	SMTP 邮件
统计计算	<code>gonum</code>	Go 原生统计和数值计算库
飞书 SDK	<code>go-lark/lark</code>	Go 飞书开放平台 SDK，支持消息收发和事件订阅
Token 计数	<code>pkoukk/tiktoken-go</code>	OpenAI 兼容 token 计数 (MIT)，用于上下文窗口压缩阈值判断
结构化日志	<code>uber-go/zap</code>	高性能结构化日志，支持 Debug/Info/Warn/Error 级别
Mock LLM 存储	内嵌 Redis List (无额外依赖)	Mock Service 的 per-key 队列存储 (复用现有 Redis 实例)

2.3 开发工具链

- 版本控制: Git (内部 GitLab/GitHub)
- CI/CD: GitHub Actions / Jenkins
- 容器化: Docker + Docker Compose (开发/测试)
- 容器编排: Kubernetes (生产)
- API 文档: Swagger/OpenAPI 3.0 自动生成
- 代码质量: golangci-lint, SonarQube
- 测试: Go testing + testify + 端到端 Playwright

3. 业务时序图

系统四种核心交互模式的详细时序流程：

3.1 Chat 模式 (同步即时交互)



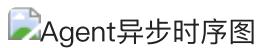
流程: User 发送自然语言 → API Gateway JWT+Rate Limit → Security Input Filter → Agent Service 创建 Session → ADK Agent Engine 推理 → Agent 自主调用 Skills (SQL/Stats/KB) → Security Output Filter + Audit → SSE 流式返回

3.2 Agent 同步模式




流程: User POST `/tasks {mode: sync}` → Gateway Auth → AgentService.CreateAndExecuteSync() → Agent Engine + Skills → 同步返回 Response。请求-响应模式，适用于中等复杂度的实时分析任务。

3.3 Agent 异步模式



流程: User POST `/tasks {mode: async}` → AgentService 保存任务(MongoDB) + XADD agent:tasks → 立即返回 task_id。Worker 从队列消费 → 回调 Agent Service → Agent Engine + Skills → 结果落库 → Email+WS 通知。

3.4 定时任务模式 (Scheduled → Convert → Re-enqueue)




流程: Cron 触发 → Scheduler 创建 ScheduledTask(MongoDB) + XADD agent:tasks {type:scheduled} → Worker Dequeue → **转换为 AgentTask** → XADD agent:tasks {type:agent} (重入队) → Worker 再次 Dequeue → 回调 Agent Service → 复用 Agent 异步管道完成执行和通知。

设计意图: ScheduledTask 不直接执行。Worker 将其转换为标准 AgentTask 并重入同一 `agent:tasks` 队列，实现 Scheduler 和 Agent 异步模式的管道统一。

4. 系统分层架构

部署形态: 整个 Service Layer 编译为单个 Go 二进制文件部署，内部按逻辑分层（Handler → Service → Repository），不做物理微服务拆分。Worker 和 Scheduler 在同一进程中以独立 goroutine 运行，通过 Redis Stream 协调。

3.1 分层设计



请求处理流程 (Handler → Service → Repository):

所有 API 服务严格遵循三层架构，每层职责明确、不可越界：

Request → Handler (入口层) → Service (逻辑层) → Repository (存储层)

- | | | |
|-----------|----------|-----------|
| | | |
| · 参数解析与校验 | · 业务逻辑编排 | · 数据持久化 |
| · 权限前置检查 | · 跨模块协调 | · 缓存操作 |
| · 响应格式化 | · 事务管理 | · 外部API调用 |

入口层 (Handler) 必须完成的校验:

校验项	说明	示例
参数存在性	必填字段非空检查	<code>title</code> 不能为空
参数类型	字段类型匹配	<code>retry_count</code> 必须为整数
参数范围	数值/枚举范围检查	<code>report_type</code> 必须在预置枚举中
参数长度	字符串长度限制	<code>content</code> 不超过 100KB
参数格式	格式合规检查	<code>email</code> 符合邮箱正则
权限校验	当前用户是否有操作权限	RBAC <code>agent:create</code> 权限

Handler 层校验失败直接返回 4xx，不进入 Service 层。校验通过后的参数以 Domain Model 传递到 Service 层。

3.2 Go 项目目录结构

```
.
├── cmd/
│   ├── server/           # 主服务入口 - 单二进制部署
│   │   └── main.go       # 启动 API Server + Worker Pool + Scheduler (goroutines)
│   └── cli/              # 运维 CLI 工具 (migration/seed/admin, 非 Worker)
├── internal/
│   ├── api/              # HTTP Handler 层
│   │   ├── handler/      # 请求处理器 (参数校验 + 响应格式化)
│   │   ├── middleware/   # 中间件
│   │   └── router/        # 路由定义
│   ├── logic/            # ★ Logic 层 (Skill 与 Service 的共用业务逻辑)
│   │   ├── artifact.go   # Artifact 创建/删除 (save_artifact & save_report 共用)
│   │   ├── report.go     # Report CRUD (save_report 与 admin handler 共用)
│   │   └── session.go    # Session 清理 (agent service & cleanup goroutine 共用)
│   ├── service/          # 业务逻辑层 (Agent Service 内部模块)
│   │   ├── chat/         # Chat 模式业务逻辑 (SSE 流式、提示词)
│   │   ├── agent/        # Agent 批量任务模式业务逻辑
│   │   ├── scheduler/
│   │   ├── auth/
│   │   ├── admin/
│   │   └── knowledge/
│   └── domain/           # 领域模型
```

```

|   |   └─ model/          # 数据模型
|   |   └─ agent/          # Agent 引擎
|   |   └─ skill/          # Skill/MCP 注册中心
|   |   └─ audit/          # 审计系统
|   |   └─ security/       # 安全审查
|   └─ worker/             # Agent Worker Pool (goroutine, 非独立进程)
|   |   └─ pool.go         # 1. Worker 池管理 → Redis Stream 消费
|   |   └─ consumer.go     # 2. 异步 Agent 任务消费
|   |   └─ executor.go     # 3. 消费回调 Agent Service (纯 Go)
|   └─ infra/             # 基础设施层
|   |   └─ mongo/          # MongoDB Repository
|   |   └─ milvus/         # Milvus Client
|   |   └─ seaweedfs/      # SeaweedFS Client (S3 compatible)
|   |   └─ redis/          # Redis Client
|   |   └─ mem0/           # Mem0 Client
|   |   └─ email/         # 邮件客户端
|   └─ config/            # 配置管理
└─ pkg/                  # 可复用公共库
|   └─ errcode/           # 错误码
|   └─ jwt/              # JWT 工具
|   └─ logger/           # 日志
└─ skills/               # Skill 定义与实现
|   └─ sql-executor/
|   └─ stats-engine/
|   └─ email-sender/
|   └─ openapi-converter/
└─ configs/              # 配置文件
└─ docs/                 # API 文档
└─ scripts/              # 部署/运维脚本
└─ docker-compose.yml
└─ Makefile

```

4.3 Logic 层 — Skill/Controller/Service 共用逻辑抽取

问题: Skill (Agent 侧的业务入口)、Controller (HTTP API Handler)、Service (内部业务逻辑) 三者之间存在重复逻辑。例如： - `save_artifact` Skill 和 `save_report` Skill 都需要「上传文件到 SeaweedFS + 写入 MongoDB」 - Admin API 的「下载 Report」和 Agent Skill 的「下载 Report」走同一逻辑 - Workspace 清理在 Session 过期回调和 Admin 手动清理中重复

方案: 在 `internal/logic/` 中抽取纯业务函数，供上述三层共同调用：



Logic 层设计原则:

1. **无状态** — Logic 结构体不持有请求级状态，可安全并发调用
2. **接收 SkillContext 或 context.Context** — 不绑定 HTTP 或 Skill 特化上下文
3. **返回 Domain Model** — 不返回 HTTP 响应格式，由上层自行组装
4. **幂等性内置** — MongoDB upsert 在 Logic 层实施，上层无需关心重复调用

```

// internal/logic/artifact.go

type ArtifactLogic struct {
    seaweedfs *seaweedfs.Client
    mongo     *mongo.Collection
}

// CreateArtifact 创建 Artifact (幂等)
// 被 save_artifact Skill 和 save_report Skill 共同调用
func (l *ArtifactLogic) CreateArtifact(ctx context.Context, sc SkillContext, input
CreateArtifactInput) (*ArtifactRecord, error) {
    // 上传 SeaweedFS → MongoDB upsert → 返回记录
}

// DeleteArtifact 删除 Artifact (幂等)
// 被 Artifact GC 和 Admin API 共同调用
func (l *ArtifactLogic) DeleteArtifact(ctx context.Context, artifactID string) error {
  
```

```
// SeaweedFS 删除（不关心文件是否存在）→ MongoDB 标记删除 → 返回 nil（已删除也视为成功）
}
```

4.4 幂等性设计规范

系统中所有资源创建和删除操作必须保证幂等性，支持安全重试。

4.4.1 创建幂等

原则: 相同参数多次调用 `CreateXxx` 不会产生多条记录，不会报错。

实现方式 — MongoDB `$setOnInsert` upsert:

```
// internal/logic/idempotent.go

// IdempotentCreate 通用幂等创建 Helper
// uniqueKey 为唯一索引字段组合（如 {task_id, report_type}）
func IdempotentCreate(ctx context.Context, coll *mongo.Collection, uniqueKey bson.M, doc
any) (created bool, err error) {
    filter := bson.M{}
    for k, v := range uniqueKey {
        filter[k] = v
    }

    // 设置标准时间字段（如果 doc 有这些字段则用 $setOnInsert，已存在则不更新）
    update := bson.M{"$setOnInsert": doc}
    opts := options.Update().SetUpsert(true)

    result, err := coll.UpdateOne(ctx, filter, update, opts)
    if err != nil {
        return false, fmt.Errorf("idempotent_create: %w", err)
    }
    return result.UpsertedCount > 0, nil
}
```

事务回滚模式（跨资源操作，如 report 先创建 artifact 再创建 report）:

```
// Multi-step creation with rollback
func (l *ReportLogic) CreateReport(ctx context.Context, sc SkillContext, input
CreateReportInput) (*Report, error) {
```

```

// 1. 创建 Artifact

artifact, err := l.artifactLogic.CreateArtifact(ctx, sc, CreateArtifactInput{...})
if err != nil {
    return nil, err
}

// 2. 创建 Report

report, created, err := l.createReportRecord(ctx, sc, input, artifact.ID)
if err != nil {
    // ★ 回滚: 删除已创建的 Artifact (best-effort)
    l.artifactLogic.DeleteArtifact(ctx, artifact.ID)
    return nil, fmt.Errorf("create_report: %w", err)
}

// 3. 如果 Report 已存在 (幂等返回), 删除多余 Artifact
if !created {
    l.artifactLogic.DeleteArtifact(ctx, artifact.ID)
}

return report, nil
}

```

4.4.2 删除幂等

原则: 删除一个不存在或已被删除的资源直接返回成功 (HTTP 200 / 无错误), **绝不返回 404**。

```

// 应用层 Delete 模式

func (l *ArtifactLogic) DeleteArtifact(ctx context.Context, artifactID string) error {
    // 1. 标记删除 (MongoDB)
    _, err := l.mongo.UpdateOne(ctx,
        bson.M{"_id": artifactID},
        bson.M{"$set": bson.M{"deleted_at": time.Now()}}),
    )
    if err != nil {
        return fmt.Errorf("delete_artifact: %w", err)
    }
    // ★ MatchedCount = 0 (记录不存在) → 不报错, 直接返回 nil

    // 2. 删除 SeaweedFS 文件 (best-effort, 文件不存在也不报错)
}

```

```
l.seaweedfs.Delete(ctx, artifactID) // 内部吞掉 "not found" 错误

return nil


}
```


幂等删除规则汇总:

操作	资源不存在时行为
DELETE /api/v1/artifacts/:id	返回 {"deleted": true}，不返回 404
DELETE /api/v1/reports/:id	同上
DELETE /api/v1/schedules/:id	同上
DELETE /api/v1/sessions/:id	同上
DELETE /api/v1/knowledge/docs/:id	同上
Workspace 清理 (CleanupExpiredSessions)	目录不存在跳过，不报错
SeaweedFS 文件删除	文件不存在吞掉错误

5. 核心模块设计

4.1 认证与授权模块





RBAC 数据模型 (MongoDB):

```

// roles collection
{
  "_id": "role_analyst",
  "name": "Analyst",
  "description": "数据分析师",
  "permissions": [
    "chat:read", "chat:write",
    "agent:create", "agent:cancel",
    "knowledge:read", "knowledge:search",
    "data:read", "data:analyze",
    "schedule:create", "schedule:manage"
  ],
  "created_at": "2026-07-01T00:00:00Z",
  "updated_at": "2026-07-01T00:00:00Z"
}

// users collection
{
  "_id": "user_001",
  "username": "zhangsan",
  "password_hash": "$2a$10$...",
  "display_name": "张三",
  "email": "zhangsan@company.com",
  "roles": ["role_analyst", "role_viewer"],
  "status": "active", // active | disabled
  "last_login_at": "2026-07-01T08:30:00Z",
  "created_at": "2026-07-01T00:00:00Z"
}

```

权限校验流程:

```

Request → JWT Verify → Extract User + Roles
        → RBAC Engine.Check(user, resource, action)

```

```
→ [Pass] → Handler  
→ [Deny] → 403 + Audit Log
```

4.2 Agent 服务 — Chat 模式

说明: Chat 模式是 Agent Service 的同步交互模式，**不是独立服务**。前端通过 `/api/chat` 端点发送请求 → Gateway → Auth/RBAC → Agent Service (同一组件) → ADK Agent Engine → SSE 流式返回。与 §4.3 的 Agent 批量任务模式共享同一个 Agent Service 实例和 Session Manager。

功能: – 即时对话式查询和分析 – 快捷提示词管理 – 多轮对话上下文维护 (Session 统一管理) – SSE 流式返回响应 – 结果缓存 (Redis, 相同查询 5 分钟内直接返回)

请求流程:

```
POST /api/v1/chat/message  
  
→ Auth Middleware (JWT + RBAC)  
→ Security Filter (Input Sanitization)  
→ AgentService.HandleChatMessage() // ★ 同一组件  
→ SessionManager.GetOrCreate()  
→ ADK Agent Engine.Run() // LLM 推理 + Tool 调用  
→ Security Filter (Output PII)  
→ Audit Log  
→ SSE Stream: data: {"type":"content","text":"..."}
```

Chat Session 模型:

```
{  
  "_id": "session_chat_001",  
  "user_id": "user_001",  
  "type": "chat",  
  "messages": [  
    {  
      "role": "user",  
      "content": "昨天华东区销售额?",  
      "timestamp": "2026-07-01T09:00:00Z"  
    },  
    {  
      "role": "assistant",  
      "content": "...",  
    }  
  ]  
}
```

```

        "tool_calls": [...],
        "timestamp": "2026-07-01T09:00:02Z"
    }
],
"context": {
    "data_sources": ["sales_db"],
    "preferences": {}
},
"workspace_id": "ws_chat_001",
"created_at": "2026-07-01T09:00:00Z",
"last_active_at": "2026-07-01T09:05:00Z",
"expires_at": "2026-07-01T09:35:00Z" // 30 min inactivity
}

```

快捷提示词模型:

```

{
    "_id": "prompt_001",
    "category": "sales",
    "text": "本月销售额TOP10产品",
    "roles": ["viewer", "analyst"],
    "sort_order": 1,
    "is_system": true,
    "created_by": "system"
}

```

4.2.1 上下文窗口管理

LLM 上下文窗口有限（通常 128K tokens），多轮对话 + 知识库检索 + 长报告生成容易超出限制。采用 **tiktoken-go + LLM 摘要** 三层策略，无需引入额外 Python 服务。

1. 对话摘要压缩（tiktoken-go 计数 + 轻量模型摘要）

压缩阈值由当前使用的模型配置 `max_context_tokens` 动态决定，而非硬编码：

```

import "github.com/pkoukk/tiktoken-go"

type ContextCompressor struct {
    tke *tiktoken.Tiktoken
    // 摘要模型：轻量低成本（GPT-4o-mini / Claude 3.5 Haiku）
    SummaryModel string
}

```

```

}

// Compress 根据当前模型配置决定是否需要压缩
// modelCfg 从 MongoDB model_configs 查询, 含 max_context_tokens
func (c *ContextCompressor) Compress(messages []Message, modelCfg *ModelConfig) ([]Message,
error) {
    // 阈值 = 模型上下文窗口 × 50% (预留给 system prompt、工具结果、LLM 输出)
    threshold := modelCfg.MaxContextTokens / 2

    // tiktoken-go 精确计数
    tokens := 0
    for _, msg := range messages {
        tokens += len(c.tke.Encode(msg.Content, nil, nil))
    }
    if tokens <= threshold {
        return messages, nil
    }

    // 保留最近 4 轮对话原文 (约 2K-4K tokens)
    recent := messages[len(messages)-4:]
    older := messages[:len(messages)-4]

    // 轻量模型生成摘要 (~100 tokens, 成本约 ¥0.001/次)
    summary := c.llmRouter.Chat(ctx, &ChatRequest{
        Model:      c.SummaryModel,
        Messages: append(older, Message{Role: "user", Content: "请用200字以内总结以上对话的关键信息和结论"}),
    })

    return append([]Message{{Role: "system", Content: "历史对话摘要:\n" + summary}},
recent...), nil
}

```

阈值计算: $\text{threshold} = \text{max_context_tokens} \times 50\%$, 例如 GPT-4o (128K) → 64K, GPT-4o-mini (128K) → 64K, Claude 3.5 Sonnet (200K) → 100K。剩余 50% 预留给 system prompt、知识库检索结果、工具输出和 LLM 回复。

2. 知识库结果截断 – 向量搜索结果按相似度排序，取 top-5 条 – 每条 chunk 截断至 800 tokens（用 tiktoken-go 精确计算） – $5 \times 800 = 4000$ tokens 上限

3. 长报告分段生成合并

```
// 报告预计长度超过阈值时，分段生成后合并
func (c *ReportBuilder) BuildLongReport(prompt string, estimatedTokens int) (string, error)
{
    if estimatedTokens <= c.MaxOutputTokens {
        return c.llm.Generate(prompt) // 单次生成
    }
    // 分段生成
    sections := c.splitPromptBySections(prompt)
    var parts []string
    for _, section := range sections {
        part := c.llm.Generate(section)
        parts = append(parts, part)
    }
    return strings.Join(parts, "\n\n"), nil
}
```

4.3 Agent 服务 — Agent 模式（批量任务）

定位: 与 §4.2 Chat 模式共享同一个 `AgentService` 组件。区别在于：Chat 是同步即时交互，Agent 模式支持同步/异步两种执行路径。Agent Service 是系统唯一的中央协调器。

功能: – 统一入口：Chat 实时对话和 Agent 批量任务均通过 Agent Service – Session 生命周期管理（创建、上下文维护、超时清理） – Chat 模式：接收用户消息，调用 ADK Agent Engine 进行同步推理，SSE 流式返回 – Agent 模式 — 同步：直接执行 Agent Engine，等待结果后返回 – Agent 模式 — 异步：将任务入队 Redis Stream，立即返回 task_id；由 Worker 消费后回调 Agent Service 执行 – 任务状态跟踪与进度上报 – 任务取消（Goroutine context cancel） – 子 Agent 编排（A2A） – 结果持久化和通知

Agent 任务模型:

```
{
  "_id": "task_001",
  "user_id": "user_001",
  "type": "batch_analysis", // batch_analysis | scheduled | sub_agent
  "status": "running", // pending | queued | running | completed | failed | cancelled
  "input": {
```

```

    "query": "对过去3年销售数据做回归分析和预测",
    "data_sources": ["sales_db"],
    "analysis_types": ["regression", "time_series"],
    "parameters": {}
  },
  "progress": {
    "percentage": 45,
    "current_step": "执行回归分析中...",
    "steps": [
      {"name": "数据提取", "status": "completed", "duration_ms": 5200},
      {"name": "数据清洗", "status": "completed", "duration_ms": 3100},
      {"name": "回归分析", "status": "running", "duration_ms": null},
      {"name": "结果解读", "status": "pending", "duration_ms": null}
    ]
  },
  "result": null,
  "error": null,
  "sub_agents": ["task_002", "task_003"],
  "parent_task_id": null,
  "workspace_id": "ws_agent_001",
  "created_at": "2026-07-01T09:00:00Z",
  "started_at": "2026-07-01T09:00:05Z",
  "completed_at": null,
  "cancellable": true
}

```

任务取消机制:

```

// 基于 context 的优雅取消
type AgentTask struct {
    ctx    context.Context
    cancel context.CancelFunc

    // ...
}

func (s *AgentService) CancelTask(taskID string) error {
    task := s.getTask(taskID)

    if task.Status != "running" {
        return ErrTaskNotRunning
    }
}

```

```

    }

    task.cancel() // 触发 context cancellation
    // Agent Engine 中所有 goroutine 检查 ctx.Done()

    task.Status = "cancelled"

    s.saveTask(task)

    return nil
}

```

4.4 定时任务服务 (Scheduler Service)

调度方式: Scheduler 不直接调用 Agent Service。Cron 触发时，创建任务记录 (MongoDB) 并写入 Redis Stream，由 Worker 统一消费后回调 Agent Service 执行。这与异步 Agent 模式走同一条路径，保持架构一致性。

调度器设计:

```

type SchedulerService struct {
    cron      *cron.Cron
    repo      *SchedulerRepo
    redisStream *RedisStreamClient // 写入 Redis Stream, 不直接调 AgentSvc
}

type ScheduledTask struct {
    ID          string    `bson:"_id"`
    UserID      string    `bson:"user_id"`
    Name        string    `bson:"name"`
    CronExpr    string    `bson:"cron_expr"` // "0 8 * * *"
    AgentInput  AgentInput `bson:"agent_input"`
    Status      string    `bson:"status"` // active | paused | deleted
    LastRunAt   *time.Time `bson:"last_run_at"`
    LastStatus  string    `bson:"last_status"`
    RetryCount  int        `bson:"retry_count"` // 最大重试次数
    ValidFrom   *time.Time `bson:"valid_from"`
    ValidUntil  *time.Time `bson:"valid_until"`
    CreatedAt   time.Time `bson:"created_at"`
}

// onCronTrigger: Cron 到达触发时刻

```

```

func (s *SchedulerService) onCronTrigger(task ScheduledTask) {

    // 1. 创建任务执行记录 (MongoDB)

    execID := s.repo.CreateExecution(task)

    // 2. 写入 Redis Stream (与异步 Agent 任务共用队列)

    msg := map[string]interface{}{

        "task_id":    execID,

        "task_type":  "scheduled",

        "user_id":    task.UserID,

        "agent_input": task.AgentInput,

    }

    s.redisStream.XAdd(ctx, "agent:tasks", msg)

    // Worker 消费后:

    // 1. Dequeue → 识别 type=scheduled

    // 2. 创建 AgentTask (MongoDB) → XADD agent:tasks {type:agent}

    // 3. Worker 再次 Dequeue → 识别 type=agent

    // 4. 调用 AgentService.ExecuteTask() → 结果落库 + 通知

}

```

Worker 分流处理逻辑:

```

// Worker processTask - 根据 task_type 分流

func (w *AgentWorker) processTask(ctx context.Context, taskID string) {

    msg := w.loadMessage(taskID)

    switch msg.TaskType {

    case "scheduled":

        // == ScheduledTask: 转换 → 重入队 ==

        sched := w.loadScheduledTask(msg.ScheduledTaskID)

        // 创建 AgentTask (复用用户手动创建任务的同构模型)

        agentTask := &AgentTask{

            UserID:    sched.UserID,

            Query:      sched.AgentInput.Query,

            Mode:       "async",

            Source:     "scheduled",           // 标记来源

            SourceID:  sched.ID,

            CreatedAt: time.Now(),

        }
    }
}

```



```

    }

    w.mongo.CreateAgentTask(agentTask)

    // 重入同一条队列 (type=agent)
    w.redis.XAdd("agent:tasks", map[string]string{
        "task_type": "agent",
        "agent_task_id": agentTask.ID,
    })

case "agent":
    // === AgentTask: 标准异步执行 ===
    task := w.mongo.GetAgentTask(msg.AgentTaskID)

    taskCtx, cancel := context.WithCancel(ctx)
    defer cancel()

    w.updateStatus(task.ID, "running")
    result, err := w.agentSvc.ExecuteTask(taskCtx, task)
    if err != nil {
        w.updateStatus(task.ID, "failed")
        w.notifier.Notify(task.UserID, task.ID, err)
        return
    }
    w.saveResult(task.ID, result)
    w.updateStatus(task.ID, "completed")
    w.notifier.Notify(task.UserID, task.ID, nil)
}
}

```

4.5 管理后台服务 (Admin Service)

功能模块:

```

Admin Service
├── Dashboard Handler
│   ├── Agent Stats (调用量/成功率/耗时分布)
│   ├── Business Stats (分析指标聚合)
│   └── System Health (CPU/Mem/QPS)
└── User Management

```

```

|   ├── CRUD Users
|   ├── Role Assignment
|   └── Account Status (enable/disable)
└── Permission Management
    ├── Role CRUD
    └── Permission Mapping
└── Model Configuration
    ├── Model Selection
    ├── Context Length Limit
    └── Temperature/Top-P Settings
└── Task Management
    ├── Task List (running/history)
    ├── Cancel Task
    └── Retry Failed Task
└── Knowledge Base Management
    ├── Document Upload/Delete
    ├── Index Status Tracking
    └── Permission Settings
└── Audit Log Viewer
    ├── Filter by Time/User/Action
    └── Export Logs

```

4.6 报告格式校验 Skill (`save_analysis_report`)

功能: Agent 通过调用 `save_analysis_report` Skill 保存分析报告。Skill 在保存前自动校验报告格式，校验通过才执行保存；不通过时返回缺失项反馈，由 Agent 自行修正后重新调用。

设计原则: 报告校验不属于审计/安全层，而是 Agent 工具调用链中的一个环节。Agent 自主决定何时保存、是否重试、何时放弃。

调用流程:

```

Agent generates report content
|
▼
Agent calls save_analysis_report(report_type, content)
|
▼

```



```

        return "校验并保存分析报告。先创建 Artifact 上传到 SeaweedFS, 再创建 Report 记录引用 Artifact。
        校验不通过时返回缺失项供 Agent 修正。"
    }

func (s *SaveReportSkill) Parameters() json.RawMessage {
    return toJSONSchema(map[string]any{
        "type": "object",
        "properties": map[string]any{
            "report_type": map[string]any{
                "type": "string",
                "enum": []string{
                    "financial_analysis", "sales_analysis",
                    "general_analysis", "weekly_report", "user_behavior",
                },
                "description": "报告类型",
            },
            "title":      map[string]any{"type": "string", "description": "报告标题"},
            "content":     map[string]any{"type": "string", "description": "报告全文 (Markdown
            格式)"},
            "task_id":     map[string]any{"type": "string", "description": "关联的Agent任务
            ID"},
            "retry_count": map[string]any{"type": "integer", "description": "当前重试次数 (0-
            based)"},
        },
        "required": []string{"report_type", "title", "content"},
    })
}

func (s *SaveReportSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    reportType := params["report_type"].(string)
    content     := params["content"].(string)
    title       := params["title"].(string)
    retryCount  := getInt(params, "retry_count")

    // Step 1: 格式校验
    result := s.validator.Validate(reportType, content)
    s.audit.LogValidation(ctx, AuditValidationLog{
        TaskID: sc.TaskID, ReportType: reportType,

```

```

        Passed: result.Passed, RetryCount: retryCount,
        Failures: result.Failures, Action: "validate",
    })
    if !result.Passed {
        maxRetries := s.validator.MaxRetries(reportType)
        return map[string]any{
            "saved": false, "retry_count": retryCount + 1,
            "max_retries": maxRetries, "feedback": result.FeedbackMsg, "failures":
result.Failures,
        }, nil
    }

    // Step 2: 创建 Artifact (共用 ArtifactLogic, 幂等 upsert)
    artifact, err := s.artifactLogic.CreateArtifact(ctx, sc, logic.CreateArtifactInput{
        Name:      fmt.Sprintf("%s.md", title),
        Content:    []byte(content),
        MimeType:   "text/markdown",
    })
    if err != nil {
        return nil, fmt.Errorf("save_report: create artifact failed: %w", err)
    }

    // Step 3: 创建 Report - 幂等写入 (task_id + report_type 唯一)
    report := &AnalysisReport{
        ID:          id.New("rpt"),
        UserID:      sc.UserID,
        SessionID:   sc.SessionID,
        TaskID:      sc.TaskID,
        ReportType:  reportType,
        Title:       title,
        Content:     content,
        ArtifactID:  artifact.ID,      // ← 引用 Artifact
        CreatedAt:   time.Now(),
        UpdatedAt:   time.Now(),
    }

    filter := bson.M{"task_id": sc.TaskID, "report_type": reportType}
    update := bson.M{"$setOnInsert": report}
    opts := options.Update().SetUpsert(true)

```

```

result, err := s.mongo.UpdateOne(ctx, "analysis_reports", filter, update, opts)

if err != nil {
    s.artifactLogic.DeleteArtifact(ctx, artifact.ID) // best-effort rollback
    return nil, fmt.Errorf("save_report: db upsert failed: %w", err)
}

s.audit.LogValidation(ctx, AuditValidationLog{TaskID: sc.TaskID, ReportType:
reportType, Passed: true, Action: "saved"})

return map[string]any{
    "saved":      true,
    "report_id":  report.ID,
    "artifact_id": artifact.ID,
    "is_new":     result.UpsertedCount > 0,
}, nil
}

```

Agent 使用示例 (Agent 自行管理重试循环):

```

Agent decides to save report → calls save_analysis_report
├─ [FAIL] Skill returns feedback with missing sections
│   Agent reads feedback, revises report
│   Agent calls save_analysis_report again (retry_count=1)
│   ...
│   Up to max_retries (configured in report_rules)
│   If still failing after max_retries:
│       Agent annotates report with warnings and saves as draft
└─ [PASS] Skill saves to MongoDB, returns result_id
        Agent proceeds to next step

```

规则配置 (保持不变, 存储在 MongoDB `report_rules` 集合):

```

{
  "_id": "rule_financial_analysis",
  "report_type": "financial_analysis",
  "description": "财务分析报告格式规范",
  "max_retries": 3,
  "enabled": true,
  "rules": [
    {

```

```

    "name": "has_summary",
    "type": "section_required",
    "match_mode": "md_ast",
    "sections": ["摘要", "执行摘要"],
    "min_level": 2,
    "feedback": "请补充「摘要」章节，概述本次分析的核心发现"
  },
  {
    "name": "has_data_source",
    "type": "section_required",
    "match_mode": "md_ast",
    "sections": ["数据来源", "数据说明"],
    "min_level": 2,
    "feedback": "请补充「数据来源」章节，说明分析所使用的数据范围和时间"
  },
  {
    "name": "has_methodology",
    "type": "section_required",
    "match_mode": "md_ast",
    "sections": ["分析方法"],
    "min_level": 2,
    "feedback": "请补充「分析方法」章节，说明采用的统计方法及其选择理由"
  },
  {
    "name": "has_key_metrics",
    "type": "section_required",
    "match_mode": "md_ast",
    "sections": ["关键指标", "核心指标"],
    "min_level": 2,
    "feedback": "请补充「关键指标」章节，列出核心财务指标及其变化"
  },
  {
    "name": "has_comparison",
    "type": "element_required",
    "match_mode": "md_ast",
    "sections": [],
    "min_level": 0,
    "keywords": ["同比", "环比", "对比", "较上"],
    "feedback": "请补充同比/环比对比数据，说明各项指标的变化趋势"
  }

```

```
    },
    {
      "name": "has_conclusion",
      "type": "section_required",
      "match_mode": "md_ast",
      "sections": ["结论", "总结", "建议"],
      "min_level": 2,
      "feedback": "请补充「结论与建议」章节，给出分析结论和可操作的建议"
    },
    {
      "name": "min_word_count",
      "type": "format_constraint",
      "threshold": 200,
      "unit": "characters",
      "feedback": "报告内容过短（少于200字），请丰富分析内容和数据支撑"
    }
  ]
}
```

预置报告类型与规则:

报告类型	关联分析类型	必需章节	最小字数	最大重试
financial_analysis	财务分析	摘要、数据来源、分析方法、关键指标、同比环比、结论	200	3
sales_analysis	销售分析	摘要、时间范围、核心指标、趋势分析、TOP/N、结论	150	3
general_analysis	SQL统计、高级分析	摘要、数据描述、分析过程、关键发现、结论	100	3
weekly_report	经营周报	本周概览、核心指标达成率、异常标注、对比上周、下周关注	200	3
user_behavior	用户分析	摘要、数据范围、用户分层、关键行为指标、洞察建议	150	3

与审计/安全层的关系: save_analysis_report Skill 的校验逻辑独立于安全审查中间件。安全审查层仅负责输入/输出的敏感内容和越权检查（Section 8.1），不介入报告格式校验。报告格式的合规性由 Skill 在保存时自主保证。

4.7 SQL 执行器 (含 AST 语法树解析)

功能: SQL Executor Skill 负责将 Agent 生成的 SQL 语句安全地执行到企业数据源。核心安全机制：在 SQL 执行前通过 AST 语法树解析，识别并拒绝所有写入/修改类操作。

4.7.1 AST 解析流程



4.7.2 AST 节点白名单策略

采用白名单 + 黑名单双重策略:

允许的操作 (白名单): | 操作类型 | SQL 语句 | AST Node Type | |-----|-----|-----|
 ----|| 数据查询 | `SELECT` | `*ast.SelectStmt` || 公共表达式 | `WITH ... AS` | `*ast.With` || 子查询 |
 subquery | `*ast.SubqueryExpr` || 表连接 | `JOIN` | `*ast.Join` || 集合操作 | `UNION`, `INTERSECT`,
`EXCEPT` | `*ast.SetOprStmt` || 聚合函数 | `GROUP BY`, `HAVING` | embedded in `SelectStmt` || 排序分页 |
`ORDER BY`, `LIMIT`, `OFFSET` | embedded in `SelectStmt` || 数据描述 | `DESCRIBE`, `SHOW`, `EXPLAIN` |
`*ast.ShowStmt` / `*ast.ExplainStmt` |

禁止的操作 (黑名单 — 立即拒绝): | 操作类型 | SQL 语句 | AST Node Type | 严重级别 | |-----|-----|
 -----|-----|-----|:---:| | 数据插入 | `INSERT` | `*ast.InsertStmt` | HIGH || 数据更新 |
`UPDATE` | `*ast.UpdateStmt` | CRITICAL || 数据删除 | `DELETE` | `*ast.DeleteStmt` | CRITICAL || 表结
 构 变 更 | `DROP`, `ALTER`, `TRUNCATE`, `RENAME` | `*ast.DropStmt`, `*ast.AlterTableStmt`,
`*ast.TruncateStmt`, `*ast.RenameTableStmt` | CRITICAL || 数据库操作 | `CREATE DATABASE`, `DROP`
`DATABASE` | `*ast.CreateDatabaseStmt`, `*ast.DropDatabaseStmt` | CRITICAL || 表 创 建 | `CREATE`
`TABLE` | `*ast.CreateTableStmt` | HIGH || 索 引 操 作 | `CREATE INDEX`, `DROP INDEX` |
`*ast.CreateIndexStmt`, `*ast.DropIndexStmt` | HIGH || 权 限 操 作 | `GRANT`, `REVOKE` |
`*ast.GrantStmt`, `*ast.RevokeStmt` | CRITICAL || 事 务 控 制 | `BEGIN`, `COMMIT`, `ROLLBACK` |
`*ast.BeginStmt`, `*ast.CommitStmt` | HIGH || 变 量 赋 值 | `SET @var = ...` | `*ast.SetStmt` |
MEDIUM || 存 储 过 程 | `CALL`, `EXEC` | `*ast.CallStmt` | HIGH || 数 据 加 载 | `LOAD DATA` |
`*ast.LoadDataStmt` | CRITICAL || 表 锁 操 作 | `LOCK TABLES`, `UNLOCK TABLES` |
`*ast.LockTablesStmt`, `*ast.UnlockTablesStmt` | HIGH |

4.7.3 核心实现

```
// SQL Executor Skill — 包含 AST 安全校验
type SQLExecutorSkill struct {
    dbConn    *sql.DB           // 只读连接的数据库
    audit     *AuditService
    security  *SecurityService
}

// SQLParseResult 保存解析结果
type SQLParseResult struct {
    SQL        string           // 原始 SQL
    Parsed     bool            // 是否成功解析
```

```

    ASTType      string          // AST 根节点类型

    DBOperation  string          // 数据库操作类型: SELECT | INSERT | UPDATE | ...

    IsReadOnly   bool            // 是否只读操作

    Forbidden    bool            // 是否被禁止

    Violations   []Violation     // 违规详情

    Tables       []string        // 涉及的表名
}

type Violation struct {
    Rule      string // 触发的规则名称
    NodeType  string // 违规的 AST 节点类型
    Severity  string // LOW | MEDIUM | HIGH | CRITICAL
    Message   string // 违规说明
}

// ParseAndValidate 是 SQL Executor 的入口
func (s *SQLExecutorSkill) ParseAndValidate(ctx context.Context, sql string)
(*SQLParseResult, error) {
    // Step 1: 基础正则预检 (快速拦截明显攻击)
    if s.hasDangerousPatterns(sql) {
        return nil, ErrDangerousSQL
    }

    // Step 2: AST 语法树解析
    // 使用 pingcap/tidb/parser (兼容 MySQL) 或 xwb1989/sqlparser
    stmts, err := s.parser.Parse(sql)
    if err != nil {
        // 解析失败 - 拒绝执行
        s.audit.LogSQLRejection(ctx, sql, "PARSE_ERROR", err.Error())
        return nil, fmt.Errorf("SQL 语法解析失败: %w", err)
    }

    // Step 3: AST 遍历 - 检测禁止操作
    result := &SQLParseResult{SQL: sql, Parsed: true}
    for _, stmt := range stmts {
        violations := s.walkASTForForbidden(stmt)
        result.Violations = append(result.Violations, violations...)

        switch stmt.(type) {

```

```

        case *ast.SelectStmt:
            result.ASTType = "SELECT"
            result.IsReadOnly = true
        case *ast.InsertStmt:
            result.ASTType = "INSERT"
            result.Forbidden = true
        case *ast.UpdateStmt:
            result.ASTType = "UPDATE"
            result.Forbidden = true
        case *ast.DeleteStmt:
            result.ASTType = "DELETE"
            result.Forbidden = true
        case *ast.DropStmt:
            result.ASTType = "DROP"
            result.Forbidden = true
        // ... 其他禁止类型
    }
}

// Step 4: 拒绝写入/修改操作
if result.Forbidden {
    s.audit.LogSQLRejection(ctx, sql, result.ASTType, "WRITE_OPERATION_BLOCKED")
    s.security.Alert(ctx, SecurityAlert{
        Type:      "SQL_WRITE_BLOCKED",
        Severity: "CRITICAL",
        SQL:       sql,
        ASTType:   result.ASTType,
    })
    return result, fmt.Errorf("禁止的 SQL 操作类型: %s。仅允许 SELECT/DESCRIBE/SHOW/EXPLAIN 等只读操作", result.ASTType)
}

return result, nil
}

// walkASTForForbidden 递归遍历 AST 树查找禁止的节点类型
func (s *SQLExecutorSkill) walkASTForForbidden(node ast.Node) []Violation {
    var violations []Violation
    if node == nil { return nil }

```

```
// 黑名单检查
switch n := node.(type) {
case *ast.InsertStmt:
    violations = append(violations, Violation{
        Rule: "no_write", NodeType: "INSERT", Severity: "HIGH",
        Message: "不允许 INSERT 操作",
    })
case *ast.UpdateStmt:
    violations = append(violations, Violation{
        Rule: "no_write", NodeType: "UPDATE", Severity: "CRITICAL",
        Message: "不允许 UPDATE 操作",
    })
case *ast.DeleteStmt:
    violations = append(violations, Violation{
        Rule: "no_write", NodeType: "DELETE", Severity: "CRITICAL",
        Message: "不允许 DELETE 操作",
    })
case *ast.DropStmt:
    violations = append(violations, Violation{
        Rule: "no_ddl", NodeType: "DROP", Severity: "CRITICAL",
        Message: "不允许 DROP 操作",
    })
case *ast.TruncateStmt:
    violations = append(violations, Violation{
        Rule: "no_ddl", NodeType: "TRUNCATE", Severity: "CRITICAL",
        Message: "不允许 TRUNCATE 操作",
    })
case *ast.AlterTableStmt:
    violations = append(violations, Violation{
        Rule: "no_ddl", NodeType: "ALTER TABLE", Severity: "CRITICAL",
        Message: "不允许 ALTER TABLE 操作",
    })
case *ast.CreateTableStmt:
    violations = append(violations, Violation{
        Rule: "no_ddl", NodeType: "CREATE TABLE", Severity: "HIGH",
        Message: "不允许 CREATE TABLE 操作",
    })
case *ast.SetStmt:
```

```

        violations = append(violations, Violation{
            Rule: "no_variable", NodeType: "SET", Severity: "MEDIUM",
            Message: "不允许 SET 变量操作",
        })
    // ... 更多禁止节点类型
default:
    // 允许的节点类型, 不做处理
}

// 递归检查子节点
node.Accept(func(child ast.Node) error {
    if child != node {
        violations = append(violations, s.walkASTForbidden(child)...)
    }
    return nil
})

return violations
}

// hasDangerousPatterns 快速正则预检
func (s *SQLExecutorSkill) hasDangerousPatterns(sql string) bool {
    patterns := []string{
        `(?(i)\bDROP\s+(TABLE|DATABASE|INDEX|VIEW)\b`,
        `(?(i)\bTRUNCATE\s+(TABLE\s+)?`,
        `(?(i)\bALTER\s+(TABLE|DATABASE)\b`,
        `(?(i);\s*(INSERT|UPDATE|DELETE|DROP|ALTER|TRUNCATE)`, // 换行注入
        `(?(i)'\s*OR\s*'1'='1`, // SQL 注入
        `(?(i)\bUNION\s+SELECT\b.*\bFROM\b`, // UNION 注入 (仅在一个 SQL 中
        出现非预期的 UNION SELECT)
    }
    for _, p := range patterns {
        if matched, _ := regexp.MatchString(p, sql); matched {
            return true
        }
    }
    return false
}

```

```
// Execute 仅当 SQL 通过 AST 校验后才执行
func (s *SQLExecutorSkill) Execute(ctx context.Context, params map[string]any) (any, error)
{
    sql := params["sql"].(string)

    // AST 解析 + 安全校验
    result, err := s.ParseAndValidate(ctx, sql)
    if err != nil {
        return nil, err
    }

    // 执行只读 SQL
    rows, err := s.dbConn.QueryContext(ctx, sql)
    if err != nil {
        s.audit.LogSQLExecution(ctx, sql, "ERROR", err.Error())
        return nil, err
    }
    defer rows.Close()

    // 序列化结果
    data := s.serializeRows(rows)

    s.audit.LogSQLExecution(ctx, sql, "SUCCESS", fmt.Sprintf("%d rows", len(data)))
    return data, nil
}
```


4.7.4 推荐 AST 解析库

库	适用场景	优势
<code>github.com/pingcap/tidb/parser</code>	MySQL 兼容	TiDB 出品，生产级品质，支持 MySQL 5.7/8.0 语法
<code>github.com/xwb1989/sqlparser</code>	通用 SQL	轻量级，Google Vitess 分支，支持 MySQL 语法
<code>github.com/auxten/postgresql-parser</code>	PostgreSQL	CockroachDB 出品，支持 PostgreSQL 语法
<code>github.com/dolthub/go-mysql-server</code>	MySQL 兼容	完整的 MySQL 语法支持，包含分析引擎

MVP 选型: `pingcap/tidb/parser` — MySQL 兼容性好，AST 节点类型完备，经过大规模生产验证。

6. Agent 系统设计

5.1 ADK Agent 引擎架构





5.2 Agent 系统提示词设计

<agent_system_prompt>
你是企业数据分析助手，具备以下能力：

****核心能力**：**

1. 数据查询与分析：通过 SQL 执行器查询企业数据库，进行统计分析
2. 高级分析：回归分析、聚类分析、主成分分析、时间序列预测
3. 财务分析：财务比率计算、同比环比分析、预算偏差分析
4. 结果解读：结合企业知识库和行业数据，对分析结果进行深度解读

****工具使用规则**：**

- SQL 查询前必须先确认数据源和表结构
- 涉及多表关联查询时，先验证关联条件是否正确
- 分析结果必须通过 `save\_analysis\_report` Skill 落库保存（该 Skill 会自动校验报告格式合规性）
- 若 `save\_analysis\_report` 返回校验失败，根据反馈逐一修正报告后重新调用，直到通过或达到重试上限
- 生成的图表、数据文件等产出物通过 `save\_artifact` Skill 保存为 Artifact
- 查询用户敏感数据前需要额外确认

****安全规则**：**

- ****SQL 执行器自动拦截写入操作****：系统通过 AST 语法树解析，自动识别并拒绝 INSERT/UPDATE/DELETE/DROP/ALTER/TRUNCATE 等 DML 和 DDL 语句。Agent 无需手动判断，SQL Executor Skill 在执行前完成安全校验
- 不得查询其他用户的数据（除非有授权）
- 不得将内部数据通过邮件发送到外部邮箱
- 分析结果中的敏感信息需要脱敏处理

****交互规则**：**

- 复杂分析任务建议使用异步模式，避免等待
- 提供清晰的分析步骤说明
- 结果以结构化方式呈现（表格、图表描述）
- 对于不确定的分析结论，标注置信度

****限制**：**

- 不对外透露系统内部实现细节
- 不执行未授权的 API 调用
- 不修改系统配置

****报告格式要求**：**

- 生成分析报告时，必须按照系统指定的报告类型模板组织内容
- 财务分析报告必须包含：摘要、数据来源与范围、分析方法、关键财务指标、同比/环比数据、结论与建议
- 销售分析报告必须包含：摘要、时间范围、核心指标、趋势分析、TOP/N分析、结论
- 通用分析报告必须包含：摘要、数据描述、分析过程、关键发现、结论

- 若系统反馈格式校验不通过，根据反馈信息逐一修正缺失的章节/要素后重新生成

</agent_system_prompt>

5.3 Skill/MCP 插件机制

Skill 注册接口:

```
// Skill 定义
type Skill interface {
    Name() string
    Description() string
    Parameters() json.RawMessage // JSON Schema
    Execute(ctx context.Context, params map[string]any) (any, error)
    Permissions() []string        // 所需权限
    RateLimit() *RateLimit        // 频率限制
}

// Skill 注册中心
type SkillRegistry struct {
    skills map[string]Skill
    mu      sync.RWMutex
}

func (r *SkillRegistry) Register(s Skill) error {
    r.mu.Lock()
    defer r.mu.Unlock()
    if _, exists := r.skills[s.Name()]; exists {
        return fmt.Errorf("skill %s already registered", s.Name())
    }
    r.skills[s.Name()] = s
    return nil
}

func (r *SkillRegistry) GetAdkTools() []adk.Tool {
    // 将所有 Skill 转换为 ADK Tool 格式
    // 自动生成 Function Declaration
}
```

Skill 目录结构:

```
skills/
├─ sql-executor/
│   ├── skill.go          # Skill 实现
│   ├── config.yaml       # Skill 配置 (MCP 连接信息等)
│   └─ SKILL.md           # Skill 说明文档
├─ stats-engine/
│   ├── skill.go
│   ├── regression.go     # 回归分析
│   ├── clustering.go     # 聚类分析
│   ├── pca.go            # 主成分分析
│   ├── time_series.go    # 时间序列
│   └─ config.yaml
├─ email-sender/
│   ├── skill.go
│   └─ config.yaml
├─ openapi-converter/
│   ├── skill.go
│   └─ config.yaml
├─ knowledge-search/
│   ├── skill.go
│   └─ config.yaml
├─ save-analysis-report/
│   ├── skill.go
│   └─ config.yaml
├─ save-artifact/
│   ├── skill.go
│   └─ config.yaml
└─ security-audit/
    ├── skill.go
    └─ config.yaml
└─ workspace-read/
    ├── skill.go
    └─ config.yaml
└─ workspace-write/
    ├── skill.go
    └─ config.yaml
└─ workspace-exec/
```

```
├─ skill.go
└─ config.yaml
```

Skill 自动加载:

```
// 启动时自动扫描 skills/ 目录

func (r *SkillRegistry) AutoLoad(skillsDir string) error {
    entries, _ := os.ReadDir(skillsDir)
    for _, entry := range entries {
        if !entry.IsDir() { continue }
        skillPath := filepath.Join(skillsDir, entry.Name())
        skill, err := LoadSkill(skillPath) // 读取 config.yaml + 初始化
        if err != nil {
            log.Warnf("Failed to load skill %s: %v", entry.Name(), err)
            continue
        }
        r.Register(skill)
        log.Infof("Skill loaded: %s", skill.Name())
    }
    return nil
}
```

5.4 Skill 与 Session 绑定机制

设计目标： Skill 执行时必须自动继承当前 Session 上下文，无需 Agent 或 Caller 手动传递 `session_id`。确保 workspace 操作、Artifact 产出、报告保存**强制关联**当前 Session，杜绝跨 Session 操作和数据归属混乱。

5.4.1 SkillContext — 注入式 Session 上下文

```
// internal/skill/context.go

// SkillContext 封装 Skill 执行的运行时上下文
// 由 Agent Engine 在执行 Skill 前自动注入，禁止 Skill 自行修改

type SkillContext struct {
    SessionID string    `json:"session_id"` // 当前 Session ID (自动注入)
    UserID     string    `json:"user_id"`    // 当前用户 ID
    TaskID     string    `json:"task_id"`    // 当前任务 ID (可选, Agent 模式)
    TraceID    string    `json:"trace_id"`   // 请求追踪 ID
}
```

```

Role      string    `json:"role"`      // 用户角色（用于权限校验）

// 私有字段，仅 framework 可访问

workspaceRoot string // /workspaces/<session_id>/

}

```

5.4.2 升级后的 Skill 接口

```

// Skill（升级版）- Execute 第一个参数强制为 SkillContext
type Skill interface {
    Name() string
    Description() string
    Parameters() json.RawMessage

    // 核心变更: SkillContext 替代零散的 session_id/user_id 参数
    Execute(ctx context.Context, sc SkillContext, params map[string]any) (any, error)

    Permissions() []string
    RateLimit() *RateLimit
}

```

Agent Engine 注入流程:

```

// internal/agent/engine.go

func (e *AgentEngine) invokeSkill(ctx context.Context, toolCall adk.ToolCall) (any, error) {
    skill := e.registry.Get(toolCall.Name)

    // 自动构建 SkillContext（从 gin.Context / Agent 运行时提取）
    sc := SkillContext{
        SessionID:    e.currentSession.ID,      // 自动注入
        UserID:       e.currentSession.UserID,
        TaskID:       e.currentTask.ID,         // Agent 模式有值, Chat 模式为空
        TraceID:      e.traceID,               // 从 X-Trace-Id header 继承
        Role:         e.currentUser.Role,
        workspaceRoot: e.workspaceManager.Root(e.currentSession.ID),
    }
}

```

```
logger.Debug("[AgentEngine] invoking skill",
    zap.String("component", "agent_engine"),
    zap.String("trace_id", sc.TraceID),
    zap.String("session_id", sc.SessionID),
    zap.String("skill_name", toolCall.Name),
)

return skill.Execute(ctx, sc, toolCall.Arguments)
}
```

5.4.3 Session 绑定强制规则

Skill	绑定规则	实现方式
<code>workspace_read</code>	路径强制限定 <code>/workspaces/<sc.SessionID>/</code>	<code>resolveSafePath</code> 使用 <code>sc.SessionID</code> ，不接受外部传入
<code>workspace_write</code>	同上	同上
<code>workspace_exec</code>	同上 + 环境变量 <code>HOME</code> / <code>TMPDIR</code> 限定	同上
<code>save_artifact</code>	<code>artifact.session_id</code> 自动设为 <code>sc.SessionID</code>	MongoDB <code>session_id</code> 字段由 framework 填入，Skill 无法覆盖
<code>save_analysis_report</code>	<code>report.session_id</code> 自动设为 <code>sc.SessionID</code>	同上
<code>sql_executor</code>	记录 SQL 日志时自动关联 <code>sc.SessionID</code> + <code>sc.TaskID</code>	审计字段自动注入

关键约束：

1. Skill 不得接受外部 `session_id` 参数 — 由 SkillContext 注入，Skill 实现中不暴露 `session_id` 给 LLM/Agent 填值。
2. 数据归属强制写入 — `save_artifact` 和 `save_analysis_report` 的 MongoDB 文档中，`session_id` 字段由 Skill framework 在 Execute 内部设置，Skill 代码传入的 `params["session_id"]` 被忽略。
3. 跨 Session 操作拒绝 — workspace Skill 的 `resolveSafePath` 以 `sc.SessionID` 为锚，即使 Skill 代码内部尝试访问其他 session 目录，也会被路径沙箱拦截。

5.4.4 改造示例：save_artifact

```
// internal/skill/save_artifact.go

type SaveArtifactSkill struct {
    logic *logic.ArtifactLogic // ← 共用 Logic 层, 内部封装 SeaweedFS + MongoDB 操作
}

type ArtifactRecord struct {
    ID            string    `bson:"_id"`
    TaskID        string    `bson:"task_id"`
    SessionID     string    `bson:"session_id"` // ← 由 framework 注入, Skill 不可覆盖
    UserID        string    `bson:"user_id"`    // ← 同上
    Name          string    `bson:"name"`
    MimeType      string    `bson:"mime_type"`  // ← 替代 type 字段 (由文件内容推断)
    SizeBytes     int64     `bson:"size_bytes"`
    StoragePath   string    `bson:"storage_path"`
    Persistent    bool      `bson:"persistent"`
    CreatedAt     time.Time `bson:"created_at"`
    UpdatedAt     time.Time `bson:"updated_at"`
}

func (s *SaveArtifactSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    name, _ := params["name"].(string)
    content, _ := params["content"].([]byte)
    mimeType, _ := params["mime_type"].(string)

    // 通过 Logic 层幂等创建 (共用 save_report 底层逻辑)
    artifact, err := s.logic.CreateArtifact(ctx, sc, logic.CreateArtifactInput{
        Name:      name,
        Content:   content,
        MimeType:  mimeType,
    })
    if err != nil {
        return nil, fmt.Errorf("save_artifact: %w", err)
    }

    logger.Info("[SaveArtifact] created",
```



```

        zap.String("component", "skill"),
        zap.String("session_id", sc.SessionID),
        zap.String("artifact_id", artifact.ID),
    )

    return map[string]any{"artifact_id": artifact.ID, "path": artifact.StoragePath}, nil
}

```

5.4.5 改造示例：save_analysis_report

```

func (s *SaveReportSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    reportType, _ := params["report_type"].(string)
    content, _ := params["content"].(string)

    // 格式校验
    validation := s.validator.Validate(reportType, content)
    if !validation.Passed {
        return map[string]any{"status": "validation_failed", "errors": validation.Errors,
"retry": true}, nil
    }

    // 通过 Logic 层创建 Artifact + Report (幂等, 失败时自动回滚)
    report, err := s.reportLogic.CreateReport(ctx, sc, logic.CreateReportInput{
        ReportType: reportType,
        Content:     content,
    })
    if err != nil {
        return nil, err
    }

    return map[string]any{"status": "saved", "report_id": report.ID, "artifact_id":
report.ArtifactID}, nil
}

```

5.4.6 约束总览



5.5 OpenAPI → MCP 转换器

转换流程:

```

OpenAPI Spec (JSON/YAML)
  → Parse via kin-openapi
  → Extract: endpoints, methods, parameters, schemas
  → Generate MCP Tool Definition:
    - Tool Name: operationId
    - Tool Description: summary/description
    - Parameters: JSON Schema from OpenAPI schema
  → Create Dynamic Skill (内存中)
  → Submit for Admin Review
  → [Approved] → Register to SkillRegistry
  → [Rejected] → Delete from pending list

```

核心实现:

```

type OpenAPIConverter struct {
    parser    *openapi3.Loader
    registry *SkillRegistry
}

type PendingAPIConversion struct {
    ID            string    `bson:"_id"`
    SpecContent string    `bson:"spec_content"`
    Tools         []ToolDef `bson:"tools"`
    SubmittedBy  string    `bson:"submitted_by"`
    ReviewedBy   string    `bson:"reviewed_by"`
    Status       string    `bson:"status"` // pending | approved | rejected
    CreatedAt    time.Time `bson:"created_at"`
}

func (c *OpenAPIConverter) Convert(specContent []byte) ([]ToolDef, error) {
    doc, _ := openapi3.NewLoader().LoadFromData(specContent)
    var tools []ToolDef
    for path, pathItem := range doc.Paths.Map() {
        for method, op := range pathItem.Operations() {
            tool := ToolDef{
                Name:      op.OperationID,

```

```
        Description: op.Summary,
        Method:      method,
        Path:        path,
        Parameters:  buildJSONSchema(op.Parameters),
        BaseURL:     doc.Servers[0].URL,
    }
    tools = append(tools, tool)
}
}
return tools, nil
}
```

7. 数据模型设计

7.0 数据表统一规范

所有 MongoDB Collection 遵循以下字段约定：

标准字段

字段	类型	必填	说明
<code>_id</code>	<code>string</code> (UUID v4)	✓	主键，36 字符 UUID，由应用层生成（非 MongoDB ObjectId）
<code>user_id</code>	<code>string</code>	视情况	数据归属用户 ID，记录/审计类表必须
<code>session_id</code>	<code>string</code>	视情况	数据归属 Session ID，Session 生命周期内的操作产物必须
<code>task_id</code>	<code>string</code>	视情况	关联 Agent 任务 ID，异步任务产物必须
<code>created_at</code>	<code>ISODate</code>	✓	创建时间，服务端写入
<code>updated_at</code>	<code>ISODate</code>	✓	最后更新时间，每次修改自动更新
<code>deleted_at</code>	<code>ISODate</code>	✗	软删除时间， <code>null</code> 表示未删除（仅需要软删除的表使用）

UUID 主键生成

```
// internal/pkg/id/id.go

package id

import "github.com/google/uuid"

// 前缀可读类型 + UUID v4
func New(prefix string) string {
    return prefix + "_" + uuid.New().String()
}

// 示例: id.New("task") → "task_3f7a2b1c-..."
//       id.New("rpt")  → "rpt_a1b2c3d4-..."
```

索引设计原则

1. 按查询 case 建索引 — 先梳理实际查询场景，再建对应索引，避免"先建再说"。
2. 唯一索引优先 — 天然唯一的字段（如 `order_no`、`email`）用唯一索引防脏数据。
3. 复合索引覆盖查询 — 常见查询条件组建成复合索引，避免多个单字段索引重复。
4. ESR 规则 — 复合索引字段顺序：Equality → Sort → Range。
5. 避免功能重复索引 — `{a:1, b:1}` 已覆盖仅按 `a` 查询的场景，无需额外建 `{a:1}`。
6. TTL 索引清理临时数据 — Session、临时 Artifact 等用 TTL 索引自动清理。
7. 索引数量控制在 5 个以内 — 每表索引数不超过 5 个，写入性能与查询性能平衡。

7.1 MongoDB 集合设计（完整字段）

MongoDB 作为业务主存储：所有业务实体数据统一存储在 MongoDB 中。SeaweedFS 仅存储二进制大文件（Session 临时文件、Artifact 文件内容），Milvus 仅存储向量索引，Redis 仅做缓存和消息队列。

Collection	用途	关键字段	索引
users	用户信息	_id, username, password_hash, roles[], status, created_at, updated_at	{username:1} unique, {status:1}
roles	角色定义	_id, name, permissions[], created_at	{name:1} unique
sessions	用户会话	_id, user_id, type, expires_at, workspace_id, created_at, updated_at	{user_id:1, created_at:-1}, {expires_at:1} TTL
chat_messages	对话消息	_id, session_id, user_id, role, content, created_at	{session_id:1, created_at:1}
agent_tasks	Agent 任务	_id, user_id, session_id, status, input, progress, result, created_at, updated_at	{user_id:1, created_at:-1}, {status:1, created_at:1}
scheduled_tasks	定时任务	_id, user_id, cron_expr, agent_input, status, created_at, updated_at	{status:1}, {user_id:1}
analysis_reports	分析报告	_id, user_id, session_id, task_id, report_type, title, content, artifact_id, created_at, updated_at	{task_id:1}, {session_id:1, created_at:-1}, {user_id:1, created_at:-1}
aggregation_layers	聚合层数据	_id, name, dimensions[], metrics[], source, data, created_at, updated_at	{name:1} unique
knowledge_docs	知识库文档元数据	_id, user_id, title, type, tags[], permissions, versions[], created_at, updated_at	{user_id:1, created_at:-1}, {tags:1}
knowledge_doc_contents	知识库文档内容	_id, doc_id, version, gridfs_file_id, filename, size_bytes, created_at	{doc_id:1, version:-1}

Collection	用途	关键字段	索引
	(GridFS 引用)		
<code>prompts</code>	快捷提示词	<code>_id</code> , <code>category</code> , <code>text</code> , <code>roles[]</code> , <code>sort_order</code> , <code>created_at</code>	<code>{category:1, sort_order:1}</code>
<code>audit_logs</code>	审计日志	<code>_id</code> , <code>user_id</code> , <code>session_id</code> , <code>action</code> , <code>ip</code> , <code>detail</code> , <code>created_at</code>	<code>{user_id:1, created_at:-1}</code> , <code>{created_at:-1}</code>
<code>security_alerts</code>	安全告警	<code>_id</code> , <code>type</code> , <code>user_id</code> , <code>content</code> , <code>rule</code> , <code>created_at</code>	<code>{created_at:-1}</code> , <code>{type:1, created_at:-1}</code>
<code>pending_api_conversions</code>	API 转换审核	<code>_id</code> , <code>user_id</code> , <code>spec_content</code> , <code>tools[]</code> , <code>status</code> , <code>created_at</code> , <code>updated_at</code>	<code>{status:1}</code> , <code>{user_id:1}</code>
<code>model_configs</code>	模型配置	<code>_id</code> , <code>provider</code> , <code>base_url</code> , <code>api_key_vault_id</code> , <code>model_name</code> , <code>temperature</code> , <code>top_p</code> , <code>max_context_tokens</code> , <code>max_output_tokens</code> , <code>is_active</code> , <code>created_at</code> , <code>updated_at</code>	<code>{is_active:1}</code>
<code>vault_secrets</code>	Vault 加密密钥	<code>_id</code> , <code>key_type</code> , <code>encrypted_value</code> , <code>created_by</code> , <code>created_at</code> , <code>updated_at</code>	<code>{key_type:1}</code>
<code>skill_configs</code>	Skill 配置	<code>_id</code> , <code>skill_name</code> , <code>config_yaml</code> , <code>enabled</code> , <code>rate_limit</code> , <code>created_at</code> , <code>updated_at</code>	<code>{skill_name:1}</code> unique
<code>report_rules</code>	报告格式校验规则	<code>_id</code> , <code>report_type</code> , <code>max_retries</code> , <code>enabled</code> , <code>rules[]</code> , <code>created_at</code> , <code>updated_at</code>	<code>{report_type:1}</code> unique

Collection	用途	关键字段	索引
<code>report_validation_logs</code>	报告校验 审计日志	<code>_id</code> , <code>task_id</code> , <code>report_type</code> , <code>result</code> , <code>retry_attempt</code> , <code>failures[]</code> , <code>action</code> , <code>created_at</code>	<code>{task_id:1}</code> , <code>{created_at:-1}</code>
<code>artifacts</code>	Artifact 元数据	<code>_id</code> , <code>user_id</code> , <code>session_id</code> , <code>task_id</code> , <code>name</code> , <code>mime_type</code> , <code>size_bytes</code> , <code>storage_path</code> , <code>persistent</code> , <code>created_at</code> , <code>updated_at</code>	<code>{task_id:1}</code> , <code>{session_id:1}</code> , <code>created_at:-1}</code> , <code>{persistent:1}</code> , <code>created_at:-1}</code>
<code>token_consumptions</code>	Token 消 耗记录	<code>_id</code> , <code>session_id</code> , <code>task_id</code> , <code>model_name</code> , <code>input_tokens</code> , <code>output_tokens</code> , <code>cost_cents</code> , <code>created_at</code>	<code>{created_at:-1}</code> , <code>{model_name:1}</code> , <code>created_at:-1}</code>
<code>output_stats</code>	产出统计 (聚合)	<code>_id</code> , <code>date</code> , <code>report_count</code> , <code>chart_count</code> , <code>download_count</code> , <code>export_count</code> , <code>created_at</code> , <code>updated_at</code>	<code>{date:1}</code> unique
<code>roi_metrics</code>	ROI 指标 (聚合)	<code>_id</code> , <code>date</code> , <code>total_cost_cents</code> , <code>total_tasks</code> , <code>equivalent_man_hours_saved</code> , <code>created_at</code>	<code>{date:1}</code> unique
<code>kb_index_tasks</code>	知识库索 引任务	<code>_id</code> , <code>doc_id</code> , <code>status</code> , <code>chunk_count</code> , <code>model_name</code> , <code>created_at</code> , <code>updated_at</code>	<code>{doc_id:1}</code> , <code>created_at:-1}</code> , <code>{status:1}</code>
<code>kb_chunks</code>	知识库文 档分片	<code>_id</code> , <code>doc_id</code> , <code>index_task_id</code> , <code>chunk_index</code> , <code>content</code> , <code>embedding</code> , <code>created_at</code>	<code>{doc_id:1}</code> , <code>chunk_index:1}</code> , <code>{embedding:</code> <code>\ "vector\ "}</code>
<code>prompt_enhancements</code>	增强提示 词记录 (无状 态, 仅记 录)	<code>_id</code> , <code>original_text</code> , <code>enhanced_texts[]</code> , <code>model_name</code> , <code>created_at</code>	<code>{created_at:-1}</code>

Collection	用途	关键字段	索引
<code>im_bindings</code>	IM 用户绑定（飞书 open_id ↔ user_id）	<code>_id</code> , <code>platform</code> , <code>open_id</code> , <code>user_id</code> , <code>tenant_key</code> , <code>nickname</code> , <code>avatar_url</code> , <code>created_at</code> , <code>updated_at</code>	<code>{platform:1, open_id:1, tenant_key:1}</code> unique, <code>{user_id:1}</code>
<code>im_bind_tokens</code>	一次性绑定 Token	<code>_id</code> , <code>platform</code> , <code>open_id</code> , <code>tenant_key</code> , <code>expires_at</code> , <code>created_at</code>	<code>{expires_at:1}</code> TTL
<code>im_templates</code>	IM 消息模板 (V1.1)	<code>_id</code> , <code>platform</code> , <code>template_type</code> , <code>name</code> , <code>content</code> , <code>created_at</code> , <code>updated_at</code>	<code>{platform:1, template_type:1}</code>

关键设计变更: 1. `kb_index_tasks` 使用 Agent 任务框架异步执行（复用 `agent_tasks` 架构），索引完成后更新 `knowledge_docs.index_status` 2. `kb_chunks.embedding` 由当前配置的 LLM 模型生成（非专用 embedding 模型），通过向量索引实现语义检索 3. `kb_chunks.doc_id` 与 `knowledge_docs._id` 强绑定，查询时按 `doc_id` 隔离，避免跨文档串数据 4. `prompt_enhancements` 为无状态记录表，不关联 `session_id` 或 `user_id`，仅用于增强结果缓存和日志审计 5. **KB 文档统一使用 GridFS 存储:** 所有知识库文档上传后存 MongoDB GridFS（无需区分大小，GridFS 自动分片 255KB chunk），`gridfs_file_id` 关联 `knowledge_doc_contents`。索引任务和详情页均通过 `GridFSDownloadStream`（实现 `io.ReadSeeker`）流式读取，不占内存。小文件（<16MB）同样走 GridFS，避免两套路径。

7.2 分析报告数据模型（analysis_reports）

报告独立建表，通过 `artifact_id` 单向引用 `artifacts`，不反向在 `artifacts` 表加 `type` 字段：

```
// analysis_reports collection
{
  "_id": "rpt_alb2c3d4-e5f6-7890-abcd-ef1234567890",
  "user_id": "user_001",
  "session_id": "session_abcl23",
  "task_id": "task_001",
  "report_type": "financial_analysis",
  "title": "2026 Q2 财务分析报告",
```

```

"content": "# 2026 Q2 财务分析报告\n\n# 概述\n...",
"artifact_id": "art_xly2z3-...",
"metadata": {
  "data_sources": ["enterprise_demo.orders", "enterprise_demo.products"],
  "time_range": {"start": "2026-04-01", "end": "2026-06-30"},
  "validation_retries": 1
},
"created_at": "2026-07-01T10:30:00Z",
"updated_at": "2026-07-01T10:30:00Z"
}

```

```

// artifacts collection (对应报告的那个 artifact 记录)
{
  "_id": "art_xly2z3-w4v5-6789-abcd-ef1234567890",
  "user_id": "user_001",
  "session_id": "session_abc123",
  "task_id": "task_001",
  "name": "2026 Q2 财务分析报告.md",
  "mime_type": "text/markdown",
  "size_bytes": 15200,
  "storage_path": "artifacts/task_001/art_xly2z3_report.md",
  "persistent": false,
  "created_at": "2026-07-01T10:30:00Z",
  "updated_at": "2026-07-01T10:30:00Z"
}

```

设计说明： `artifact.type` 字段已移除。判断一个 artifact 是否为“报告”，通过查询 `analysis_reports` 表中是否存在 `artifact_id` 引用即可。Artifact 表保持通用性，不承载业务语义字段。

Report 下载流程 — 复用 Artifact 下载：

```

GET /api/v1/reports/:report_id/download
→ 查询 analysis_reports 获取 artifact_id
→ 查询 artifacts 获取 storage_path
→ SeaweedFS presigned URL → 302 重定向
→ 与 GET /api/v1/artifacts/:id/download 共用同一底层实现

```

6.3 聚合层数据模型

```
// aggregation_layers collection
{
  "_id": "agg_sales_by_region_product",
  "name": "按地区和产品线的销售聚合",
  "dimensions": ["region", "product_line"],
  "metrics": [
    {"name": "total_revenue", "agg_func": "sum", "field": "revenue"},
    {"name": "avg_price", "agg_func": "avg", "field": "unit_price"},
    {"name": "order_count", "agg_func": "count", "field": "order_id"}
  ],
  "source": {
    "type": "raw", // raw | aggregation_layer
    "data_source": "sales_db.orders",
    "parent_agg_id": null // 如果基于其他聚合层, 此处填写父层ID
  },
  "data": [
    {"region": "华东", "product_line": "电子产品", "total_revenue": 5000000, ...},
    ...
  ],
  "refresh_schedule": "0 2 * * *", // 每日凌晨2点刷新
  "created_at": "2026-07-01T00:00:00Z",
  "updated_at": "2026-07-01T02:00:00Z",
  "created_by": "user_001"
}
```

6.4 Milvus 向量集合设计

Collection	用途	向量维度	元数据字段
knowledge_chunks	知识库文档 分块向量	1536 (OpenAI) / 768 (其他)	doc_id, chunk_index, title, tags[], permissions[]
analysis_history	历史分析结果 向量	1536	task_id, user_id, analysis_type, result_id
query_cache	查询语义缓存	1536	query_hash, result_id, hit_count, last_hit_at

8. API 设计

7.1 API 路由结构

Base URL: /api/v1

认证

POST	/auth/login	# 登录
POST	/auth/logout	# 登出
POST	/auth/refresh	# 刷新 Token
GET	/auth/me	# 当前用户信息

Chat

POST	/chat/query	# 发送消息（支持 SSE 流式）
GET	/chat/sessions	# 我的会话列表（历史，按时间倒序）
GET	/chat/sessions/:id	# 会话详情（含历史消息）
DELETE	/chat/sessions/:id	# 删除会话
PUT	/chat/sessions/:id/archive	# 归档会话
GET	/chat/sessions/search	# 搜索历史会话（?q=xxx）
GET	/chat/prompts	# 获取快捷提示词

Prompt Enhancement（无状态，不依赖 Session）

POST	/enhance	# 增强提示词（请求体：{text, context?}）
------	----------	-------------------------------

返回：{original, enhanced: [{text, reason}]}, 不创建 session_id

Agent

POST	/agent/tasks	# 创建 Agent 任务
GET	/agent/tasks	# 任务列表（?page=&limit=&sort=&status=） - 支持分页/排序/筛选
GET	/agent/tasks/:id	# 任务详情（含进度 + Artifact 列表）
POST	/agent/tasks/:id/cancel	# 取消任务
GET	/agent/tasks/:id/result	# 任务结果

Scheduler

POST	/schedules	# 创建定时任务
GET	/schedules	# 定时任务列表
PUT	/schedules/:id	# 更新
DELETE	/schedules/:id	# 删除

```

POST    /schedules/:id/pause    # 暂停
POST    /schedules/:id/resume   # 恢复

# Analysis Results → Reports
GET     /reports                # 报告列表 (?task_id=xxx&report_type=xxx)
GET     /reports/:id           # 报告详情
GET     /reports/:id/download   # 下载报告 (复用 Artifact 下载链路)

# Aggregation
POST    /aggregations          # 创建聚合定义
GET     /aggregations          # 聚合列表
GET     /aggregations/:id      # 聚合详情
DELETE  /aggregations/:id      # 删除聚合
POST    /aggregations/:id/refresh # 手动刷新

# Knowledge Base
POST    /knowledge/docs/batch   # 批量上传 (multipart/form-data, 多个文件)
POST    /knowledge/docs         # 上传单个文档
GET     /knowledge/docs         # 文档列表 (?page=&limit=&sort=&filter=) - 支持分页/排序/筛选
GET     /knowledge/docs/:id     # 文档详情
DELETE  /knowledge/docs/:id     # 删除 (含级联清理 kb_chunks)
GET     /knowledge/search       # 搜索 (?q=xxx&type=semantic|fulltext)
GET     /knowledge/docs/:id/index-status # 索引状态 (pending/indexing/done/failed)

# Admin (需要 Admin 角色)
GET     /admin/dashboard/stats  # 看板统计 (调用量/成功率/耗时/Token/产出/ROI)
GET     /admin/dashboard/token-stat # Token 消耗统计 (按模型/日期聚合)
GET     /admin/dashboard/output-stat # 产出统计 (报告/图表/下载/导出)
GET     /admin/dashboard/roi    # AI Agent ROI 指标
POST    /admin/users            # 创建用户
GET     /admin/users            # 用户列表
PUT     /admin/users/:id        # 更新用户
DELETE  /admin/users/:id        # 删除用户
POST    /admin/roles            # 创建角色
PUT     /admin/roles/:id        # 更新角色
PUT     /admin/models           # 模型配置
GET     /admin/models           # 模型配置列表
GET     /admin/audit-logs       # 审计日志
GET     /admin/security-alerts  # 安全告警

```

```
# API Conversion (需要 Knowledge Admin)
POST    /admin/api-convert/batch # 批量上传 OpenAPI 文件
POST    /admin/api-convert      # 上传单个 OpenAPI
GET     /admin/api-convert      # 转换列表 (?page=&limit=&status=)
POST    /admin/api-convert/:id/approve # 审核通过
POST    /admin/api-convert/:id/reject  # 审核拒绝

# Vault (管理密钥)
POST    /vault/secrets          # 保存密钥 (加密存储)
GET     /vault/secrets/:id/reveal # 解密查看 (需二次验证)
DELETE  /vault/secrets/:id      # 删除密钥

# Artifact (Task Detail)
POST    /tasks/:id/artifacts/download # 批量打包下载 (ZIP)
```

7.3 消息渲染格式规范 (Message Render Schema)

Chat 模式下 AI 回复可能包含多种内容类型，前端需根据 `message\_type` 字段选择对应的渲染组件：

`message_type`	渲染组件	说明
`markdown`	Markdown 渲染器	标准自然语言文本，支持加粗/斜体/列表/链接
`tool_call`	工具调用卡片 (折叠)	显示工具图标、名称、执行耗时、输入参数摘要、输出结果
`sql_query`	SQL 代码卡片	语法高亮渲染，带「复制」和「查看执行计划」按钮
`data_table`	数据表格渲染器	斑马纹表格，支持轻量级排序和「导出 CSV」按钮
`chart`	内嵌图表渲染器	直接渲染图表，含放大/下载/引用工具栏
`progress`	进度指示器	旋转动画 + 状态文本 (查询中.../计算中.../索引中...)

7.4 知识库 LLM 索引流水线 (KB Indexing Pipeline)

知识库文档索引不依赖专用向量化模型，复用当前配置的 LLM 完成分片和 Embedding：

上传文档 → 保存文件 → 创建索引 Agent 任务(异步) ↓ LLM 分析语义段落边界 → 拆分 Chunks (≤2000 tokens) ↓ 每个 Chunk → LLM 生成 Embedding 向量 ↓ 写入 kb_chunks (doc_id 强绑定) + Milvus ↓ 更新 knowledge_docs.index_status = indexed

关键约束：`kb\_chunks.doc\_id` 与知识库文档 ID 强绑定，删除文档时级联清理，Semantic Search 按 `doc\_id` 隔离避免串数据。

```
# Mock LLM Service (仅 dev/test 环境, 需要 Admin 角色)
POST    /mock/v1/chat/completions      # OpenAI-compatible Chat Completions (支持
stream=true SSE)
POST    /mock/v1/chat/completions/stream # 同上 (显式 stream 路径, 便于测试)
POST    /mock/responses                # 向队列写入预设 mock 响应 (管理接口)
DELETE  /mock/responses/:key           # 清空指定 key 的队列
GET     /mock/responses/:key           # 查看指定 key 队列内容 (不消耗)
GET     /mock/responses                # 列出所有 mock key 及队列长度
DELETE  /mock/responses                # 清空所有 mock 数据
```

7.2 关键 API 示例

Chat 查询 (SSE 流式) :

```
// Request: POST /api/v1/chat/query
{
  "session_id": "session_chat_001", // 可选, 不传则创建新会话
  "message": "昨天华东区销售额多少?",
  "stream": true
}

// Response (SSE):
data: {"type": "thinking", "content": "正在分析查询意图..."}
data: {"type": "tool_call", "tool": "sql_executor", "status": "running"}
data: {"type": "tool_result", "tool": "sql_executor", "result": {...}}
data: {"type": "text", "content": "昨天华东区销售额为 1,250 万元..."}
data: {"type": "done"}
```

Agent 任务创建:

```
// Request: POST /api/v1/agent/tasks
{
  "query": "对过去3年全部销售数据做完整的回归分析和预测",
  "data_sources": ["sales_db"],
  "analysis_types": ["regression", "time_series"],
  "mode": "async", // sync | async
  "notification": {
    "email": true,
```

```
    "in_app": true
  }
}

// Response:
{
  "task_id": "task_001",
  "status": "queued",
  "estimated_duration": "约 2-5 分钟",
  "ws_channel": "/ws/tasks/task_001"  // 实时进度 WebSocket
}
```

9. Mock LLM Service（测试用）

9.1 设计目标

Mock Service 在开发 / 测试环境中完整替代真实 LLM（OpenAI / Azure / Anthropic 等），解决以下问题：

问题	Mock Service 解法
真实 LLM 调用费用高	全部请求由本地 Mock 响应，零成本
网络不稳定导致测试抖动	离线运行，延迟可控
测试需要精确控制返回内容	预先向队列注入期望响应
Agent 流程复杂，难以复现特定路径	可构造任意 LLM 输出驱动 Agent 走指定分支

仅在 `APP_ENV=development` 或 `APP_ENV=test` 时挂载 Mock 路由，生产环境自动禁用。

9.2 匹配策略：上下文末尾消息 + Redis List 队列

匹配键（Lookup Key）生成

当 Mock Service 收到 `POST /mock/v1/chat/completions` 请求时：

- 取请求体 `messages[]` 数组的最后一条消息（`messages[len-1]`）。

2. 取其 `content` 字段（字符串或 content parts 拼接），做 **SHA-256** 哈希，截取前 16 字节的 hex → `lookupKey`。
3. 以 `mock:resp:<lookupKey>` 为 Redis List Key 执行 **LPOP**。
4. 如果队列为空 → fallback 到通配符 key `mock:resp:*` 做 **LPOP**（按插入时间最早的队列）。
5. 如果仍然没有数据 → 返回内置默认响应（可配置）。

```
messages[last].content → SHA256 → hex[:16] → "mock:resp:<hex>"
```

↓
Redis LPOP

↓
└ 有数据 → 返回该 mock 响应

└ 无数据 → LPOP "mock:resp:*"

↓
└ 有数据 → 返回

└ 无数据 → 内置默认响应

设计说明： – 使用 List（队列）而非 String，同一 key 可以预置**多轮**不同响应，模拟连续对话或重试场景。 – **LPOP** 消耗式读取，保证每次调用消费一条；测试后队列自然清空。 – 通配符 fallback 让“不关心内容匹配”的测试只需注入一条通用响应。

9.3 接口规范

9.3.1 Chat Completions (OpenAI-compatible)

```
POST /mock/v1/chat/completions
```

```
Content-Type: application/json
```

```
Authorization: Bearer <any-string> # Mock 不校验 key, 仅验证 Bearer 格式
```

```
Request Body (完全兼容 OpenAI Chat Completions v1) :
```

```
{
  "model": "gpt-4o",           // 忽略, Mock 不区分模型
  "messages": [
    {"role": "system", "content": "You are a helpful assistant."},
    {"role": "user", "content": "请分析上季度销售数据"} // ← 匹配此条
  ],
  "stream": true | false,
  "temperature": 0.7,         // 忽略
}
```

```
"max_tokens": 2000          // 忽略  
}
```

非流式响应 (`stream: false`):

```
{  
  "id": "chatcmpl-mock-<uuid>",  
  "object": "chat.completion",  
  "created": 1720000000,  
  "model": "mock-llm",  
  "choices": [{  
    "index": 0,  
    "message": {  
      "role": "assistant",  
      "content": "<预置内容或默认响应>"  
    },  
    "finish_reason": "stop"  
  }],  
  "usage": {  
    "prompt_tokens": 0,  
    "completion_tokens": 0,  
    "total_tokens": 0  
  }  
}
```

流式响应 (`stream: true` , SSE 格式):

```
Content-Type: text/event-stream  
Cache-Control: no-cache  
  
data: {"id":"chatcmpl-mock-xxx","object":"chat.completion.chunk","choices":[{"delta":  
{"role":"assistant"},"index":0}]}  
  
data: {"id":"chatcmpl-mock-xxx","object":"chat.completion.chunk","choices":[{"delta":  
{"content":"上季度"},"index":0}]}  
  
data: {"id":"chatcmpl-mock-xxx","object":"chat.completion.chunk","choices":[{"delta":  
{"content":"销售额总计..."},"index":0}]}  
  
data: {"id":"chatcmpl-mock-xxx","object":"chat.completion.chunk","choices":[{"delta":
```

```
{}, "index": 0, "finish_reason": "stop"]]}

data: [DONE]
```

预置 mock 内容时若包含 `\n` 分隔的多行，Mock Service 自动按行拆分为多个 SSE chunk，模拟真实流式输出；每个 chunk 之间插入 `5ms` 延迟（可通过 `MOCK_CHUNK_DELAY_MS` 环境变量覆盖）。

9.3.2 Mock 数据管理接口（Admin 专用）

写入预设响应

```
POST /mock/responses

Authorization: Bearer <admin-token>
Content-Type: application/json

{
  "match": "请分析上季度销售数据",    // 原始字符串（服务端计算 SHA-256 key）
  "response": "上季度总销售额 1.25 亿元，同比增长 12.3%，...",
  "stream_chunks": null,              // 可选：显式指定 SSE 分块列表（覆盖自动拆行）
  "ttl_seconds": 3600                  // 可选，0 = 永不过期
}

Response:
{
  "key": "mock:resp:alb2c3d4e5f6a7b8",
  "queue_length": 1,
  "match_preview": "请分析上季度销售数据"
}
```

批量写入（同一个 match 对应多轮响应）：

```
POST /mock/responses

{
  "match": "请分析上季度销售数据",
  "responses": [                      // 使用 responses（复数）即可写入多条
    "第一次回答：...",
    "第二次回答：..."
  ]
}
```

查看队列（不消耗）

```
GET /mock/responses/:key

// key 为 SHA-256 hex[:16], 或直接传原始文本（服务端转换）

Response:

{
  "key": "mock:resp:alb2c3d4e5f6a7b8",
  "match_preview": "请分析上季度销售数据",
  "queue_length": 2,
  "items": [
    "第一次回答: ...",
    "第二次回答: ..."
  ]
}
```

列出所有 Mock Key

```
GET /mock/responses

Response:

{
  "total_keys": 3,
  "keys": [
    {
      "key": "mock:resp:alb2c3d4e5f6a7b8",
      "preview": "请分析上季度销售数据",
      "queue_length": 2
    },
    {
      "key": "mock:resp:*",
      "preview": "(通配符 fallback)",
      "queue_length": 1
    }
  ]
}
```

清空指定 key

```
DELETE /mock/responses/:key

Response: {"deleted": true, "key": "mock:resp:alb2c3d4e5f6a7b8"}
```

清空所有

```
DELETE /mock/responses
```

```
Response: {"deleted_keys": 3}
```

9.4 Go 实现骨架

```
// internal/mockllm/service.go
package mockllm

import (
    "context"
    "crypto/sha256"
    "encoding/hex"
    "encoding/json"
    "fmt"
    "strings"
    "time"

    "github.com/redis/go-redis/v9"
    "go.uber.org/zap"
)

const (
    keyPrefix      = "mock:resp:"
    wildcardKey    = "mock:resp:*"
    defaultReply   = "这是一条 Mock LLM 默认响应。请先通过管理接口注入测试数据。"
    chunkDelayMs   = 5
)

// MockLLMService 兼容 OpenAI Chat Completions 协议的 Mock 服务
type MockLLMService struct {
    rdb      *redis.Client
    logger   *zap.Logger
}

// LookupKey 根据 messages 最后一条 content 生成 Redis key
func (s *MockLLMService) LookupKey(messages []ChatMessage) string {
    if len(messages) == 0 {
        return wildcardKey
    }
}
```

```

    }

    last := messages[len(messages)-1].Content
    sum := sha256.Sum256([]byte(last))
    return keyPrefix + hex.EncodeToString(sum[:])[16]
}

// PopResponse 从队列弹出一条预设响应
func (s *MockLLMService) PopResponse(ctx context.Context, key string) (string, error) {
    s.logger.Debug("[Mock] PopResponse attempt",
        zap.String("key", key),
    )

    // 优先精确 key
    val, err := s.rdb.LPop(ctx, key).Result()
    if err == nil {
        s.logger.Debug("[Mock] hit exact key", zap.String("key", key),
            zap.String("preview", truncate(val, 80)))
        return val, nil
    }

    // fallback 通配符
    val, err = s.rdb.LPop(ctx, wildcardKey).Result()
    if err == nil {
        s.logger.Debug("[Mock] hit wildcard fallback", zap.String("preview", truncate(val,
80)))
        return val, nil
    }

    // 默认响应
    s.logger.Warn("[Mock] queue empty, using default response", zap.String("key", key))
    return defaultReply, nil
}

// Push 写入预设响应（管理接口调用）
func (s *MockLLMService) Push(ctx context.Context, match string, responses []string, ttl
time.Duration) (string, error) {
    sum := sha256.Sum256([]byte(match))
    key := keyPrefix + hex.EncodeToString(sum[:])[16]

```

```

    vals := make([]interface{}, len(responses))

    for i, r := range responses {
        vals[i] = r
    }

    if err := s.rdb.RPush(ctx, key, vals...).Err(); err != nil {
        return "", fmt.Errorf("push mock response: %w", err)
    }

    if ttl > 0 {
        s.rdb.Expire(ctx, key, ttl)
    }

    s.logger.Info("[Mock] pushed responses",
        zap.String("key", key),
        zap.String("match_preview", truncate(match, 60)),
        zap.Int("count", len(responses)),
    )

    return key, nil
}

func truncate(s string, n int) string {
    if len([]rune(s)) <= n { return s }

    return string([]rune(s)[:n]) + "..."
}

```

```

// internal/mockllm/handler.go
package mockllm

import (
    "bufio"
    "fmt"
    "net/http"
    "strings"
    "time"

    "github.com/gin-gonic/gin"
    "go.uber.org/zap"
)

// ChatCompletionsHandler 处理 POST /mock/v1/chat/completions

```

```

func (s *MockLLMService) ChatCompletionsHandler(c *gin.Context) {
    var req ChatCompletionRequest
    if err := c.ShouldBindJSON(&req); err != nil {
        c.JSON(http.StatusBadRequest, gin.H{"error": err.Error()})
        return
    }

    key := s.LookupKey(req.Messages)
    s.logger.Debug("[Mock] ChatCompletions request",
        zap.String("model", req.Model),
        zap.Bool("stream", req.Stream),
        zap.Int("messages_count", len(req.Messages)),
        zap.String("last_content_preview", truncate(lastContent(req.Messages), 60)),
        zap.String("lookup_key", key),
    )

    content, _ := s.PopResponse(c.Request.Context(), key)

    if req.Stream {
        s.writeSSE(c, content)
    } else {
        s.writeCompletion(c, content)
    }
}

// writeSSE 按行拆分 content, 逐 chunk 输出 SSE
func (s *MockLLMService) writeSSE(c *gin.Context, content string) {
    id := fmt.Sprintf("chatcmpl-mock-%d", time.Now().UnixNano())
    delay := chunkDelayMs * time.Millisecond

    c.Header("Content-Type", "text/event-stream")
    c.Header("Cache-Control", "no-cache")
    c.Header("X-Accel-Buffering", "no")
    c.Status(http.StatusOK)

    flusher, _ := c.Writer.(http.Flusher)

    // 首包: role
    writeChunk(c.Writer, flusher, id, `{"role":"assistant"}`)
}

```



```

time.Sleep(delay)

// 按行拆分正文
scanner := bufio.NewScanner(strings.NewReader(content))
first := true
for scanner.Scan() {
    line := scanner.Text()
    if !first {
        writeChunk(c.Writer, flusher, id, `{"content":"\n"}`)
        time.Sleep(delay)
    }
    // 按字符拆分, 模拟真实 token 流 (每次最多 8 字符)
    runes := []rune(line)
    for i := 0; i < len(runes); i += 8 {
        end := i + 8
        if end > len(runes) { end = len(runes) }
        chunk := string(runes[i:end])
        escaped, _ := json.Marshal(chunk)
        writeChunk(c.Writer, flusher, id, fmt.Sprintf(`{"content":%s}`, escaped))
        time.Sleep(delay)
    }
    first = false
}

// 结束包
fmt.Fprintf(c.Writer, "data:
{"id\":"%s","\nobject\":"chat.completion.chunk","\nchoices\":[{"delta\":"
{"index\":"0","\nfinish_reason\":"stop"}]}\n\n", id)
fmt.Fprintf(c.Writer, "data: [DONE]\n\n")
if flusher != nil { flusher.Flush() }

s.logger.Debug("[Mock] SSE stream completed", zap.String("id", id))
}

func writeChunk(w http.ResponseWriter, f http.Flusher, id, delta string) {
    fmt.Fprintf(w, "data: {"id\":"%s","\nobject\":"chat.completion.chunk","\nchoices\":"
[{"delta\":"%s","\nindex\":"0"}]}\n\n", id, delta)
    if f != nil { f.Flush() }
}

```

```
// internal/mockllm/routes.go - 路由注册 (仅 dev/test 环境)

func RegisterMockRoutes(r *gin.Engine, svc *MockLLMService) {
    // OpenAI-compatible 接口

    mock := r.Group("/mock")

    mock.POST("/v1/chat/completions", svc.ChatCompletionsHandler)

    // 管理接口 (需要 Admin 角色)

    admin := mock.Group("/responses", middleware.RequireRole("admin"))

    admin.POST("",          svc.PushHandler)
    admin.GET("",           svc.ListHandler)
    admin.GET("/:key",      svc.GetQueueHandler)
    admin.DELETE("",        svc.ClearAllHandler)
    admin.DELETE("/:key",   svc.ClearKeyHandler)
}

// cmd/server/main.go - 条件挂载
if cfg.AppEnv == "development" || cfg.AppEnv == "test" {
    mockSvc := mockllm.New(redisClient, logger)
    mockllm.RegisterMockRoutes(router, mockSvc)
    logger.Info("Mock LLM Service enabled", zap.String("env", cfg.AppEnv))
}
```

LLM Router 集成：在 `internal/llm/router.go` 中，当环境变量 `LLM_BASE_URL` 指向本地 Mock（如 `http://localhost:8080/mock/v1`）时，Agent Engine 完全透明地使用 Mock——无需改动 Agent 逻辑代码。

9.5 Docker Compose 集成

Mock Service 内嵌在主 `api` 容器中，无需额外容器。通过环境变量控制：

```
# docker-compose.yml (api service 环境变量)

environment:
    APP_ENV: ${APP_ENV:-development}          # development | test | production
    MOCK_CHUNK_DELAY_MS: ${MOCK_CHUNK_DELAY_MS:-5}
    MOCK_DEFAULT_REPLY: ${MOCK_DEFAULT_REPLY:-"Mock LLM: 请注入测试数据"}
```

```
# .env 追加
# =====
# Mock LLM Service (仅 dev/test 生效)
# =====
APP_ENV=development
MOCK_CHUNK_DELAY_MS=5
MOCK_DEFAULT_REPLY=Mock LLM default response. Inject test data via /mock/responses API.
```

10. Debug 日志规范

10.1 日志库选型

使用 **uber-go/zap** (结构化高性能日志库, MIT License):

```
// internal/logger/logger.go
package logger

import (
    "os"
    "go.uber.org/zap"
    "go.uber.org/zap/zapcore"
)

func New(level, format string) *zap.Logger {
    var lvl zapcore.Level
    _ = lvl.UnmarshalText([]byte(level)) // "debug" | "info" | "warn" | "error"

    encoderCfg := zap.NewProductionEncoderConfig()
    encoderCfg.TimeKey = "ts"
    encoderCfg.EncodeTime = zapcore.ISO8601TimeEncoder

    var enc zapcore.Encoder
    if format == "console" {
        enc = zapcore.NewConsoleEncoder(encoderCfg)
    } else {
        enc = zapcore.NewJSONEncoder(encoderCfg)
    }
}
```

```
core := zapcore.NewCore(enc, zapcore.AddSync(os.Stdout), lvl)

return zap.New(core, zap.AddCaller(), zap.AddCallerSkip(0))

}
```

环境变量控制：

```
LOG_LEVEL=debug      # debug | info | warn | error (默认 info)
LOG_FORMAT=console   # console (开发友好) | json (生产结构化)
```

10.2 日志字段规范

每条日志必须包含以下**标准字段**（通过中间件自动注入）：

字段	类型	说明
ts	string	ISO-8601 时间戳
level	string	debug / info / warn / error
caller	string	源文件:行号
msg	string	日志主体描述
trace_id	string	请求追踪 ID (UUID, X-Trace-Id header)
user_id	string	当前用户 ID (认证后注入)
session_id	string	会话 ID (适用于 Chat/Agent)
task_id	string	Agent 任务 ID (适用于异步流程)
latency_ms	int	Handler 耗时 (仅请求日志)
component	string	所属组件 (见下表)

component 标准值：

值	说明
handler	HTTP 处理层
agent_service	Agent 执行核心
agent_engine	ADK Agent Engine
skill	Skill 调用
sql_executor	SQL 执行器
worker	异步 Worker
scheduler	定时调度器
mock_llm	Mock LLM Service
llm_router	LLM 路由器
vector_store	Milvus 向量操作
artifact	Artifact 存储
knowledge	知识库
auth	认证鉴权

10.3 关键路径 Debug 日志清单

HTTP 请求层（Middleware）

```
// middleware/logging.go
func LoggingMiddleware(logger *zap.Logger) gin.HandlerFunc {
    return func(c *gin.Context) {
        start := time.Now()

        traceID := uuid.New().String()
        c.Set("trace_id", traceID)
        c.Header("X-Trace-Id", traceID)

        logger.Debug("HTTP request received",
            zap.String("component", "handler"),
            zap.String("trace_id", traceID),
```

```

        zap.String("method", c.Request.Method),
        zap.String("path", c.FullPath()),
        zap.String("client_ip", c.ClientIP()),
        zap.String("user_agent", c.Request.UserAgent()),
        zap.Int64("content_length", c.Request.ContentLength),
    )

    c.Next()

    logger.Info("HTTP request completed",
        zap.String("component", "handler"),
        zap.String("trace_id", traceID),
        zap.String("method", c.Request.Method),
        zap.String("path", c.FullPath()),
        zap.Int("status", c.Writer.Status()),
        zap.Int64("latency_ms", time.Since(start).Milliseconds()),
        zap.Int("response_size", c.Writer.Size()),
    )
}
}

```

Agent Service — 任务全生命周期

```

// Debug 日志点 (internal/service/agent_service.go)

// 1. 任务创建
logger.Debug("[AgentService] task created",
    zap.String("component", "agent_service"),
    zap.String("trace_id", traceID),
    zap.String("task_id", task.ID),
    zap.String("user_id", task.UserID),
    zap.String("mode", task.Mode),           // sync | async
    zap.String("query_preview", truncate(task.Query, 80)),
    zap.Strings("data_sources", task.DataSources),
)

// 2. 入队
logger.Debug("[AgentService] task enqueued to Redis Stream",
    zap.String("component", "agent_service"),

```

```
zap.String("task_id", task.ID),
zap.String("stream_key", "agent:tasks"),
zap.String("msg_id", streamMsgID),
)

// 3. Agent Engine 调用前
logger.Debug("[AgentService] invoking Agent Engine",
    zap.String("component", "agent_service"),
    zap.String("task_id", task.ID),
    zap.String("session_id", sessionID),
    zap.String("llm_model", cfg.LLMModel),
    zap.Int("context_messages", len(messages)),
)

// 4. Skill 调用
logger.Debug("[AgentService] skill call",
    zap.String("component", "skill"),
    zap.String("task_id", task.ID),
    zap.String("skill_name", skillName),
    zap.Any("input_preview", truncateAny(input, 200)),
)

// 5. Skill 返回
logger.Debug("[AgentService] skill result",
    zap.String("component", "skill"),
    zap.String("task_id", task.ID),
    zap.String("skill_name", skillName),
    zap.Int64("duration_ms", durationMs),
    zap.Bool("success", err == nil),
    zap.Any("output_preview", truncateAny(output, 200)),
)

// 6. 任务完成
logger.Info("[AgentService] task completed",
    zap.String("component", "agent_service"),
    zap.String("task_id", task.ID),
    zap.String("status", "completed"),
    zap.Int64("total_duration_ms", totalMs),
    zap.Int("artifact_count", len(artifacts)),
```

```
)

// 7. 任务失败
logger.Error("[AgentService] task failed",
    zap.String("component", "agent_service"),
    zap.String("task_id", task.ID),
    zap.Error(err),
    zap.Int("retry_count", retryCount),
)
```

SQL 执行器

```
// Debug 日志点 (internal/skill/sql_executor.go)

// 1. AST 解析
logger.Debug("[SQLExecutor] AST parse",
    zap.String("component", "sql_executor"),
    zap.String("task_id", taskID),
    zap.String("raw_sql_preview", truncate(rawSQL, 200)),
    zap.String("stmt_type", stmtType),    // SELECT / DESCRIBE 等
    zap.Bool("allowed", allowed),
)

// 2. 执行前 (包含完整 SQL, DEBUG 级别)
logger.Debug("[SQLExecutor] executing query",
    zap.String("component", "sql_executor"),
    zap.String("task_id", taskID),
    zap.String("data_source", dsName),
    zap.String("sql", rawSQL),            // 完整 SQL, 仅 DEBUG 级别暴露
    zap.Any("params", params),
)

// 3. 执行后
logger.Debug("[SQLExecutor] query result",
    zap.String("component", "sql_executor"),
    zap.String("task_id", taskID),
    zap.Int("row_count", rowCount),
    zap.Int64("query_ms", queryMs),
)
```



```
        zap.Int("col_count", colCount),  
    )  
}
```

Worker

```
// Debug 日志点 (internal/worker/agent_worker.go)  
  
logger.Debug("[Worker] dequeued message",  
    zap.String("component", "worker"),  
    zap.String("stream_msg_id", msgID),  
    zap.String("task_type", taskType),    // "agent" | "scheduled"  
    zap.String("task_id", taskID),  
)  
  
// scheduled → agent 转换  
logger.Debug("[Worker] converting ScheduledTask to AgentTask",  
    zap.String("component", "worker"),  
    zap.String("scheduled_task_id", scheduledID),  
    zap.String("new_agent_task_id", agentTaskID),  
)  
  
logger.Debug("[Worker] re-enqueued as AgentTask",  
    zap.String("component", "worker"),  
    zap.String("agent_task_id", agentTaskID),  
    zap.String("stream_msg_id", newMsgID),  
)
```

LLM Router

```
logger.Debug("[LLMRouter] sending request to LLM",  
    zap.String("component", "llm_router"),  
    zap.String("task_id", taskID),  
    zap.String("base_url", cfg.LLMBaseURL),  
    zap.String("model", model),  
    zap.Bool("stream", stream),  
    zap.Int("messages_count", len(messages)),  
    zap.String("last_msg_preview", truncate(lastMsg, 80)),  
)
```

```
logger.Debug("[LLMRouter] LLM response received",
    zap.String("component", "llm_router"),
    zap.String("task_id", taskID),
    zap.Int64("latency_ms", latencyMs),
    zap.Int("completion_tokens", tokens),
    zap.String("finish_reason", finishReason),
)
```

Mock LLM Service

```
logger.Debug("[Mock] incoming request",
    zap.String("component", "mock_llm"),
    zap.String("model", req.Model),
    zap.Bool("stream", req.Stream),
    zap.Int("msg_count", len(req.Messages)),
    zap.String("last_content", truncate(lastContent(req.Messages), 80)),
    zap.String("lookup_key", key),
)

logger.Debug("[Mock] queue status before pop",
    zap.String("component", "mock_llm"),
    zap.String("key", key),
    zap.Int64("queue_length", queueLen),
)
```

10.4 日志级别使用规范

级别	用途	示例
DEBUG	开发调试，生产默认关闭。包含：完整 SQL、LLM 请求/响应 preview、每步 skill 调用入参出参、Mock 队列状态	<code>[Mock] hit exact key</code> 、 <code>[SQLExecutor] executing query</code>
INFO	关键业务事件，生产默认开启	任务创建/完成、用户登录/登出、定时任务触发
WARN	可恢复异常，需关注但不阻断业务	Mock 队列为空 fallback、重试超时、SQL 行数超限
ERROR	需立即处理的错误，触发告警	任务执行失败、数据库连接断开、Vault 读取失败

 **安全注意：** `DEBUG` 级别日志可能包含完整 SQL 语句和 LLM prompt/response 内容，**生产环境必须设置 `LOG_LEVEL=info`**，避免敏感数据泄漏到日志系统。

10.5 日志采样与聚合（生产建议）

```
# 生产环境日志配置建议 (docker-compose / k8s)

LOG_LEVEL: info

LOG_FORMAT: json           # 结构化 JSON，方便 ELK/Loki 解析

# 采样（高频路径避免日志爆炸）

LOG_SAMPLING_INITIAL: 100   # 每秒前 100 条完整记录

LOG_SAMPLING_THEREAFTER: 10 # 之后每 10 条记录 1 条
```


采样实现（zap sampler）：

```
if cfg.LogSamplingInitial > 0 {
    core = zapcore.NewSamplerWithOptions(
        core,
        time.Second,
        cfg.LogSamplingInitial,
        cfg.LogSamplingThereafter,
```

```
)  
  
}
```

11. 安全架构

8.1 安全审查层



安全规则配置:

```
# security_rules.yaml

input_rules:
  - name: "sql_injection"
    patterns:
      - "(?i) (drop\\s+table|delete\\s+from|truncate|alter\\s+table) "
    action: "block"
    severity: "critical"

  - name: "prompt_injection"
    patterns:
      - "(?i) (ignore\\s+(all\\s+)?(previous|above)\\s+(instructions|rules)) "
      - "(?i) (system\\s*prompt) "
    action: "block"
    severity: "high"

  - name: "unauthorized_access"
    patterns:
      - "(?i) (other\\s+users?('|\\s+)?data|salary|personal\\s+info) "
    action: "warn"
    severity: "medium"

output_rules:
  - name: "pii_detection"
    patterns:
      - "\\b1[3-9]\\d{9}\\b" # 手机号
      - "\\b\\d{17}[\\dXx]\\b" # 身份证
    action: "redact"
    severity: "high"

tool_rules:
  - name: "email_whitelist"
    check: "validate_email_domain"
    action: "block"
    severity: "critical"

  - name: "rate_limit"
    check: "check_rate_limit"
```

```
action: "throttle"

severity: "medium"
```

熔断器 (Circuit Breaker):

```
type CircuitBreaker struct {
    failureThreshold int          // 连续失败次数阈值
    successThreshold int          // 恢复所需成功次数
    timeout          time.Duration // 熔断后等待时间
    state            State         // closed | open | half-open
    failures         int
    successes        int
    lastFailure      time.Time
    mu               sync.Mutex
}

func (cb *CircuitBreaker) Execute(fn func() error) error {
    cb.mu.Lock()

    if cb.state == StateOpen {
        if time.Since(cb.lastFailure) < cb.timeout {
            cb.mu.Unlock()
            return ErrCircuitOpen
        }
        cb.state = StateHalfOpen
    }
    cb.mu.Unlock()

    err := fn()

    cb.mu.Lock()
    defer cb.mu.Unlock()
    if err != nil {
        cb.failures++
        cb.lastFailure = time.Now()
        if cb.failures >= cb.failureThreshold {
            cb.state = StateOpen
            // 记录审计日志
            audit.LogSecurityAlert("circuit_breaker_open", ...)
        }
    }
}
```

```

        return err
    }


    // success
    cb.successes++

    if cb.state == StateHalfOpen && cb.successes >= cb.successThreshold {
        cb.state = StateClosed
        cb.failures = 0
        cb.successes = 0
    }

    return nil
}

```


8.2 认证流程



	RBAC Check	

12. 会话与工作区管理

9.1 Session 生命周期



Session 管理器:

```
type SessionManager struct {
    mongo      *MongoClient
    redis      *RedisClient
    seaweedfs  *SeaweedFSClient
    mem0       *Mem0Client
}

func (sm *SessionManager) CreateSession(userID, sessionType string) (*Session, error) {
```



```
workspaceID := uuid.New().String()

// 1. 创建 SeaweedFS workspace bucket
sm.seaweedfs.CreateBucket(ctx, workspaceID)

// 2. 初始化 Mem0 session memory
sm.mem0.CreateSession(ctx, userID, workspaceID)

// 3. 保存 Session 记录到 MongoDB
session := &Session{
    ID:          uuid.New().String(),
    UserID:      userID,
    Type:        sessionType,
    WorkspaceID: workspaceID,
    CreatedAt:   time.Now(),
    ExpiresAt:   time.Now().Add(30 * time.Minute),
}

sm.mongo.Insert("sessions", session)

return session, nil
}

func (sm *SessionManager) CleanupExpiredSessions() {
    sessions := sm.mongo.Find("sessions", bson.M{
        "expires_at": bson.M{"$lt": time.Now().Add(-24 * time.Hour)},
    })
    for _, s := range sessions {
        // 级联清理
        sm.cleanupSession(s)
        // 清理子 session
        subSessions := sm.mongo.Find("sessions", bson.M{
            "parent_session_id": s.ID,
        })
        for _, sub := range subSessions {
            sm.cleanupSession(sub)
        }
    }
}
```

```
func (sm *SessionManager) cleanupSession(s *Session) {
    sm.seaweedfs.DeleteBucket(ctx, s.WorkspaceID) // 清理工作区文件
    sm.mem0.DeleteSession(ctx, s.ID)             // 清理 Mem0 会话记忆
    sm.redis.Delete(ctx, "session:"+s.ID)        // 清理 Redis 缓存
    sm.mongo.Delete("sessions", bson.M{"_id": s.ID}) // 删除记录
}
```

9.2 子 Agent Session 管理

```
// A2A 子 Agent 创建
func (sm *SessionManager) CreateSubSession(parentSessionID string, task AgentInput)
(*Session, error) {
    parent, _ := sm.GetSession(parentSessionID)

    // 继承父 session 的部分上下文
    subSession, _ := sm.CreateSession(parent.UserID, "sub_agent")
    subSession.ParentSessionID = parentSessionID
    subSession.WorkspaceID = parent.WorkspaceID + "/sub_" + subSession.ID

    sm.mongo.Update("sessions", bson.M{"_id": subSession.ID}, subSession)

    return subSession, nil
}
```

12.3 本地文件系统工作区 (Workspace)

每个 Agent Session 拥有一个**独立的本地文件系统工作区**，生命周期与 Session 完全一致（创建时分配，销毁时级联清理）。工作区用于存放 Agent 执行过程中需要操作的文件：

- 临时脚本（Shell、SQL 片段等）
- 生成的图表、图片
- 生成的 PPT/Word/PDF 文档
- 数据分析中间结果文件
- 其他需要文件系统交互的临时产物

与 SeaweedFS Workspace 的关系：本地 Workspace（`/workspaces/<session_id>/`）用于运行时文件操作和脚本执行；SeaweedFS Workspace（`workspaces/` bucket）用于持久化存储跨步骤共享的数据文件。两者互补：本地 Workspace 满足 POSIX 文件系统需求（脚本执行、工具链），SeaweedFS 满足持久化和跨副本共享需求。

目录结构

```

/workspaces/                                # 宿主机挂载点（可配置 WORKSPACE_ROOT）
├── <session_id_a>/                          # Session A 的工作区
│   ├── scripts/                            # 临时脚本
│   │   └── analysis.sh
│   ├── output/                             # 生成产出
│   │   ├── chart.png
│   │   └── report.docx
│   └── data_export.xlsx
├── tmp/                                     # 临时文件
├── <session_id_b>/                          # Session B 的工作区（完全隔离）
├── ...
└── _cleanup/                              # 待清理目录（异步 GC）

```

安全隔离原则（三层防护）

Layer 1 - Docker 层：容器以 appuser（非 root）运行

```

├── /workspaces/ → rwx（唯一可读、写、执行的用户目录）
├── /app/         → r-x（只读，无写权限；server 需要 x 启动）
├── /usr/bin 等   → r-x（系统工具如 bash 需要 x，但属 root，不可写）
└── 其他系统路径 → ---（无任何权限）

```

Layer 2 - Skill 网关层：禁止任何代码直接操作文件系统

```

├── 所有文件读写 → workspace_read / workspace_write Skill
└── 所有脚本执行 → workspace_exec Skill（含安全审计）

```

Layer 3 - 运行时审计层：

```

├── 路径沙箱：resolved_path 必须在 /workspaces/<session_id>/ 内
├── 脚本白名单：禁止 rm -rf、curl/wget、nc、chmod 777 等
└── 资源限制：单文件 ≤ 100MB，总目录 ≤ WORKSPACE_MAX_SIZE_MB

```

12.3.1 文件读写 Skill（workspace_read / workspace_write）

文件操作必须通过 Skill 接口，禁止 Handler/Service/Agent Engine 直接调用 `os.Open` / `os.WriteFile`。

`workspace_read` Skill:

```
// internal/skill/workspace_read.go

type WorkspaceReadSkill struct {
    maxFileSizeMB int64    // 默认: 50
    // workspaceRoot 从 SkillContext 获取, 不存储为字段
}

// Execute 使用 SkillContext - session_id 自动注入, 参数中不可见
func (s *WorkspaceReadSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    path, _ := params["path"].(string)

    logger.Debug("[WorkspaceRead] executing",
        zap.String("component", "skill"),
        zap.String("skill_name", "workspace_read"),
        zap.String("session_id", sc.SessionID),
        zap.String("path", path),
    )

    // 路径安全解析 - session 从 SkillContext 获取, 不接受外部传入
    safePath, err := s.resolveSafePath(sc.SessionID, path)
    if err != nil {
        return nil, fmt.Errorf("workspace_read: path not allowed: %w", err)
    }

    // 大小检查
    fi, err := os.Stat(safePath)
    if err != nil {
        return nil, fmt.Errorf("workspace_read: stat failed: %w", err)
    }
    if fi.Size() > s.maxFileSizeMB*1024*1024 {
        return nil, fmt.Errorf("workspace_read: file too large (%d MB > %d MB max)",
fi.Size()/1024/1024, s.maxFileSizeMB)
    }

    // 读取
    content, err := os.ReadFile(safePath)
    if err != nil {
        return nil, fmt.Errorf("workspace_read: read failed: %w", err)
    }
}
```

```

    }

    return &WorkspaceReadOutput{
        Path:      path,
        Content:    content,
        ContentType: mime.TypeByExtension(filepath.Ext(safePath)),
        Size:       fi.Size(),
    }, nil
}

// resolveSafePath 确保解析后路径在 session workspace 内 - sessionID 来自 SkillContext
func (s *WorkspaceReadSkill) resolveSafePath(sessionID, relPath string) (string, error) {
    // 禁止绝对路径
    if filepath.IsAbs(relPath) {
        return "", fmt.Errorf("absolute path not allowed: %s", relPath)
    }
    // 清理并拼接
    clean := filepath.Clean(relPath)
    full := filepath.Join("/workspaces", sessionID, clean)

    // 二次校验: 解析真实路径后必须仍在 /workspaces/<session_id>/ 内
    realPath, err := filepath.EvalSymlinks(full)
    if err != nil {
        return "", fmt.Errorf("cannot resolve path: %w", err)
    }
    prefix := filepath.Join("/workspaces", sessionID) + "/"
    if !strings.HasPrefix(realPath, prefix) {
        return "", fmt.Errorf("path escape attempt blocked: %s → %s", relPath, realPath)
    }
    return realPath, nil
}

```

workspace_write Skill:

```

// internal/skill/workspace_write.go
type WorkspaceWriteSkill struct {
    maxFileSizeMB int64 // 默认: 100
}

```

```

func (s *WorkspaceWriteSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    path, _ := params["path"].(string)
    content, _ := params["content"].([]byte)
    overwrite, _ := params["overwrite"].(bool)

    logger.Debug("[WorkspaceWrite] writing file",
        zap.String("component", "skill"),
        zap.String("skill_name", "workspace_write"),
        zap.String("session_id", sc.SessionID),
        zap.String("path", path),
        zap.Int("size_bytes", len(content)),
    )

    safePath, err := resolveSafePath(sc.SessionID, path)
    if err != nil {
        return nil, fmt.Errorf("workspace_write: %w", err)
    }

    if len(content) > int(s.maxFileSizeMB*1024*1024) {
        return nil, fmt.Errorf("workspace_write: content too large (%d MB > %d MB max)",
len(content)/1024/1024, s.maxFileSizeMB)
    }

    // 确保父目录存在
    os.MkdirAll(filepath.Dir(safePath), 0o750)

    flag := os.O_WRONLY | os.O_CREATE | os.O_TRUNC
    if !overwrite {
        flag |= os.O_EXCL
    }

    f, err := os.OpenFile(safePath, flag, 0o640)
    if err != nil {
        return nil, fmt.Errorf("workspace_write: open failed: %w", err)
    }

    defer f.Close()

    if _, err := f.Write(content); err != nil {
        return nil, fmt.Errorf("workspace_write: write failed: %w", err)
    }
}

```

```
return map[string]any{"path": path, "size_bytes": len(content)}, nil
}
```

12.3.2 脚本执行 Skill (workspace_exec) — 含安全审计

脚本执行通过 `workspace_exec` Skill 统一入口，执行前必须通过安全审计。

安全审计规则（强制，不可绕过）：

审计维度	规则	拒绝原因
路径逃逸检测	<code>resolved_script_path</code> 必须在 <code>/workspaces/<session_id>/</code> 内	防止读写其他 session 或系统文件
网络请求禁止	拦截 <code>curl</code> 、 <code>wget</code> 、 <code>nc</code> 、 <code>socat</code> 、 <code>telnet</code> 、 <code>ssh</code> 、 <code>python -m http</code> 、 <code>go run</code>	防止脚本访问外部网络
危险命令拦截	<code>rm -rf /</code> 、 <code>chmod 777</code> 、 <code>chown</code> 、 <code>mount</code> 、 <code>mkfs</code> 、 <code>dd if=</code> 、 <code>> /dev/sda</code>	防止破坏容器或宿主机
进程 fork 限制	禁止 <code>fork()</code> 炸弹特征 (<code>() { : :;& };;</code>)	防止资源耗尽
超时限制	单次脚本执行 ≤ 30 秒	防止长时间阻塞 Worker
输出大小限制	<code>stdout+stderr ≤ 10 MB</code>	防止内存溢出

```
// internal/skill/workspace_exec.go

type WorkspaceExecSkill struct {
    timeout          time.Duration // 默认 30s
    maxOutputBytes int64          // 默认 10 MB
    audit            *ExecAuditor
    // workspaceRoot 从 SkillContext 获取，不存储
}

func (s *WorkspaceExecSkill) Execute(ctx context.Context, sc SkillContext, params
map[string]any) (any, error) {
    script, _ := params["script"].(string)
    interpreter, _ := params["interpreter"].(string)
    workDir, _ := params["work_dir"].(string)
    if workDir == "" { workDir = "." }
}
```

```

logger.Debug("[WorkspaceExec] audit+exec",
    zap.String("component", "skill"),
    zap.String("skill_name", "workspace_exec"),
    zap.String("session_id", sc.SessionID),
    zap.String("interpreter", interpreter),
    zap.Int("script_bytes", len(script)),
)

// Step 1: 安全审计
if err := s.audit.Audit(script); err != nil {
    logger.Warn("[WorkspaceExec] audit blocked",
        zap.String("session_id", sc.SessionID),
        zap.Error(err),
    )
    return nil, fmt.Errorf("workspace_exec: security audit failed: %w", err)
}

// Step 2: 写脚本到 workspace (sc.SessionID 来自 SkillContext, 不接受 params 传入)
scriptPath := filepath.Join("/workspaces", sc.SessionID, "scripts",
fmt.Sprintf("exec_%d.sh", time.Now().UnixNano()))
safePath, err := resolveSafePath(sc.SessionID, scriptPath)
if err != nil {
    return nil, err
}
if err := os.WriteFile(safePath, []byte(script), 0o700); err != nil {
    return nil, fmt.Errorf("workspace_exec: write script failed: %w", err)
}

// Step 3: 构建命令 (限制可用解释器)
var cmd *exec.Cmd
workDirFull := filepath.Join("/workspaces", sc.SessionID, workDir)
switch interpreter {
case "bash":
    cmd = exec.CommandContext(ctx, "bash", safePath)
case "sh":
    cmd = exec.CommandContext(ctx, "sh", safePath)
default:
    return nil, fmt.Errorf("workspace_exec: unsupported interpreter: %s", interpreter)
}

```



```
}

cmd.Dir = workDirFull
cmd.Env = []string{
    "HOME=/workspaces/" + sc.SessionID,
    "PATH=/usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/sbin:/bin",
    "TMPDIR=/workspaces/" + sc.SessionID + "/tmp",
}

// Step 4: 超时执行
timeoutCtx, cancel := context.WithTimeout(ctx, s.timeout)
defer cancel()

var stdout, stderr bytes.Buffer
cmd.Stdout = io.MultiWriter(&stdout, limitWriter{max: s.maxOutputBytes})
cmd.Stderr = io.MultiWriter(&stderr, limitWriter{max: s.maxOutputBytes})

start := time.Now()
err = cmd.Run()
elapsed := time.Since(start)

output := &ExecOutput{
    ExitCode: 0,
    Stdout:   stdout.String(),
    Stderr:   stderr.String(),
    Duration: elapsed,
}

if err != nil {
    if exitErr, ok := err.(*exec.ExitError); ok {
        output.ExitCode = exitErr.ExitCode()
    } else {
        return nil, fmt.Errorf("workspace_exec: execution error: %w", err)
    }
}

logger.Debug("[WorkspaceExec] completed",
    zap.String("component", "skill"),
    zap.String("session_id", sc.SessionID),
    zap.Int("exit_code", output.ExitCode),
    zap.Int64("duration_ms", elapsed.Milliseconds()),
```

```

    )

    return output, nil
}

type ExecOutput struct {
    ExitCode int          `json:"exit_code"`
    Stdout   string              `json:"stdout"`
    Stderr   string              `json:"stderr"`
    Duration time.Duration    `json:"duration"`
}

```

12.3.3 Workspace 生命周期管理

```

// internal/session/workspace.go

type WorkspaceManager struct {
    root      string    // /workspaces
    maxSizeMB int64
}

// Create 在 Session 创建时调用
func (wm *WorkspaceManager) Create(ctx context.Context, sessionID string) (string, error) {
    wsPath := filepath.Join(wm.root, sessionID)
    dirs := []string{
        filepath.Join(wsPath, "scripts"),
        filepath.Join(wsPath, "output"),
        filepath.Join(wsPath, "tmp"),
    }
    for _, d := range dirs {
        if err := os.MkdirAll(d, 0o750); err != nil {
            return "", fmt.Errorf("create workspace dirs: %w", err)
        }
    }
    logger.Info("[Workspace] created", zap.String("session_id", sessionID),
        zap.String("path", wsPath))
    return wsPath, nil
}

// Destroy 在 Session 过期/清理时调用

```

```

func (wm *WorkspaceManager) Destroy(ctx context.Context, sessionID string) error {
    wsPath := filepath.Join(wm.root, sessionID)
    logger.Info("[Workspace] destroying", zap.String("session_id", sessionID))

    // 移到 _cleanup 目录异步删除（避免阻塞）
    cleanupDir := filepath.Join(wm.root, "_cleanup", sessionID)
    if err := os.Rename(wsPath, cleanupDir); err != nil {
        return err
    }

    go func() {
        os.RemoveAll(cleanupDir)
        logger.Debug("[Workspace] cleanup completed", zap.String("session_id", sessionID))
    }()

    return nil
}

// EnforceSizeLimit 周期性执行，清理超限 workspace
func (wm *WorkspaceManager) EnforceSizeLimit(ctx context.Context) {
    sessions, _ := os.ReadDir(wm.root)
    for _, s := range sessions {
        if !s.IsDir() || strings.HasPrefix(s.Name(), "_") {
            continue
        }

        size, _ := dirSize(filepath.Join(wm.root, s.Name()))
        if size > wm.maxSizeMB*1024*1024 {
            logger.Warn("[Workspace] size limit exceeded, cleaning up",
                zap.String("session_id", s.Name()),
                zap.Int64("size_mb", size/1024/1024),
            )
            wm.Destroy(ctx, s.Name())
        }
    }
}

```

13. Artifact 管理 (基于 SeaweedFS)

10.1 概述

Artifact 是 Agent 在执行分析任务过程中生成的各类产出物：图表、导出数据文件、报告附件、中间结果等。所有 Artifact 统一存储在 SeaweedFS 中，通过 MongoDB 管理元数据。

设计原则：

- **与 Session Workspace 分离：**Artifact 有独立的 SeaweedFS volume，不与 Session 临时文件混存
- **生命周期独立：**Artifact 的清理策略不同于 Session workspace：默认跟随 Session 清理，但用户可标记为「持久化」长期保留
- **Agent 透明：**Agent 通过 Skill 自动将产出物保存为 Artifact，无需感知底层存储

10.2 SeaweedFS 存储设计

```
SeaweedFS Buckets:
├─ workspaces/           # Session 临时工作区 (已有)
│   ├─ ws_a1/
│   ├─ ws_a2/
│   └─ ...
└─
└─ artifacts/           # Artifact 持久存储 (新增)
    ├─ {task_id}/
    │   ├─ chart_revenue_trend.png
    │   ├─ export_top10.csv
    │   └─ report_q2_analysis.pdf
    └─ ...
```

存储路径规则： `artifacts/{task_id}/{artifact_id}.{ext}`

- `task_id`：关联的 Agent 任务 ID（保证同一任务的所有 Artifact 在同一目录下）
- `artifact_id`：Artifact 唯一标识（UUID）
- `ext`：文件扩展名


10.3 数据模型

MongoDB `artifacts` 集合：

```
{
  "_id": "artifact_001",
  "task_id": "task_001",
  "session_id": "session_agent_001",
```

```
"user_id": "user_001",
"name": "华东区销售额趋势图",
"type": "chart",           // chart | export | report | interim | screenshot
"mime_type": "image/png",
"size_bytes": 245760,
"storage_path": "artifacts/task_001/artifact_001.png",
"persistent": false,      // 用户是否标记为持久化（不受 Session 清理）
"metadata": {
  "chart_type": "line",
  "dimensions": "1920x1080",
  "generated_by": "stats_engine_skill",
  "generation_duration_ms": 3200
},
"created_at": "2026-07-01T10:30:00Z"
}
```

10.4 Artifact 生命周期管理



清理策略:

条件	行为
<code>persistent = false</code> + Session 过期	跟随 Session 清理，删除 SeaweedFS 文件和 MongoDB 记录
<code>persistent = true</code>	不受 Session 清理影响，永久保留
手动删除	用户主动删除 Artifact（需确认），同时清理 SeaweedFS 和 MongoDB
批量清理	管理员可按时间范围/任务批量清理非持久化 Artifact

Session 清理联动:

```
func (sm *SessionManager) cleanupArtifacts(sessionID string) {
    // 删除该 session 下所有非持久化的 artifact
    artifacts := sm.mongo.Find("artifacts", bson.M{
        "session_id": sessionID,
        "persistent": false,
    })
    for _, art := range artifacts {
        sm.seaweedfs.DeleteObject(ctx, "artifacts", art.StoragePath)
        sm.mongo.Delete("artifacts", bson.M{"_id": art.ID})
    }
}
```

13.5 Artifact Skill (`save_artifact`)

Agent 通过调用 `save_artifact` Skill 将生成的图表、数据文件等保存为 Artifact。底层复用 `ArtifactLogic` (§4.3 Logic 层) 实现，与 `save_report` Skill 共用同一 SeaweedFS 上传 + MongoDB 写入逻辑：

```
// internal/skill/save_artifact.go

type SaveArtifactSkill struct {
    logic *logicC.ArtifactLogic // ← 共用 Logic 层
}

func (s *SaveArtifactSkill) Name() string { return "save_artifact" }

func (s *SaveArtifactSkill) Execute(ctx context.Context, sc SkillContext, params
```

```
map[string]any) (any, error) {  
    name, _ := params["name"].(string)  
    content, _ := params["content"].([]byte) // 原始字节  
    mimeType, _ := params["mime_type"].(string)  
  
    // 幂等创建 (通过 ArtifactLogic)  
    artifact, err := s.logic.CreateArtifact(ctx, sc, logic.CreateArtifactInput{  
        Name:      name,  
        Content:   content,  
        MimeType:  mimeType,  
    })  
    if err != nil {  
        return nil, err  
    }  
  
    return map[string]any{  
        "artifact_id": artifact.ID,  
        "download_url": fmt.Sprintf("/api/v1/artifacts/%s/download", artifact.ID),  
        "is_new":      true, // ArtifactLogic 内部已做幂等处理  
    }, nil  
}
```

13.6 Artifact API


Method	Path	Description
GET	/api/v1/artifacts?task_id=xxx	获取 Artifact 列表 (按任务筛选)
GET	/api/v1/artifacts/:id	获取 Artifact 元数据
GET	/api/v1/artifacts/:id/download	下载 Artifact 原始文件 (SeaweedFS presigned URL)
GET	/api/v1/artifacts/:id/preview	获取 Artifact 预览 (图片直接返回, CSV 返回前 N 行)
POST	/api/v1/artifacts/:id/persist	标记为持久化
POST	/api/v1/artifacts/:id/unpersist	取消持久化标记
DELETE	/api/v1/artifacts/:id	删除 Artifact (同时清理 SeaweedFS)


10.7 预览支持

文件类型	预览方式	限制
PNG / JPEG / SVG / GIF	直接返回文件流	单文件 ≤ 10MB
CSV	返回前 100 行 JSON	单文件 ≤ 50MB
PDF	返回文件流（浏览器内置预览）	单文件 ≤ 20MB
其他类型	显示文件信息，提供下载链接	-

14. 知识库设计

11.1 知识库架构





文档处理流程:

```

type KnowledgeService struct {
    mongo    *MongoClient
    gridfs   *gridfs.Bucket // mongo.GridFSBucket
    milvus   *MilvusClient
    redis    *RedisClient
}

func (s *KnowledgeService) UploadDocument(userID string, file io.Reader, filename string,
metadata DocMetadata) (*Document, error) {
    // 1. 解析文档
    content, err := s.parseDocument(file, filename)
    if err != nil { return nil, err }
    contentBytes := []byte(content)

    doc := &Document{
        ID:      uuid.New().String(),
        Title:   metadata.Title,
        Type:    metadata.Type,
        Tags:    metadata.Tags,
        UploadBy: userID,
        Status:  "processing",
    }

    // 2. 统一存入 GridFS (小文件和大文件同一路径, GridFS 自动 255KB 分片)
    uploadOpts := options.GridFSUpload().SetMetadata(bson.M{
        "doc_id": doc.ID,
        "filename": filename,
    })

    fileId, err := s.gridfs.UploadFromStream(filename, bytes.NewReader(contentBytes),
uploadOpts)

```

```

    if err != nil { return nil, fmt.Errorf("gridfs upload: %w", err) }

    // 3. 保存元数据
    s.mongo.Insert("knowledge_doc_contents", bson.M{
        "_id":          uuid.New().String(),
        "doc_id":        doc.ID,
        "gridfs_file_id": fileID,
        "filename":      filename,
        "size_bytes":    len(contentBytes),
        "created_at":    time.Now(),
    })
    s.mongo.Insert("knowledge_docs", doc)

    // 4. 异步索引
    s.redis.XAdd(ctx, "knowledge:index:queue", map[string]any{
        "doc_id": doc.ID,
    })
    return doc, nil
}

```

```

func (s *KnowledgeService) IndexWorker() { for { msgs := s.redis.XReadGroup(ctx,
"knowledge:index:queue", "indexer") for _, msg := range msgs { docID := msg.Values["doc_id"]
s.indexDocument(docID.(string)) s.redis.XAck(ctx, "knowledge:index:queue", "indexer", msg.ID) } } }

```

```

func (s *KnowledgeService) indexDocument(docID string) { doc :=
s.mongo.FindOne("knowledge_docs", bson.M{"_id": docID}) docContent :=
s.mongo.FindOne("knowledge_doc_contents", bson.M{"doc_id": docID})

```

```

// 统一从 GridFS 读取, DownloadStream 实现 io.ReadSeeker, LLM 分片器直接 seek
stream, err := s.gridfs.OpenDownloadStream(docContent.GridFSFileID)
if err != nil { /* handle */ }
defer stream.Close()

// 1. LLM 语义分片 (直接操作 io.ReadSeeker, 不占内存)
chunks := s.llmChunker.Split(stream, docContent.SizeBytes)

// 2. 向量化 + 写入 Milvus
for i, chunk := range chunks {
    embedding := s.embedModel.Embed(chunk)
    s.milvus.Insert("knowledge_chunks", MilvusEntity{

```

```

        Vector:      embedding,
        DocID:       docID,
        ChunkIndex: i,
        Title:       doc.Title,
        Tags:        doc.Tags,
    })
}

// 3. 更新状态
s.mongo.Update("knowledge_docs", bson.M{"_id": docID}, bson.M{
    "$set": bson.M{"status": "indexed", "chunk_count": len(chunks)},
})

```

```

}

```

11.2 混合搜索策略

```

```go
func (s *KnowledgeService) Search(query string, userID string, opts SearchOptions)
([]SearchResult, error) {
 var results []SearchResult

 switch opts.Type {
 case "semantic":
 // Milvus 向量搜索
 embedding := s.embedModel.Embed(query)
 milvusResults := s.milvus.Search("knowledge_chunks", embedding, opts.TopK)
 results = append(results, s.enrichResults(milvusResults)...)

 case "fulltext":
 // MongoDB 全文搜索
 mongoResults := s.mongo.Find("knowledge_doc_contents", bson.M{
 "$text": bson.M{"$search": query},
 })
 results = append(results, s.enrichResults(mongoResults)...)

 case "hybrid":
 // 混合搜索 + 重排序
 semResults := s.Search(query, userID, SearchOptions{Type: "semantic", TopK:

```

```
opts.TopK}))
 fullResults := s.Search(query, userID, SearchOptions{Type: "fulltext", TopK:
opts.TopK}))
 results = s.mergeAndRerank(semResults, fullResults)
 }

 // 权限过滤
 results = s.filterByPermission(results, userID)

 return results, nil
}
```

---

## 15. 审计系统设计

### 12.1 审计日志模型

```
{
 "_id": "audit_20260701_001",
 "timestamp": "2026-07-01T10:30:00Z",
 "user_id": "user_001",
 "username": "zhangsan",
 "ip_address": "192.168.1.100",
 "session_id": "session_chat_001",
 "action_type": "agent_task_create", // 操作类型枚举
 "action_detail": {
 "task_id": "task_001",
 "query": "对过去3年销售数据做回归分析",
 "data_sources": ["sales_db"],
 "mode": "async"
 },
 "resource_type": "agent_task",
 "resource_id": "task_001",
 "result": "success",
 "error": null,
 "duration_ms": 120
}
```

## 12.2 Agent 操作审计

```
{
 "_id": "audit_20260701_002",
 "timestamp": "2026-07-01T10:30:05Z",
 "trigger_user_id": "user_001",
 "agent_id": "agent_001",
 "task_id": "task_001",
 "session_id": "session_agent_001",
 "ip_address": "192.168.1.100",
 "action_type": "skill_call",
 "action_detail": {
 "skill_name": "sql_executor",
 "params_summary": "SELECT revenue FROM sales WHERE region='华东'",
 "duration_ms": 320,
 "result": "success",
 "rows_affected": 150
 },
 "result": "success"
}
```

## 12.3 日志类数据表 TTL 自动过期

所有日志类 Collection 使用 MongoDB TTL 索引自动过期，无需手动清理任务：

```
// 审计日志 - 90 天
db.audit_logs.createIndex(
 { "created_at": 1 },
 { expireAfterSeconds: 7776000, name: "ttl_created_at" }
)

// 会话记录 - 30 天（已过期/已完成的会话）
db.sessions.createIndex(
 { "expires_at": 1 },
 { expireAfterSeconds: 0, name: "ttl_expires_at" }
)

// 请求日志 - 30 天
db.request_logs.createIndex(
```

```
 { "created_at": 1 },
 { expireAfterSeconds: 2592000, name: "ttl_created_at" }
)

// 通知记录 - 7 天
db.notifications.createIndex(
 { "created_at": 1 },
 { expireAfterSeconds: 604800, name: "ttl_created_at" }
)

// Token 消耗日志 - 90 天 (长期统计从 Redis Stats 聚合)
db.token_consumptions.createIndex(
 { "created_at": 1 },
 { expireAfterSeconds: 7776000, name: "ttl_created_at" }
)
```

**TTL 策略:** MongoDB TTL 索引在后台每 60 秒扫描一次，过期文档自动删除。不需要额外的定时清理 Worker。部分查询依赖 `created_at` 的集合需额外创建非 TTL 的查询索引。

---

## 13. 统计监控 (Redis Stats Counter)

---

### 13.1 设计原则

统计指标使用 Redis 作为实时计数器（必须开启 AOF + RDB 持久化），Scheduler 定时任务直接写入 Redis，不经过消息队列，仅记录日志。提供 Dashboard API 聚合查询。

13.2 统计指标

指标	Redis Key	说明
Agent 调用次数	<code>stats:agent_calls:{date}</code>	按日聚合，区分 sync/async
模型调用次数	<code>stats:model_calls:{date}:{model_name}</code>	按模型+日期聚合
Session 创建次数	<code>stats:sessions:{date}</code>	按日聚合，区分 chat/agent
Task 创建次数	<code>stats:tasks:{date}</code>	按日聚合，区分 sync/async/scheduled
Token 消耗量	<code>stats:tokens:{date}:{model_name}</code>	按模型+日期聚合 input/output token
AI 总成本	<code>stats:cost:{date}</code>	按日聚合，单位分 (cents)

13.3 Redis 写入策略

```
// Scheduler 定时任务 (每 5 分钟)，直接写入 Redis
func (s *StatsCollector) Collect(ctx context.Context) error {
 today := time.Now().Format("2006-01-02")

 // 原子递增 Redis 计数器
 pipe := s.redis.Pipeline()

 // Agent 调用次数
 pipe.IncrBy(ctx, fmt.Sprintf("stats:agent_calls:%s", today), s.agentCallCount())
 pipe.IncrBy(ctx, fmt.Sprintf("stats:agent_calls:%s:sync", today), s.agentSyncCount())
 pipe.IncrBy(ctx, fmt.Sprintf("stats:agent_calls:%s:async", today), s.agentAsyncCount())

 // Session/Task
 pipe.IncrBy(ctx, fmt.Sprintf("stats:sessions:%s", today), s.sessionCount())
 pipe.IncrBy(ctx, fmt.Sprintf("stats:tasks:%s", today), s.taskCount())

 // Token 消耗 (按模型拆分)
 for model, tokens := range s.tokenUsage() {
 pipe.IncrBy(ctx, fmt.Sprintf("stats:tokens:%s:%s:input", today, model),
tokens.Input)
```

```

 pipe.IncrBy(ctx, fmt.Sprintf("stats:tokens:%s:%s:output", today, model),
tokens.Output)

 pipe.IncrByFloat(ctx, fmt.Sprintf("stats:cost:%s", today), tokens.CostCents)
 }

 _, err := pipe.Exec(ctx)
 return err
}

```

### 13.4 投入产出比 (ROI) 计算

```

// ROI = 等效节省人时 / AI 总成本
// 等效节省人时 = Agent调用次数 × 平均单次节省时间(30min) / 60
// AI 总成本 = sum(stats:cost:{date}) / 100 → 元

func (s *StatsCollector) CalcROI(ctx context.Context, days int) (*ROIResult, error) {
 // 从 Redis 读取近 N 天的聚合数据
 dates := s.lastNDates(days)

 var totalCalls int64
 var totalCost float64

 for _, date := range dates {
 calls, _ := s.redis.Get(ctx, fmt.Sprintf("stats:agent_calls:%s", date)).Int64()
 cost, _ := s.redis.Get(ctx, fmt.Sprintf("stats:cost:%s", date)).Float64()
 totalCalls += calls
 totalCost += cost
 }

 savedHours := float64(totalCalls) * 0.5 // 每次节省 30 分钟
 totalCostYuan := totalCost / 100 // 分 → 元

 return &ROIResult{
 TotalCalls: totalCalls,
 SavedHours: savedHours,
 TotalCostYuan: totalCostYuan,
 ROI: savedHours / totalCostYuan * 100, // 百分比
 }
}

```



```
 }, nil
}
```

13.5 Redis 持久化配置

```
redis.conf - 必须同时开启 AOF + RDB

save 900 1

save 300 10

save 60 10000

appendonly yes


appendfsync everysec
```


**数据可靠性:** AOF + RDB 双持久化确保统计数据不会因 Redis 重启丢失。Scheduler 写入采用 Pipeline 批量操作，5 分钟窗口内的少量数据丢失可接受。

16. 异步任务与消息队列

13.1 Redis Stream 作为轻量消息队列

**Worker 职责定义:** Worker 是异步任务消费者，运行在 Go 服务进程的独立 goroutine 中。核心职责：从 Redis Stream 消费异步 Agent 任务和定时任务，回调 Agent Service 执行 Agent Engine 核心逻辑。Worker 纯 Go 实现，不依赖 Python/R 等外部运行时。





## Worker 实现:

```

// Worker 职责 (纯 Go, 不依赖外部脚本运行时) :
// 从 Redis Stream 消费异步 Agent 任务 → 回调 Agent Service 执行核心逻辑

type AgentWorker struct {
 redis *RedisClient
 agentSvc *AgentService // 回调 Agent Service
 notifier *Notifier
}

func (w *AgentWorker) Run(ctx context.Context, workerID string) {
 for {

```

```

// 从 Redis Stream 消费任务

msgs, err := w.redis.XReadGroup(ctx, &redis.XReadGroupArgs{
 Group: "agent_workers",
 Consumer: workerID,
 Streams: []string{"agent:tasks", ">"},
 Count: 1,
 Block: 5 * time.Second,
})

if err != nil || len(msgs) == 0 {
 continue
}

for _, msg := range msgs[0].Messages {
 taskID := msg.Values["task_id"].(string)
 w.processTask(ctx, taskID)
 w.redis.XAck(ctx, "agent:tasks", "agent_workers", msg.ID)
}
}

func (w *AgentWorker) processTask(ctx context.Context, taskID string) {
 task := w.loadTask(taskID)

 // 创建可取消的 context
 taskCtx, cancel := context.WithCancel(ctx)
 w.registerCancelHandler(taskID, cancel)
 defer cancel()

 // 更新状态
 w.updateTaskStatus(taskID, "running")

 // 回调 Agent Service 执行核心逻辑
 // Worker 不持有 Agent Engine, 完全复用 Agent Service
 result, err := w.agentSvc.ExecuteTask(taskCtx, task)

 if taskCtx.Err() == context.Canceled {
 w.updateTaskStatus(taskID, "cancelled")
 return
 }
}

```

```
 if err != nil {
 w.updateTaskStatus(taskID, "failed")
 w.notifier.NotifyFailure(task.UserID, taskID, err)
 return
 }

 // 保存结果
 w.saveResult(taskID, result)
 w.updateTaskStatus(taskID, "completed")
 w.notifier.NotifyCompletion(task.UserID, taskID)
}
```

## 17. Hermes Service（自由探索模式）


### 17.1 设计原则

Hermes Service 是 Data Agent 系统中的一个**轻量独立服务**，专用于"自由探索模式"。它遵循以下原则：

原则	说明
接口隔离	与 Agent Service 完全解耦，互不依赖
转发模式	不做任何 LLM 逻辑处理，仅做请求转发和输入/输出记录
Session 双轨	Hermes Session 由 Hermes 端管理；Data Agent 仅保存轻量上下文快照
共享 MongoDB	仅共享 MongoDB 连接用于 <code>hermes_sessions</code> 集合写入
独立部署	Docker Compose 中独立容器，可独立扩缩

### 17.2 架构示意





### 17.3 MongoDB `hermes_sessions` 集合

```

{
 "_id": "ObjectId",
 "session_id": "hermes-session-abcl23",
 "user_id": "user_zhangsan",
 "conversation_name": "探索-2026-07-03-001",
 "messages": [
 {
 "role": "user",
 "content": "帮我分析以太坊最近的价格趋势",
 "timestamp": "2026-07-03T10:30:00Z"
 },
 {
 "role": "assistant",

```

```
 "content": "根据最近数据...",
 "tool_calls": ["web_search"],
 "timestamp": "2026-07-03T10:30:15Z"
 }
],
 "hermes_session_id": "hermes://20260703_103000_a1b2c3",
 "platform": "api-server",
 "started_at": "2026-07-03T10:30:00Z",
 "ended_at": null,
 "token_count_input": 1240,
 "token_count_output": 850,
 "status": "active"
}
```

索引设计:

```
hermes_sessions:
 - {user_id: 1, started_at: -1} # 用户按时间查询
 - {session_id: 1} # 唯一查找
 - {status: 1, started_at: -1} # 活跃会话筛选
```

17.4 API 端点

方法	路径	说明
POST	/api/hermes/chat	探索模式对话: 接收 {input, conversation?} → 转发 Hermes → SSE 流式返回
GET	/api/hermes/sessions	列出当前用户的 Hermes Session 记录 (从 MongoDB 读取)
GET	/api/hermes/sessions/{id}	获取指定 Session 的上下文快照
DELETE	/api/hermes/sessions/{id}	删除 Session 记录 (仅删 MongoDB 快照, 不删 Hermes 端)

17.5 Docker Compose 集成

```
docker-compose.prod.yml / docker-compose.test.yml 新增

services:
 # =====
```

```
Hermes Service

=====

hermes-service:

 build:

 context: ./hermes-service

 dockerfile: Dockerfile

 container_name: hermes-service

 ports:

 - "${HERMES_PORT:-8088}:8088"

 environment:

 HERMES_API_URL: ${HERMES_API_URL:-http://hermes:8642}

 HERMES_API_KEY: ${HERMES_API_KEY:-}

 MONGO_URI: mongodb://mongodb:27017

 MONGO_DB: dataagent

 LOG_LEVEL: info

 depends_on:

 mongodb:

 condition: service_healthy

 hermes:

 condition: service_healthy

 restart: unless-stopped

 healthcheck:

 test: ["CMD", "wget", "-q", "-O-", "http://localhost:8088/health"]

 interval: 30s

 timeout: 5s

 retries: 3

Hermes Agent (官方镜像/自部署)

hermes:

 image: ghcr.io/nousresearch/hermes-agent:latest

 container_name: hermes-agent

 ports:

 - "${HERMES_PORT_INTERNAL:-8642}:8642"

 environment:

 API_SERVER_ENABLED: "true"

 API_SERVER_PORT: "8642"

 API_SERVER_HOST: "0.0.0.0"

 API_SERVER_KEY: ${HERMES_API_KEY:-}

 LLM_PROVIDER: ${HERMES_LLM_PROVIDER:-openai}
```

```
LLM_API_KEY: ${HERMES_LLM_API_KEY:-}

LLM_MODEL: ${HERMES_LLM_MODEL:-gpt-4o}

volumes:

 - hermes_data:/root/.hermes

restart: unless-stopped

healthcheck:

 test: ["CMD", "wget", "-q", "-O-", "http://localhost:8642/health"]

 interval: 30s

 timeout: 5s

 retries: 3

volumes:

 hermes_data:
```

## 17.6 环境变量

```
.env.prod / .env.test 新增

Hermes Service
HERMES_PORT=8088
HERMES_API_URL=http://hermes:8642
HERMES_API_KEY=hermes-api-key-change-me

Hermes Agent
HERMES_PORT_INTERNAL=8642
HERMES_LLM_PROVIDER=openai
HERMES_LLM_API_KEY=sk-your-llm-key
HERMES_LLM_MODEL=gpt-4o
```

## 17.7 关键约束

1. **Session 不互通**: Hermes Session 与 Data Agent Session 完全隔离，不交叉引用。探索模式下无法访问 Data Agent 的工具/知识库/MCP。
2. **仅代理转发**: Hermes Service 不对 Hermes 的请求/响应做任何解释、转换或增强。它仅做透传 + 记录。
3. **数据最小化**: MongoDB 中仅存储输入/输出摘要 + 元数据，不存储完整工具结果。
4. **无状态服务**: Hermes Service 本身无状态，可水平扩展多副本。
5. **单向依赖**: hermes-service → hermes 容器，hermes 崩溃时 hermes-service 返回 503。




## 17.8 IM 集成架构 (IM 模块，集成在主二进制)


### 17.8.1 设计目标

IM 模块集成在 Data Agent 主二进制中 ( `internal/service/im/` ), 负责统一管理企业 IM 平台的消息收发。遵循以下原则:

- **适用范围:** IM 渠道仅服务于轻量办公模式 (Chat), 不接入 Agent 批量任务模式和 Hermes 自由探索模式
- **集成部署:** IM 模块与 Agent Service 在同一进程中运行, 通过内部调用通信, 不单独部署
- **平台适配:** 每个 IM 平台 (飞书/钉钉/企微) 有独立的适配器, 共享消息路由和用户绑定逻辑
- **消息路由:** IM 消息 → Agent Service Chat API (内部调用) → IM 返回 (复用现有 Chat 能力)
- **MVP 策略:** 优先实现飞书适配器, 架构预留钉钉/企微扩展点

### 17.8.2 飞书集成流程





17.8.3 核心数据结构

用户绑定 (im\_bindings):

```
// im_bindings collection - MongoDB
{
 "_id": "imb_feishu_ou_abc123",
 "platform": "feishu", // feishu | dingtalk | wecom
 "open_id": "ou_abc123def456", // IM 平台的用户唯一标识
 "user_id": "user_001", // 系统用户 ID
 "tenant_key": "2ed263bf32cf1651", // 飞书企业标识 (多租户隔离)
 "nickname": "张三", // IM 昵称 (冗余, 方便展示)
```

```

 "avatar_url": "https://...", // IM 头像 (冗余)

 "created_at": "2026-07-01T10:00:00Z",

 "updated_at": "2026-07-01T10:00:00Z"

}

// 唯一索引: {platform: 1, open_id: 1, tenant_key: 1}

```

### 飞书卡片消息模板:

```

// internal/im/feishu/card.go

// BuildAnalysisResultCard 分析结果 → 飞书卡片消息 JSON
func BuildAnalysisResultCard(result *chat.ChatResult) *lark.MsgContent {
 card := &lark.MsgContent{
 Config: &lark.CardConfig{WideScreenMode: true},
 Header: &lark.CardHeader{
 Title: &lark.Text{Tag: "plain_text", Content: "📊 数据分析结果"},
 Template: "blue",
 },
 Elements: []lark.CardElement{
 // 关键指标摘要
 buildMetricsElement(result.Metrics),
 // 数据表格
 buildTableElement(result.Data),
 // 图表链接 (跳转 Web 查看完整图表)
 buildChartLink(result.ChartURL),
 // 操作按钮
 buildActionButtons(result),
 },
 }
 return card
}

```

## 17.8.4 IM 模块结构

```

internal/service/im/
├── gateway.go # IM 模块主入口 (HTTP 路由注册, 集成在主二进制)
├── router.go # 消息路由器 (平台适配 → Agent Service 内部调用)
├── binding.go # 用户绑定管理 (CRUD + 缓存)
├── command.go # 快捷指令解析

```

```

├─ formatter.go # 消息格式化 (Agent 响应 → IM 消息格式)
├─ audit.go # IM 消息审计日志
|
├─ feishu/ # 飞书平台适配器
| ├─ adapter.go # 飞书适配器实现 (im.PlatformAdapter 接口)
| ├─ webhook.go # Webhook 接收 + 签名验证 + 消息解密
| ├─ message.go # 消息发送 (文本/卡片/图片)
| ├─ card.go # 卡片消息模板 (分析结果/通知/引导)
| └─ event.go # 事件订阅 (消息事件/用户事件)
|
├─ dingtalk/ # 钉钉平台适配器 (v1.1)
| └─ adapter.go
|
└─ wecom/ # 企业微信平台适配器 (v1.1)
 └─ adapter.go

```

### 平台适配器接口:

```

// internal/service/im/gateway.go

// PlatformAdapter 定义 IM 平台适配器接口
type PlatformAdapter interface {
 // Platform 返回平台标识
 Platform() string // "feishu" | "dingtalk" | "wecom"

 // HandleWebhook 处理 IM 平台的 Webhook 回调
 HandleWebhook(ctx context.Context, req *http.Request) (*IMMessage, error)

 // SendMessage 发送消息到 IM 平台
 SendMessage(ctx context.Context, openID string, content *MessageContent) error

 // GetUserInfo 获取 IM 用户信息 (用于绑定引导)
 GetUserInfo(ctx context.Context, openID string) (*IMUserInfo, error)

 // VerifySignature 验证 Webhook 签名
 VerifySignature(req *http.Request, body []byte) error
}

// IMMessage 标准化 IM 消息

```

```

type IMessage struct {
 Platform string // feishu
 OpenID string // IM 用户 ID
 TenantKey string // 企业标识
 ChatID string // 群聊 ID (私聊为空)
 ChatType string // private | group
 Text string // 消息文本 (去除 @机器人 前缀)
 RawData json.RawMessage // 平台原始消息
 Timestamp time.Time
}

// MessageContent 标准化消息内容
type MessageContent struct {
 Text string // 纯文本
 Card *CardDefinition // 卡片消息 (可选)
 QuickReplies []string // 快捷回复按钮
}

```

### 17.8.5 飞书 SDK 集成 (go-lark)

```

// go-lark/lark SDK - 消息 Bot 初始化

import "github.com/go-lark/lark"

func NewFeishuAdapter(cfg *FeishuConfig) (*FeishuAdapter, error) {
 bot := lark.NewChatBot(
 cfg.AppID,
 cfg.AppSecret,
 lark.WithVerificationToken(cfg.VerificationToken),
 lark.WithEncryptKey(cfg.EncryptKey),
)

 // 注册消息处理器
 bot.OnTextMessage(func(ctx context.Context, msg *lark.TextMsg) error {
 return handleTextMessage(ctx, msg)
 })

 // 启动事件订阅服务

```

```

 go bot.StartEventSvr(cfg.EventPort)

 return &FeishuAdapter{bot: bot, cfg: cfg}, nil
}

// 发送文本消息
func (a *FeishuAdapter) SendText(ctx context.Context, openID, text string) error {
 msg := lark.NewMsgBuffer(lark.MsgText)
 msg.BindChatter(openID, lark.UserChatterType)
 msg.Text(text)
 return a.bot.Send(msg.Build())
}

// 发送卡片消息
func (a *FeishuAdapter) SendCard(ctx context.Context, openID string, card *CardDefinition)
error {
 msg := lark.NewMsgBuffer(lark.MsgInteractive)
 msg.BindChatter(openID, lark.UserChatterType)
 msg.Card(card.ToFeishuJSON())
 return a.bot.Send(msg.Build())
}

```

## 17.8.6 用户绑定流程

首次使用机器人

|

▼

用户 @机器人 或 私聊任意消息

|

▼

IM 模块查询 im\_bindings

|

└─ 已绑定 → 识别 user\_id → 正常处理消息

|

└─ 未绑定 → 返回绑定引导卡片

|

▼

卡片内容:



绑定 Token 设计:

```
// 一次性绑定 Token, 5 分钟过期
type BindToken struct {
 Token string `bson:"_id"`
 Platform string `bson:"platform"`
 OpenID string `bson:"open_id"`
 TenantKey string `bson:"tenant_key"`
 ExpiresAt time.Time `bson:"expires_at"` // TTL 索引自动清理
 CreatedAt time.Time `bson:"created_at"`
}
```

17.8.7 快捷指令

指令	功能	映射
/分析 <query>	发起数据分析	→ Agent Service Chat API (mode: chat)
/查询 <query>	快速数据查询	→ Agent Service Chat API (mode: chat, cache_first)
/周报	生成本周经营周报	→ Agent Service Chat API (预设 prompt)
/帮助	查看可用指令和说明	→ 本地静态回复

### 17.8.8 集成说明

IM 模块（`internal/service/im/`）编译在主二进制内，无需独立 Docker Compose 容器。飞书 Webhook 端口复用主服务的 HTTP Server（通过 `GET/POST /api/v1/im/feishu/*` 路由注册）。

主服务 `docker-compose.yml` 中只需增加飞书环境变量：

```
docker-compose.yml agent-service 内新增

environment:

 FEISHU_APP_ID: ${FEISHU_APP_ID:-}

 FEISHU_APP_SECRET: ${FEISHU_APP_SECRET:-}

 FEISHU_VERIFICATION_TOKEN: ${FEISHU_VERIFICATION_TOKEN:-}

 FEISHU_ENCRYPT_KEY: ${FEISHU_ENCRYPT_KEY:-}
```

### 17.8.9 环境变量

```
飞书配置（主服务 .env 新增）

FEISHU_APP_ID=cli_XXXXXXXXXXXXX

FEISHU_APP_SECRET=XXXXXXXXXXXXXXXXXXXXXXXXXXXXX

FEISHU_VERIFICATION_TOKEN=XXXXXXXXXXXXXXXXXXXXX

FEISHU_ENCRYPT_KEY=XXXXXXXXXXXXXXXXXXXXXXXXXXXXX
```

### 17.8.10 关键约束

1. **仅限轻量办公模式**: IM 渠道仅接入 Agent Service Chat API（同步即时对话），不支持 Agent 异步批量任务和 Hermes 自由探索模式。
2. **消息转发不变形**: IM 模块不修改用户消息内容，仅做 @机器人 前缀去除和平台差异处理。
3. **用户绑定必做**: 未绑定用户的所有消息返回绑定引导，不进入处理流程。
4. **审计日志记录**: 所有 IM 消息（入/出）记录审计日志，`source: "feishu_bot"`，包含 open\_id、user\_id、消息内容摘要。
5. **复用 Chat 模式**: IM 渠道复用现有 Agent Service Chat API，不创建独立的推理管道。
6. **平台适配器模式**: 每个 IM 平台实现 `PlatformAdapter` 接口，核心路由逻辑不变。
7. **集成部署**: IM 模块与主服务编译在同一二进制，共享 MongoDB/Redis 连接池，IM 会话上下文由 Agent Service 统一管理。




17.8.11 V1.1 扩展规划


平台	新增组件	复用部分
钉钉	<code>dingtalk/adapter.go</code>	消息路由、用户绑定、结果格式化
企业微信	<code>wecom/adapter.go</code>	同上
交互式卡片	飞书/钉钉卡片 Action 处理	快捷指令解析
消息模板管理	MongoDB <code>im_templates</code> + Admin UI	-

18. 部署架构

14.1 生产部署拓扑

**部署形态:** Service Layer 为单个 Go 二进制文件，API Server、Worker、Scheduler 均在同一进程中通过 goroutine 运行。通过 Kubernetes Deployment 水平扩展多个副本，各副本共享 Redis 协调任务分配。





**Vault 职责:** Go Service 启动时从 Vault 拉取 JWT Secret、MongoDB 密码、SeaweedFS Access Key、SMTP 密码、LLM API Key 等敏感配置。支持配置热更新 (Vault lease renewal)。开发环境可用文件模式 ( `vault agent -mode=dev` ) 替代。

17.2 MVP 一键部署 (Docker Compose)

MVP 提供**两套** Docker Compose 配置，按场景区分：

文件	用途	包含服务
<code>docker-compose.prod.yml</code>	正式部署 / Demo	api, frontend, mongodb, milvus, seaweedfs, redis, vault, mem0
<code>docker-compose.test.yml</code>	本地开发 / 自动化测试	prod 全部 + LLM Mock (内置于 api 容器) + MySQL (模拟客户数据库) + <b>migration</b> (初始化企业测试数据)

两套配置可通过环境变量灵活切换 LLM 指向 (真实 LLM 或 Mock)，无需修改 compose 文件。

17.2.1 正式部署环境变量 (.env.prod)

正式部署所需的环境变量，复制为 `.env` 后使用：

```
=====
服务端口
=====
API_PORT=8080
FRONTEND_PORT=3000

=====
MongoDB
```

```
=====

MONGO_IMAGE=mongo:7.0
MONGO_PORT=27017
MONGO_ROOT_USER=admin
MONGO_ROOT_PASSWORD=changeme
MONGO_DATABASE=agent_platform

=====

Milvus (Standalone)
=====

MILVUS_IMAGE=milvusdb/milvus:v2.5.0
MILVUS_PORT=19530
MILVUS_METRICS_PORT=9091

=====

SeaweedFS (S3)
=====

SEAWEEDFS_IMAGE=chrislusf/seaweedfs:latest
SEAWEEDFS_S3_PORT=8333
SEAWEEDFS_ACCESS_KEY=seaweedfs-admin
SEAWEEDFS_SECRET_KEY=seaweedfs-admin

=====

Redis
=====

REDIS_IMAGE=redis:7.2-alpine
REDIS_PORT=6379
REDIS_PASSWORD=

=====

Vault (Dev Mode)
=====

VAULT_IMAGE=hashicorp/vault:1.14
VAULT_PORT=8200
VAULT_DEV_ROOT_TOKEN=dev-root-token

=====

Mem0
=====
```

```
MEMO_IMAGE=mem0ai/mem0:latest
MEMO_PORT=8000

=====
LLM
=====
LLM_PROVIDER=openai
LLM_MODEL=gpt-4o
LLM_BASE_URL=https://api.openai.com/v1
LLM_API_KEY=sk-your-key-here
LLM_MAX_TOKENS=8192
LLM_TEMPERATURE=0.1

=====
Embedding
=====
EMBEDDING_PROVIDER=openai
EMBEDDING_MODEL=text-embedding-3-small
EMBEDDING_DIM=1536

=====
JWT & Security
=====
JWT_SECRET=change-me-to-a-random-string
JWT_EXPIRE_HOURS=24

=====
Email (SMTP)
=====
SMTP_HOST=smtp.company.com
SMTP_PORT=587
SMTP_USER=noreply@company.com
SMTP_PASSWORD=
SMTP_ALLOWED_DOMAINS=company.com

=====
Report Validator
=====
REPORT_VALIDATOR_MAX_RETRIES=3
```

## 17.2.2 正式部署一键启动

```
1. 复制环境变量文件
cp .env.prod .env

2. 编辑 .env (至少修改 LLM_API_KEY、JWT_SECRET)
vim .env

3. 一键启动全部服务 (使用正式 compose 文件)
docker compose -f docker-compose.prod.yml up -d

4. 查看日志
docker compose -f docker-compose.prod.yml logs -f api

5. 访问
前端: http://localhost:3000
管理后台: http://localhost:3000/admin
API: http://localhost:8080
```

## 17.2.3 docker-compose.prod.yml (正式部署)

```
version: '3.8'

services:
 # =====
 # Go API Service (含 Agent Service + Worker Pool + Scheduler)
 # =====
 api:
 build:
 context: .
 dockerfile: Dockerfile
 container_name: agent-api
 ports:
 - "${API_PORT:-8080}:8080"
 environment:
 # MongoDB
 MONGO_URI:
 mongodb://${MONGO_ROOT_USER}:${MONGO_ROOT_PASSWORD}@mongodb:${MONGO_PORT:-27017}/${MONGO_DATABASE:-agent_platform}?authSource=admin
```

```
Redis

REDIS_ADDR: redis:${REDIS_PORT:-6379}

REDIS_PASSWORD: ${REDIS_PASSWORD:-}

SeaweedFS (S3)

SEAWEEDFS_ENDPOINT: seaweedfs:${SEAWEEDFS_S3_PORT:-8333}

SEAWEEDFS_ACCESS_KEY: ${SEAWEEDFS_ACCESS_KEY:-seaweedfs-admin}

SEAWEEDFS_SECRET_KEY: ${SEAWEEDFS_SECRET_KEY:-seaweedfs-admin}

SEAWEEDFS_WORKSPACE_VOLUME: workspaces

SEAWEEDFS_ARTIFACT_VOLUME: artifacts

Milvus

MILVUS_ADDR: milvus:${MILVUS_PORT:-19530}

Mem0

MEM0_ADDR: mem0:${MEM0_PORT:-8000}

Vault

VAULT_ADDR: http://vault:${VAULT_PORT:-8200}

VAULT_TOKEN: ${VAULT_DEV_ROOT_TOKEN:-dev-root-token}

LLM

LLM_PROVIDER: ${LLM_PROVIDER:-openai}

LLM_MODEL: ${LLM_MODEL:-gpt-4o}

LLM_BASE_URL: ${LLM_BASE_URL:-https://api.openai.com/v1}

LLM_API_KEY: ${LLM_API_KEY}

LLM_MAX_TOKENS: ${LLM_MAX_TOKENS:-8192}

LLM_TEMPERATURE: ${LLM_TEMPERATURE:-0.1}

Embedding

EMBEDDING_PROVIDER: ${EMBEDDING_PROVIDER:-openai}

EMBEDDING_MODEL: ${EMBEDDING_MODEL:-text-embedding-3-small}

EMBEDDING_DIM: ${EMBEDDING_DIM:-1536}

JWT

JWT_SECRET: ${JWT_SECRET}

JWT_EXPIRE_HOURS: ${JWT_EXPIRE_HOURS:-24}

Email

SMTP_HOST: ${SMTP_HOST}

SMTP_PORT: ${SMTP_PORT:-587}

SMTP_USER: ${SMTP_USER}

SMTP_PASSWORD: ${SMTP_PASSWORD:-}

SMTP_ALLOWED_DOMAINS: ${SMTP_ALLOWED_DOMAINS:-company.com}

Report Validator

REPORT_VALIDATOR_MAX_RETRIES: ${REPORT_VALIDATOR_MAX_RETRIES:-3}

Workspace
```

```

 WORKSPACE_ROOT: ${WORKSPACE_ROOT:-/workspaces}

 WORKSPACE_MAX_SIZE_MB: ${WORKSPACE_MAX_SIZE_MB:-500}
volumes:
 - workspace_data:/workspaces
depends_on:
 mongodb:
 condition: service_healthy
 redis:
 condition: service_healthy
 seaweedfs:
 condition: service_healthy
 milvus:
 condition: service_healthy
restart: unless-stopped
healthcheck:
 test: ["CMD", "curl", "-f", "http://localhost:8080/health"]
 interval: 15s
 timeout: 5s
 retries: 3
 start_period: 30s

=====
Next.js Frontend (含用户端 + 管理后台)
=====

frontend:
 build:
 context: ./web
 dockerfile: Dockerfile
 container_name: agent-frontend
 ports:
 - "${FRONTEND_PORT:-3000}:3000"
 environment:
 NEXT_PUBLIC_API_URL: http://localhost:${API_PORT:-8080}
 API_INTERNAL_URL: http://api:8080
 depends_on:
 api:
 condition: service_healthy
 restart: unless-stopped

```

```

=====
MongoDB
=====

mongodb:

 image: ${MONGO_IMAGE:-mongo:7.0}

 container_name: agent-mongodb

 ports:

 - "${MONGO_PORT:-27017}:27017"

 environment:

 MONGO_INITDB_ROOT_USERNAME: ${MONGO_ROOT_USER:-admin}

 MONGO_INITDB_ROOT_PASSWORD: ${MONGO_ROOT_PASSWORD:-changeme}

 volumes:

 - mongo_data:/data/db

 healthcheck:

 test: ["CMD", "mongosh", "--eval", "db.adminCommand('ping')"]

 interval: 10s

 timeout: 5s

 retries: 5

 start_period: 20s

 restart: unless-stopped

=====
Milvus (Standalone - 无需 etcd/minio 依赖)
=====

milvus:

 image: ${MILVUS_IMAGE:-milvusdb/milvus:v2.5.0}

 container_name: agent-milvus

 ports:

 - "${MILVUS_PORT:-19530}:19530"

 - "${MILVUS_METRICS_PORT:-9091}:9091"

 environment:

 ETCD_USE_EMBED: "true"

 COMMON_STORAGE_TYPE: local

 volumes:

 - milvus_data:/var/lib/milvus

 healthcheck:

 test: ["CMD", "curl", "-f", "http://localhost:9091/healthz"]

 interval: 15s

 timeout: 10s

```



```

 retries: 5

 start_period: 40s

restart: unless-stopped

=====
SeaweedFS (S3)
=====

seaweedfs:
 image: ${SEAWEEDFS_IMAGE:-chrislusf/seaweedfs:latest}
 container_name: agent-seaweedfs
 ports:
 - "${SEAWEEDFS_S3_PORT:-8333}:8333"
 command: server -s3 -s3.accessKey=${SEAWEEDFS_ACCESS_KEY:-seaweedfs-admin} -
s3.secretKey=${SEAWEEDFS_SECRET_KEY:-seaweedfs-admin}
 volumes:
 - seaweedfs_data:/data
 healthcheck:
 test: ["CMD", "curl", "-f", "http://localhost:8333/"]
 interval: 10s
 timeout: 5s
 retries: 5
 start_period: 10s
 restart: unless-stopped

=====
Redis
=====

redis:
 image: ${REDIS_IMAGE:-redis:7.2-alpine}
 container_name: agent-redis
 ports:
 - "${REDIS_PORT:-6379}:6379"
 command: ${REDIS_PASSWORD:+redis-server --requirepass ${REDIS_PASSWORD}}
 volumes:
 - redis_data:/data
 healthcheck:
 test: ["CMD", "redis-cli", "ping"]
 interval: 10s
 timeout: 3s

```

```

 retries: 5

restart: unless-stopped

=====
Vault (Dev Mode - MVP 快速启动)
=====

vault:
 image: ${VAULT_IMAGE:-hashicorp/vault:1.14}
 container_name: agent-vault
 ports:
 - "${VAULT_PORT:-8200}:8200"
 cap_add:
 - IPC_LOCK
 environment:
 VAULT_DEV_ROOT_TOKEN_ID: ${VAULT_DEV_ROOT_TOKEN:-dev-root-token}
 VAULT_DEV_LISTEN_ADDRESS: 0.0.0.0:${VAULT_PORT:-8200}
 healthcheck:
 test: ["CMD", "vault", "status"]
 interval: 10s
 timeout: 5s
 retries: 5
 start_period: 10s
 restart: unless-stopped

=====
Mem0
=====

mem0:
 image: ${MEM0_IMAGE:-mem0ai/mem0:latest}
 container_name: agent-mem0
 ports:
 - "${MEM0_PORT:-8000}:8000"
 restart: unless-stopped

=====
Volumes (持久化存储)
=====

volumes:
 mongo_data:

```

```
milvus_data:

seaweedfs_data:

redis_data:

workspace_data:
```

#### 17.2.4 Go Service Dockerfile（多阶段构建，安全加固）

```
===== Stage 1: Build =====

FROM golang:1.22-alpine AS builder

WORKDIR /app

安装依赖（利用 Docker 缓存层）

COPY go.mod go.sum ./

RUN go mod download

编译

COPY . .

RUN CGO_ENABLED=0 GOOS=linux go build -ldflags="-s -w" -o /app/server ./cmd/server

===== Stage 2: Runtime（安全加固）=====

FROM alpine:3.20

最小化依赖

RUN apk add --no-cache ca-certificates curl tzdata bash

创建非 root 用户

RUN addgroup -S appgroup && adduser -S appuser -G appgroup

工作空间根目录 - appuser 唯一可读、写、执行的目录

RUN mkdir -p /workspaces && chown appuser:appgroup /workspaces && chmod 750 /workspaces

WORKDIR /app

复制二进制及配置（属 root:root）

COPY --from=builder /app/server .

COPY --from=builder /app/configs/ ./configs/

COPY --from=builder /app/skills/ ./skills/
```

```
限制 /app 目录: appuser 只能读和执行 (755), 不能写入
/app/server 需要 x 权限供容器启动执行; configs/skills 仅需 r
RUN chown -R root:root /app && chmod -R 755 /app

运行时以 appuser 执行 - 仅有 /workspaces 具备写+执行权限
其他路径 (/app、/usr 等) 仅有必要的读和系统级执行权限
USER appuser

EXPOSE 8080

HEALTHCHECK --interval=15s --timeout=5s --retries=3 \
 CMD curl -f http://localhost:8080/health || exit 1

ENTRYPOINT ["/server"]
```

### 17.2.5 正式部署启动后验证

```
检查所有服务健康状态
docker compose -f docker-compose.prod.yml ps

预期输出 - 全部 healthy
NAME STATUS
agent-api Up (healthy)
agent-frontend Up
agent-mongodb Up (healthy)
agent-milvus Up (healthy)
agent-seaweedfs Up (healthy)
agent-redis Up (healthy)
agent-vault Up (healthy)
agent-mem0 Up

API 健康检查
curl http://localhost:8080/health
#
{"status":"ok","mongodb":"connected","redis":"connected","milvus":"connected","seaweedfs":"connected"}
```

```
前端访问
open http://localhost:3000
```

## 17.3 测试部署 (docker-compose.test.yml)

测试部署在正式部署的基础上增加： - **LLM Mock**：内置于 api 容器，通过 `LLM_BASE_URL=http://localhost:8080/mock/v1` 启用 - **MySQL**：模拟客户企业数据库，预置企业运营数据 - **Migration 服务**：启动时自动执行 SQL 初始化脚本，写入模拟企业数据

### 17.3.1 测试环境变量 (.env.test)

```
=====
基础配置 (继承 prod 环境变量)
=====
从 .env.prod 复制基础配置，追加/覆盖以下测试专用变量

=====
环境标识
=====
APP_ENV=test

=====
LLM → 指向内置 Mock
=====
LLM_BASE_URL=http://localhost:8080/mock/v1
LLM_API_KEY=mock-key
LLM_PROVIDER=openai
LLM_MODEL=mock-llm
LLM_MAX_TOKENS=4096
LLM_TEMPERATURE=0

=====
Embedding (仍需真实服务生成向量)
=====
EMBEDDING_PROVIDER=openai
EMBEDDING_MODEL=text-embedding-3-small
EMBEDDING_DIM=1536
```

```

=====

Mock LLM 参数

=====

MOCK_CHUNK_DELAY_MS=0

MOCK_DEFAULT_REPLY=Mock LLM: 请通过 POST /mock/responses 注入测试响应

=====

LOG - 测试环境开启 DEBUG

=====

LOG_LEVEL=debug

LOG_FORMAT=console

=====

MySQL (模拟客户企业数据库)

=====

MYSQL_IMAGE=mysql:8.0

MYSQL_PORT=3306

MYSQL_ROOT_PASSWORD=dev-root-password

MYSQL_DATABASE=enterprise_demo

MYSQL_USER=demo_user

MYSQL_PASSWORD=demo_password

=====

API Service 环境变量 (连接 MySQL)

=====

测试数据源连接 (SQL Executor 使用)

TEST_DATASOURCE_NAME=enterprise_demo

TEST_DATASOURCE_TYPE=mysql

TEST_DATASOURCE_DSN=demo_user:demo_password@tcp(mysql:3306)/enterprise_demo?

charset=utf8mb4&parseTime=true

=====

Workspace (本地目录挂载, 供 Skill 脚本执行)

=====

WORKSPACE_ROOT=/workspaces

WORKSPACE_MAX_SIZE_MB=500 # 单 session workspace 上限

WORKSPACE_CLEANUP_ON_STOP=true # compose down 时自动清理

```

### 17.3.2 docker-compose.test.yml (完整)

```

version: '3.8'

services:
 # =====
 # Go API Service (含 Agent Service + Worker Pool + Scheduler + Mock LLM)
 # =====
 api:
 build:
 context: .
 dockerfile: Dockerfile
 container_name: agent-api
 ports:
 - "${API_PORT:-8080}:8080"
 environment:
 APP_ENV: ${APP_ENV:-test}
 LOG_LEVEL: ${LOG_LEVEL:-debug}
 LOG_FORMAT: ${LOG_FORMAT:-console}
 # MongoDB
 MONGO_URI:
 mongodb://${MONGO_ROOT_USER}:${MONGO_ROOT_PASSWORD}@mongodb:${MONGO_PORT:-27017}/${MONGO_DATABASE:-agent_platform}?authSource=admin
 # Redis
 REDIS_ADDR: redis:${REDIS_PORT:-6379}
 REDIS_PASSWORD: ${REDIS_PASSWORD:-}
 # SeaweedFS (S3)
 SEAWEEDFS_ENDPOINT: seaweedfs:${SEAWEEDFS_S3_PORT:-8333}
 SEAWEEDFS_ACCESS_KEY: ${SEAWEEDFS_ACCESS_KEY:-seaweedfs-admin}
 SEAWEEDFS_SECRET_KEY: ${SEAWEEDFS_SECRET_KEY:-seaweedfs-admin}
 SEAWEEDFS_WORKSPACE_VOLUME: workspaces
 SEAWEEDFS_ARTIFACT_VOLUME: artifacts
 # Milvus
 MILVUS_ADDR: milvus:${MILVUS_PORT:-19530}
 # Mem0
 MEM0_ADDR: mem0:${MEM0_PORT:-8000}
 # Vault
 VAULT_ADDR: http://vault:${VAULT_PORT:-8200}
 VAULT_TOKEN: ${VAULT_DEV_ROOT_TOKEN:-dev-root-token}

```

```

LLM → 指向内置 Mock

LLM_PROVIDER: ${LLM_PROVIDER:-openai}

LLM_MODEL: ${LLM_MODEL:-mock-llm}

LLM_BASE_URL: ${LLM_BASE_URL:-http://localhost:8080/mock/v1}

LLM_API_KEY: ${LLM_API_KEY:-mock-key}

LLM_MAX_TOKENS: ${LLM_MAX_TOKENS:-4096}

LLM_TEMPERATURE: ${LLM_TEMPERATURE:-0}

Embedding (仍需真实服务)

EMBEDDING_PROVIDER: ${EMBEDDING_PROVIDER:-openai}

EMBEDDING_MODEL: ${EMBEDDING_MODEL:-text-embedding-3-small}

EMBEDDING_DIM: ${EMBEDDING_DIM:-1536}

JWT

JWT_SECRET: ${JWT_SECRET:-test-secret-do-not-use-in-prod}

JWT_EXPIRE_HOURS: ${JWT_EXPIRE_HOURS:-999}

Workspace

WORKSPACE_ROOT: ${WORKSPACE_ROOT:-/workspaces}

WORKSPACE_MAX_SIZE_MB: ${WORKSPACE_MAX_SIZE_MB:-500}

Mock LLM

MOCK_CHUNK_DELAY_MS: ${MOCK_CHUNK_DELAY_MS:-0}

MOCK_DEFAULT_REPLY: ${MOCK_DEFAULT_REPLY:-Mock LLM: Inject test data via POST
/mock/responses}

SQL 测试数据源

TEST_DATASOURCE_NAME: ${TEST_DATASOURCE_NAME:-enterprise_demo}

TEST_DATASOURCE_TYPE: ${TEST_DATASOURCE_TYPE:-mysql}

TEST_DATASOURCE_DSN: ${TEST_DATASOURCE_DSN:-
demo_user:demo_password@tcp(mysql:3306)/enterprise_demo?charset=utf8mb4&parseTime=true}

volumes:

挂载 workspace 目录到宿主机, 便于测试时查看生成的文件
- workspace_data:/workspaces

depends_on:

mongodb:

 condition: service_healthy

redis:

 condition: service_healthy

seaweedfs:

 condition: service_healthy

milvus:

 condition: service_healthy

mysql:

```



```

 condition: service_healthy
restart: unless-stopped
healthcheck:
 test: ["CMD", "curl", "-f", "http://localhost:8080/health"]
 interval: 15s
 timeout: 5s
 retries: 3
 start_period: 30s

=====
Next.js Frontend (含用户端 + 管理后台)
=====
frontend:
 build:
 context: ./web
 dockerfile: Dockerfile
 container_name: agent-frontend
 ports:
 - "${FRONTEND_PORT:-3000}:3000"
 environment:
 NEXT_PUBLIC_API_URL: http://localhost:${API_PORT:-8080}
 API_INTERNAL_URL: http://api:8080
 depends_on:
 api:
 condition: service_healthy
 restart: unless-stopped

=====
MongoDB
=====
mongodb:
 image: ${MONGO_IMAGE:-mongo:7.0}
 container_name: agent-mongodb
 ports:
 - "${MONGO_PORT:-27017}:27017"
 environment:
 MONGO_INITDB_ROOT_USERNAME: ${MONGO_ROOT_USER:-admin}
 MONGO_INITDB_ROOT_PASSWORD: ${MONGO_ROOT_PASSWORD:-changeme}
 volumes:

```

```

 - mongo_data:/data/db

healthcheck:
 test: ["CMD", "mongosh", "--eval", "db.adminCommand('ping')"]
 interval: 10s
 timeout: 5s
 retries: 5
 start_period: 20s
 restart: unless-stopped

=====
Milvus (Standalone)
=====
milvus:
 image: ${MILVUS_IMAGE:-milvusdb/milvus:v2.5.0}
 container_name: agent-milvus
 ports:
 - "${MILVUS_PORT:-19530}:19530"
 - "${MILVUS_METRICS_PORT:-9091}:9091"
 environment:
 ETCD_USE_EMBED: "true"
 COMMON_STORAGE_TYPE: local
 volumes:
 - milvus_data:/var/lib/milvus
 healthcheck:
 test: ["CMD", "curl", "-f", "http://localhost:9091/healthz"]
 interval: 15s
 timeout: 10s
 retries: 5
 start_period: 40s
 restart: unless-stopped

=====
SeaweedFS (S3)
=====
seaweedfs:
 image: ${SEAWEEDFS_IMAGE:-chrislusf/seaweedfs:latest}
 container_name: agent-seaweedfs
 ports:
 - "${SEAWEEDFS_S3_PORT:-8333}:8333"

```

```

 command: server -s3 -s3.accessKey=${SEAWEEEDFS_ACCESS_KEY:-seaweedfs-admin} -
s3.secretKey=${SEAWEEEDFS_SECRET_KEY:-seaweedfs-admin}
 volumes:
 - seaweedfs_data:/data
 healthcheck:
 test: ["CMD", "curl", "-f", "http://localhost:8333/"]
 interval: 10s
 timeout: 5s
 retries: 5
 start_period: 10s
 restart: unless-stopped

=====
Redis
=====

redis:
 image: ${REDIS_IMAGE:-redis:7.2-alpine}
 container_name: agent-redis
 ports:
 - "${REDIS_PORT:-6379}:6379"
 command: ${REDIS_PASSWORD:+redis-server --requirepass ${REDIS_PASSWORD}}
 volumes:
 - redis_data:/data
 healthcheck:
 test: ["CMD", "redis-cli", "ping"]
 interval: 10s
 timeout: 3s
 retries: 5
 restart: unless-stopped

=====
Vault (Dev Mode)
=====

vault:
 image: ${VAULT_IMAGE:-hashicorp/vault:1.14}
 container_name: agent-vault
 ports:
 - "${VAULT_PORT:-8200}:8200"
 cap_add:

```

```

- IPC_LOCK

environment:

 VAULT_DEV_ROOT_TOKEN_ID: ${VAULT_DEV_ROOT_TOKEN:-dev-root-token}

 VAULT_DEV_LISTEN_ADDRESS: 0.0.0.0:${VAULT_PORT:-8200}

healthcheck:

 test: ["CMD", "vault", "status"]

 interval: 10s

 timeout: 5s

 retries: 5

 start_period: 10s

restart: unless-stopped

=====
Mem0
=====
mem0:

 image: ${MEM0_IMAGE:-mem0ai/mem0:latest}

 container_name: agent-mem0

 ports:

 - "${MEM0_PORT:-8000}:8000"

 restart: unless-stopped

=====
MySQL (模拟客户企业数据库)
=====
mysql:

 image: ${MYSQL_IMAGE:-mysql:8.0}

 container_name: agent-mysql

 ports:

 - "${MYSQL_PORT:-3306}:3306"

 environment:

 MYSQL_ROOT_PASSWORD: ${MYSQL_ROOT_PASSWORD:-dev-root-password}

 MYSQL_DATABASE: ${MYSQL_DATABASE:-enterprise_demo}

 MYSQL_USER: ${MYSQL_USER:-demo_user}

 MYSQL_PASSWORD: ${MYSQL_PASSWORD:-demo_password}

 volumes:

 - mysql_data:/var/lib/mysql

 healthcheck:

 test: ["CMD", "mysqladmin", "ping", "-h", "localhost", "-u", "root", "-

```

```

p${MYSQL_ROOT_PASSWORD:-dev-root-password}]

 interval: 10s
 timeout: 5s
 retries: 10
 start_period: 30s
 restart: unless-stopped

=====
Migration Service (初始化企业测试数据)
=====
migration:
 image: ${MYSQL_IMAGE:-mysql:8.0}
 container_name: agent-migration
 depends_on:
 mysql:
 condition: service_healthy
 entrypoint: ["bash", "-c"]
 command:
 - |
 echo "[Migration] Waiting for MySQL..."
 until mysqladmin ping -h mysql -u root -p${MYSQL_ROOT_PASSWORD:-dev-root-password}
--silent 2>/dev/null; do
 sleep 2
 done
 echo "[Migration] Executing seed SQL..."
 mysql -h mysql -u root -p${MYSQL_ROOT_PASSWORD:-dev-root-password}
${MYSQL_DATABASE:-enterprise_demo} < /seed/init_enterprise_data.sql
 echo "[Migration] Done. Enterprise demo data loaded."

 volumes:
 - ./testdata/migrations:/seed:ro
 restart: "no"

=====
Volumes
=====
volumes:
 mongo_data:
 milvus_data:
 seaweedfs_data:

```

```

redis_data:

mysql_data:

workspace_data:

```

### 17.3.3 测试企业种子数据 (testdata/migrations/init\_enterprise\_data.sql)

```

-- =====
-- 模拟企业数据：电商平台运营数据库
-- 供 SQL Executor Skill 执行查询测试
-- =====

CREATE TABLE IF NOT EXISTS departments (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(64) NOT NULL,
 parent_id INT DEFAULT NULL,
 FOREIGN KEY (parent_id) REFERENCES departments(id)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;

CREATE TABLE IF NOT EXISTS employees (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(32) NOT NULL,
 department_id INT NOT NULL,
 hire_date DATE NOT NULL,
 salary DECIMAL(12,2) NOT NULL DEFAULT 0,
 status ENUM('active','suspended','resigned') DEFAULT 'active',
 FOREIGN KEY (department_id) REFERENCES departments(id)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;

CREATE TABLE IF NOT EXISTS products (
 id INT PRIMARY KEY AUTO_INCREMENT,
 name VARCHAR(128) NOT NULL,
 category VARCHAR(32) NOT NULL,
 unit_price DECIMAL(10,2) NOT NULL,
 cost_price DECIMAL(10,2) NOT NULL,
 stock INT NOT NULL DEFAULT 0,
 created_at DATETIME DEFAULT CURRENT_TIMESTAMP
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;

CREATE TABLE IF NOT EXISTS orders (

```

```

 id INT PRIMARY KEY AUTO_INCREMENT,
 order_no VARCHAR(32) NOT NULL UNIQUE,
 customer_name VARCHAR(64) NOT NULL,
 product_id INT NOT NULL,
 quantity INT NOT NULL,
 unit_price DECIMAL(10,2) NOT NULL,
 total_amount DECIMAL(14,2) NOT NULL,
 status ENUM('pending','paid','shipped','completed','cancelled') DEFAULT 'pending',
 order_date DATE NOT NULL,
 FOREIGN KEY (product_id) REFERENCES products(id)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;

```

```
INSERT INTO departments (id, name, parent_id) VALUES
```

```

(1, '总公司', NULL),
(2, '华东分公司', 1),
(3, '华南分公司', 1),
(4, '华北分公司', 1),
(5, '西南分公司', 1),
(6, '销售部', 2),
(7, '市场部', 2),
(8, '销售部', 3),
(9, '技术部', 3),
(10, '销售部', 4),
(11, '运营部', 4),
(12, '财务部', 1);

```

```
INSERT INTO employees (name, department_id, hire_date, salary, status) VALUES
```

```

('张伟', 6, '2019-03-15', 18000.00, 'active'),
('李娜', 6, '2020-07-01', 16000.00, 'active'),
('王强', 7, '2018-11-20', 22000.00, 'active'),
('赵敏', 8, '2021-01-10', 15500.00, 'active'),
('刘洋', 9, '2017-06-05', 25000.00, 'active'),
('陈静', 10, '2020-09-12', 19000.00, 'active'),
('周涛', 11, '2019-04-28', 21000.00, 'active'),
('孙丽', 12, '2016-08-01', 28000.00, 'active'),
('马超', 6, '2022-02-14', 14000.00, 'active'),
('黄芳', 8, '2021-05-20', 15000.00, 'active');

```

```
INSERT INTO products (id, name, category, unit_price, cost_price, stock) VALUES
```

```
(1, '智能手机 X1', '电子产品', 4999.00, 3500.00, 250),
(2, '笔记本电脑 Pro', '电子产品', 8999.00, 6200.00, 80),
(3, '运动跑鞋', '运动户外', 599.00, 320.00, 500),
(4, '办公椅 Ergo', '办公家具', 1299.00, 700.00, 120),
(5, '蓝牙耳机 ANC', '电子产品', 799.00, 450.00, 300),
(6, '护肤套装', '美妆个护', 399.00, 180.00, 400),
(7, '双肩背包', '箱包配饰', 299.00, 130.00, 600),
(8, '智能手表 S1', '电子产品', 2499.00, 1500.00, 180);
```

```
INSERT INTO orders (order_no, customer_name, product_id, quantity, unit_price,
total_amount, status, order_date) VALUES
('ORD202601001', '王大锤', 1, 2, 4999.00, 9998.00, 'completed', '2026-01-15'),
('ORD202601002', '李小萌', 3, 1, 599.00, 599.00, 'completed', '2026-01-16'),
('ORD202601003', '赵大伟', 2, 1, 8999.00, 8999.00, 'shipped', '2026-01-17'),
('ORD202601004', '陈美美', 6, 3, 399.00, 1197.00, 'completed', '2026-01-18'),
('ORD202601005', '刘铁柱', 1, 1, 4999.00, 4999.00, 'completed', '2026-01-19'),
('ORD202601006', '周星星', 5, 2, 799.00, 1598.00, 'shipped', '2026-01-20'),
('ORD202601007', '吴彦祖', 2, 1, 8999.00, 8999.00, 'pending', '2026-01-21'),
('ORD202601008', '章子怡', 7, 1, 299.00, 299.00, 'completed', '2026-01-22'),
('ORD202601009', '孙大圣', 8, 1, 2499.00, 2499.00, 'cancelled', '2026-01-23'),
('ORD202601010', '马小云', 4, 2, 1299.00, 2598.00, 'completed', '2026-01-24'),
('ORD202602001', '王大锤', 3, 2, 599.00, 1198.00, 'completed', '2026-02-01'),
('ORD202602002', '李小萌', 1, 1, 4999.00, 4999.00, 'completed', '2026-02-03'),
('ORD202602003', '赵大伟', 5, 1, 799.00, 799.00, 'shipped', '2026-02-05'),
('ORD202602004', '陈美美', 8, 1, 2499.00, 2499.00, 'completed', '2026-02-06'),
('ORD202602005', '刘铁柱', 2, 1, 8999.00, 8999.00, 'pending', '2026-02-07'),
('ORD202602006', '周星星', 4, 1, 1299.00, 1299.00, 'completed', '2026-02-08'),
('ORD202602007', '吴彦祖', 6, 2, 399.00, 798.00, 'completed', '2026-02-10'),
('ORD202602008', '章子怡', 3, 1, 599.00, 599.00, 'cancelled', '2026-02-12'),
('ORD202602009', '孙大圣', 7, 3, 299.00, 897.00, 'completed', '2026-02-14'),
('ORD202602010', '马小云', 1, 2, 4999.00, 9998.00, 'shipped', '2026-02-15'),
('ORD202603001', '王大锤', 5, 3, 799.00, 2397.00, 'completed', '2026-03-01'),
('ORD202603002', '李小萌', 2, 1, 8999.00, 8999.00, 'completed', '2026-03-05'),
('ORD202603003', '赵大伟', 8, 1, 2499.00, 2499.00, 'shipped', '2026-03-08'),
('ORD202603004', '陈美美', 4, 1, 1299.00, 1299.00, 'completed', '2026-03-10'),
('ORD202603005', '刘铁柱', 6, 2, 399.00, 798.00, 'completed', '2026-03-12');
```

-- 索引

```
CREATE INDEX idx_orders_order_date ON orders(order_date);
```



```
CREATE INDEX idx_orders_status ON orders(status);

CREATE INDEX idx_employees_department ON employees(department_id);
```

### 17.3.4 测试部署一键启动

```
1. 复制测试环境变量
cp .env.test .env

2. 编辑 .env (修改 EMBEDDING_API_KEY 指向真实服务)
vim .env

3. 启动测试环境 (MySQL + LLM Mock + 种子数据)
docker compose -f docker-compose.test.yml up -d

4. 等待 migration 完成
docker compose -f docker-compose.test.yml logs -f migration
预期输出: [Migration] Done. Enterprise demo data loaded.

5. 验证 Mock LLM 可用
curl -X POST http://localhost:8080/mock/v1/chat/completions \
 -H "Content-Type: application/json" \
 -H "Authorization: Bearer test" \
 -d '{"model":"mock","messages":[{"role":"user","content":"test"}],"stream":false}'

返回 Mock 默认响应

6. 注入测试 LLM 响应
curl -X POST http://localhost:8080/mock/responses \
 -H "Content-Type: application/json" \
 -H "Authorization: Bearer admin-token" \
 -d '{"match":"昨天华东区销售额多少? ","response":"华东区昨日销售额 85.3 万元, 环比增长 12%"}'

7. 访问前端
open http://localhost:3000
```

### 17.3.5 测试环境清理

```
停止所有测试服务并清理数据 (包括 workspace、MySQL 种子数据)
docker compose -f docker-compose.test.yml down -v
```

18. 风险与缓解方案

风险	影响	概率	缓解措施	应急方案
ADK 框架 API 变更频繁	Agent 核心逻辑需重构	中	抽象 AgentEngine 接口，降低框架耦合	回退到自研轻量 Agent Loop
AI 模型输出质量不稳定	分析结果错误率高	高	结果置信度标注 + 用户反馈闭环	提供结果编辑功能 + 重新分析
Milvus 内存占用高	部署成本超预算	中	MVP 使用小维度向量(384d) + 定期清理	降级到 Qdrant (更轻量)
大文件索引性能瓶颈	知识库索引进度慢	中	异步队列 + 分块处理 + 并行索引	限制单文件大小上限 (20MB)
安全审查规则覆盖不足	敏感数据泄露	中	多层防护 + 定期安全审计 + 渗透测试	增加人工审批步骤
并发 Session 资源泄漏	服务器性能下降	低	严格超时 + 资源监控告警 + 定期巡检	自动重启脚本 + 手动清理工具
Agent 任务死循环	资源耗尽	低	最大步数限制(50) + 超时强制终止(10min)	全局熔断器自动切断

19. 分阶段开发任务分解

16.1 Phase 1: 基础框架 (Week 1–2)

目标: 搭建项目骨架、基础设施连接层和核心中间件。

Week 1: 项目初始化与基础设施

ID	任务	工 时	依赖	关键决策
P1-01	Go 项目初始化 (Module、目录结构、Makefile)	2h	-	Go 1.22+, RFC Section 3.2 目录结构
P1-02	Docker Compose 开发环境 (MongoDB/Milvus/SeaweedFS/Redis)	4h	-	参考 RFC Section 13.2
P1-03	配置管理系统 (Viper/YAML + 环境变量覆盖)	3h	P1-01	开发用 YAML, 生产用环境变量
P1-04	统一日志系统 (slog 结构化日志)	2h	P1-01	Go 1.21+ 原生 slog
P1-05	MongoDB 连接层 (Repository Pattern 封装)	4h	P1-02	按 RFC Section 6.1 集合设计
P1-06	Redis 连接层 (缓存 + Stream 操作)	3h	P1-02	参考 RFC Section 12.1
P1-07	SeaweedFS 连接层 (Bucket CRUD + 文件操作)	3h	P1-02	参考 RFC Section 9
P1-08	Milvus 连接层 (Collection 管理 + 向量搜索)	4h	P1-02	参考 RFC Section 10

Week 2: 中间件与认证

ID	任务	工时	依赖	关键决策
P1-09	JWT 认证中间件（签发、验证、刷新）	4h	P1-04	<code>golang-jwt/jwt</code> ，参考 RFC Section 8.2
P1-10	RBAC 引擎（角色定义、权限校验接口）	6h	P1-05, P1-09	参考 RFC Section 4.1 数据模型
P1-11	HTTP 路由注册（Gin Router + 分组）	2h	-	按 RFC Section 7.1 路由结构
P1-12	审计日志中间件（请求级别记录）	3h	P1-05, P1-09	参考 RFC Section 11
P1-13	安全过滤中间件框架（规则加载 + 过滤注册）	4h	P1-09	参考 RFC Section 8.1 YAML 规则配置
P1-14	错误码体系统一（errcode 包 + HTTP 映射）	2h	-	-
P1-15	CORS / Rate Limit 中间件	1h	-	-
P1-16	健康检查 API（ <code>GET /health</code> ）	1h	P1-05	检查所有基础设施连接

技术决策点:

决策	方案	备注
HTTP Framework	Gin	性能优先
配置格式	YAML + 环境变量覆盖	开发本地 YAML，生产环境变量
日志库	slog (Go 1.21+)	原生支持，零依赖

16.2 Phase 2: 核心服务 (Week 3–4)

目标: Agent 引擎集成、Agent Service 实现（含 Chat 模式 + Agent 批量模式 + Worker Pool）。

Week 3: Agent Engine + Skill Registry

ID	任务	工时	依赖
P2-01	ADK Agent Engine 初始化与配置	4h	P1-16
P2-02	LLM Router 实现（多模型切换、参数配置）	4h	P2-01
P2-03	Skill 接口定义与注册中心（参考 RFC Section 5.3）	4h	P2-01
P2-04	Skill 自动加载器（扫描 skills/ 目录）	3h	P2-03
P2-05	SQL Executor Skill（MCP 对接数据库）	8h	P2-03, P1-05
P2-06	Stats Engine Skill（回归 + 时间序列, gonum）	10h	P2-03
P2-07	分析结果落库模型与 Repository（参考 RFC Section 6.2）	3h	P1-05
P2-08	Artifact 存储模块（SeaweedFS volume + save_artifact Skill, 参考 RFC Section 10）	5h	P1-07, P2-03

Week 4: Agent Service (Chat 模式 + Agent 模式 + Worker Pool)

ID	任务	工时	依赖
P2-09	Session Manager (创建、续期、过期清理, 参考 RFC Section 9)	6h	P1-07
P2-10	Agent Service — Chat 模式 (SSE 流式返回, 参考 RFC §4.2 + §7.2)	6h	P2-01, P2-08
P2-11	快捷提示词 CRUD + 按角色展示	3h	P1-05
P2-12	Agent Task Queue (Redis Stream, 参考 RFC Section 12.1)	4h	P1-06
P2-13	Agent Worker Pool (并发消费, 参考 RFC Section 12.1 Worker)	6h	P2-11
P2-14	任务取消机制 (Context Cancel, 参考 RFC Section 4.3)	3h	P2-12
P2-15	任务进度上报 (WebSocket Push)	4h	P2-12
P2-16	任务完成通知 (Email + In-app)	3h	P2-14

16.3 Phase 3: 知识库与解读 (Week 5-6)

Week 5: 知识库文档处理

ID	任务	工时	依赖
P3-01	文档解析引擎 (PDF/Word/Excel/MD/TXT)	6h	–
P3-02	文档分块策略 (固定 500 字符 + 语义切分, 参考 RFC Section 10.1)	4h	P3-01
P3-03	Embedding Model 对接 (向量生成)	3h	P1-08
P3-04	Milvus Collection 创建与写入 (参考 RFC Section 10.1)	4h	P3-03, P1-08
P3-05	异步索引队列 (Redis Stream → Worker, 参考 RFC Section 10.1)	4h	P1-06
P3-06	MongoDB 全文搜索索引建立	2h	P1-05

Week 6: 搜索 + 解读 + 聚合

ID	任务	工时	依赖
P3-07	Milvus 向量相似度搜索	3h	P3-04
P3-08	混合搜索 (Semantic + Fulltext + 重排序, 参考 RFC Section 10.2)	5h	P3-07, P3-06
P3-09	权限过滤 (搜索结果按用户权限裁剪)	3h	P3-08, P1-10
P3-10	分析结果智能解读 (KB 检索 + 上下文注入)	6h	P3-08
P3-11	多维度聚合层数据定义与管理 (参考 RFC Section 6.3)	5h	P1-05
P3-12	Email Sender Skill (域名白名单)	3h	P2-03
P3-13	知识库 Web API (上传/删除/搜索)	4h	P3-08

16.4 Phase 4: 高级功能 (Week 7-8)

Week 7: 定时任务 + 子 Agent

ID	任务	工时	依赖
P4-01	Scheduler Service (robfig/cron 集成, 参考 RFC Section 4.4)	4h	P2-12
P4-02	定时任务 CRUD + 暂停/恢复	3h	P4-01
P4-03	定时任务执行 → 入队 Redis Stream → Worker 消费 → Agent Service	3h	P4-01
P4-04	失败重试逻辑 + 超时终止	2h	P4-03
P4-05	Sub-Agent 编排基础 (A2A, 参考 RFC Section 5.1 + 9.2)	6h	P2-01
P4-06	子 Agent 会话生命周期管理	4h	P2-08, P4-05

Week 8: 高级统计 + 安全 + OpenAPI

ID	任务	工 时	依赖
P4-07	聚类分析 Skill (K-Means, gonum)	6h	P2-06
P4-08	主成分分析 Skill (PCA, gonum)	4h	P2-06
P4-09	财务分析 Skill (比率计算 + 趋势对比)	6h	P2-06
P4-10	Security Audit Layer 完整实现 (参考 RFC Section 8.1)	6h	P1-13
P4-11	熔断器 Circuit Breaker (参考 RFC Section 8.1)	3h	P4-10
P4-12	OpenAPI → MCP 转换器 (参考 RFC Section 5.5)	8h	P2-03
P4-13	审计日志自动清理 (TTL Index, 参考 RFC Section 11.3)	2h	P1-12
P4-14	用户/Agent 审计日志完善 (IP、Skill 调用记录, 参考 RFC Section 11.1-11.2)	4h	P1-12
P4-15	报告格式校验模块 Report Validator (规则引擎 + Agent 修正循环, 参考 RFC Section 4.6)	6h	P2-09, P1-05



16.5 Phase 5: 管理后台 (Week 9–10)

Week 9: 后台前端搭建 + 核心页面

ID	任务	工时	依赖
P5-01	Next.js 项目初始化 + UI 框架 (Ant Design / Shadcn)	4h	–
P5-02	Admin Layout + 菜单路由	3h	P5-01
P5-03	登录页 + JWT Token 管理	3h	P5-01
P5-04	Dashboard 可视化看板 (ECharts / Recharts)	6h	P5-02
P5-05	用户管理页面 (CRUD + 角色分配 + 启停)	5h	P5-02
P5-06	权限管理页面 (角色 CRUD + 权限映射)	4h	P5-02

Week 10: 功能页面完善

ID	任务	工时	依赖
P5-07	模型配置页面 (LLM 选择 + 参数调整)	3h	P5-02
P5-08	任务管理页面 (列表 + 进度 + 取消)	4h	P5-02
P5-09	知识库管理页 (上传 + 列表 + 搜索 + 状态追踪)	5h	P5-02
P5-10	审计日志查看页 (筛选 + 导出)	4h	P5-02
P5-11	API 转换审核页面	3h	P5-02
P5-12	响应式适配 (移动浏览器兼容)	3h	P5-02
P5-13	前后端联调 + Bug 修复	8h	All above

16.6 Phase 6: 测试与优化 (Week 11–12)

Week 11: 测试

ID	任务	工时	依赖
P6-01	单元测试补充（目标覆盖率 > 70%）	10h	All
P6-02	集成测试（Service 层 + 数据库交互）	8h	P6-01
P6-03	E2E 测试（Playwright: 登录→Chat→Agent→结果）	8h	P6-02
P6-04	golangci-lint 全量检查 + 修复	4h	All
P6-05	依赖安全扫描（govulncheck）	2h	All

Week 12: 优化 + 发布

ID	任务	工时	依赖
P6-06	性能压测 + 瓶颈优化	8h	P6-03
P6-07	安全渗透测试（OWASP Top 10）	4h	P6-05
P6-08	Docker 镜像构建 + K8s 部署配置（参考 RFC Section 13）	4h	–
P6-09	内部 Alpha 发布 + 使用培训	4h	P6-08
P6-10	文档整理（API 文档 + 部署手册 + 用户指南）	6h	All

16.7 工时汇总

Phase	总预估工时	说明
Phase 1	~45h	基础设施和中间件
Phase 2	~73h	Agent Engine + Chat + Agent Service + Artifact
Phase 3	~55h	知识库文档处理 + 搜索 + 解读
Phase 4	~61h	调度器 + 子Agent + 高级 Skill + 安全 + 报告校验
Phase 5	~52h	管理后台前端
Phase 6	~56h	测试 + 优化 + 发布
总计	~342h	3 人团队约 12 周

开发路线图

20. AI 辅助开发流程规范

17.1 工作模式

采用 AI 生成代码 + 人工 Review 的混合开发模式：



Step 1 — Spec 定义: 工程师编写详细技术规格（功能需求、API 定义、数据模型、核心算法/逻辑描述）

Step 2 — 代码生成: AI 根据 Spec 生成 Go 代码 + 单元测试 + 接口文档注释

Step 3 — 人工 Review: 必须检查以下方面： -  代码逻辑正确性 -  安全审查（SQL 注入、越权、敏感数据） ← 重点 -  性能审查（N+1 查询、内存泄漏、goroutine 泄漏） -  错误处理完整性 -  代码风格一致性

Step 4 — CI/CD 自动化: golangci-lint → go test ./... → govulncheck → Build

Step 5 — PR Merge: 至少一人 Code Review + 通过 CI 检查 → Merge to Main

## 17.2 AI 生成规范模板

每次让 AI 生成代码时，必须提供以下上下文：

```
生成要求

Context
- 项目使用 Go 1.22+, Gin framework
- MongoDB driver: go.mongodb.org/mongo-driver/v2
- 代码风格遵循 golangci-lint 默认规则
- 错误处理使用自定义 errcode 包

Input Spec
[粘贴详细的技术规格]

Output Requirements
1. 生成 .go 源文件 (包含 package import path)
2. 生成对应的 _test.go 文件 (table-driven tests)
3. 关键函数添加 Godoc 注释
4. 错误处理必须显式返回，不允许 panic (除非不可恢复)
5. SQL 相关操作必须使用参数化查询
6. 敏感信息不得硬编码

Constraints
- 不修改已有文件 (只新增)
- 遵循现有目录结构 (RFC Section 3.2)
- 接口签名与 spec 保持一致
```

17.3 AI 生成 vs 人工编写比例

类别	AI 生成比例	人工介入程度	说明
项目脚手架	95%	低	模板化代码
CRUD 接口	80%	低-中	标准增删改查
中间件	70%	中	安全/审计相关需审查
Agent 逻辑	50%	高	核心 Prompt + 工具编排
Skill 实现	75%	中	取决于复杂度
安全相关	30%	极高	必须人工逐行审查
测试代码	90%	低	用例由人定，代码 AI 写
前端 UI	85%	低-中	页面布局 + 交互

21. 团队分工建议

最小团队配置

角色	人数	主要职责
后端工程师	2	核心服务开发 + AI 代码 Review
全栈/前端	1	管理后台前端 + API 联调
AI/架构师	1（兼职）	架构决策 + Agent Prompt 设计 + 技术评审

按阶段分配

Phase 1 (W1-2): 2 Backend + 1 Fullstack

- 后端：基础设施 + 中间件
- 前端：UI 框架预研

Phase 2 (W3-4): 2 Backend + 1 Fullstack

- 后端：Agent Engine + Chat/Agent Service
- 前端：Chat 页面原型

- Phase 3 (W5-6): 2 Backend
  - 后端: 知识库 + 解读 + 聚合 (专注后端)
- Phase 4 (W7-8): 2 Backend
  - 后端: 高级功能 + 安全完善
- Phase 5 (W9-10): 1 Backend + 1 Fullstack
  - 前端: 管理后台全面开发
  - 后端: API 支持 + Bug Fix
- Phase 6 (W11-12): 2 Backend + 1 Fullstack
  - 全员: 测试 + 调优 + 发布

22. 附录

19.1 开源 Skill 推荐

Skill	用途	Repository	ADK 兼容性
sql-executor	SQL 生成与执行	自研 (基于 database/sql)	✓
stats-engine	统计分析 (gonum)	自研	✓
knowledge-search	知识库搜索	自研 (Milvus SDK)	✓
email-sender	邮件发送	自研 (go-mail)	✓
openapi-mcp	API 转 MCP	社区 + 自研	⚠ 需适配
audit-logger	审计日志	go-audit/audit-go	✓
pdf-reader	PDF 解析	ledongthuc/pdf	✓
security-scanner	安全扫描	自研 (regex + keyword)	✓

## 19.2 环境变量配置

```
Server

SERVER_PORT=8080

SERVER_MODE=debug # debug | release

MongoDB (credentials managed by Vault in production)
MONGO_URI=mongodb://localhost:27017
MONGO_DB=data_agent

Milvus
MILVUS_HOST=localhost
MILVUS_PORT=19530

SeaweedFS (credentials managed by Vault in production)
SEAWEEEDFS_ENDPOINT=localhost:8333
SEAWEEEDFS_ACCESS_KEY=seaweedfs-admin
SEAWEEEDFS_SECRET_KEY=seaweedfs-admin
SEAWEEEDFS_WORKSPACE_VOLUME=workspaces
SEAWEEEDFS_ARTIFACT_VOLUME=artifacts

Redis
REDIS_ADDR=localhost:6379
REDIS_PASSWORD=
REDIS_DB=0

Mem0
MEM0_API_KEY=your_key
MEM0_ENDPOINT=http://localhost:8080

Vault
VAULT_ADDR=http://localhost:8200
VAULT_TOKEN=dev-root-token
VAULT_MOUNT_PATH=secret/data-agent # Vault KV v2 mount path

JWT (secret managed by Vault in production; dev fallback below)
JWT_SECRET=dev-secret-key
JWT_EXPIRY=24h
```

```
LLM (API key managed by Vault in production; dev fallback below)

LLM_PROVIDER=openai
LLM_MODEL=gpt-4o
LLM_API_KEY=your_key
LLM_BASE_URL=https://api.openai.com/v1

Email (password managed by Vault in production)

SMTP_HOST=smtp.company.com
SMTP_PORT=587
SMTP_USER=noreply@company.com
SMTP_PASSWORD=your_password
EMAIL_DOMAIN_WHITELIST=company.com,partner.com

Security

SECURITY_INPUT_FILTER_ENABLED=true
SECURITY_OUTPUT_FILTER_ENABLED=true
AUDIT_RETENTION_DAYS=90
```